

Statistica Descrittiva e Inferenziale

Analisi Dati e Statistica, 2026–27



Paolo Bosetti

Ultimo aggiornamento: 26/09/2026

Indice

1	Link alle slide	4
2	Statistica descrittiva	4
2.1	Variabili aleatorie (o stocastiche)	4
2.2	Effetto scala	4
2.3	Effetto scala	5
2.4	Effetto scala	6
2.5	Popolazioni	6
2.6	Popolazioni	7
2.7	Popolazione	7
2.8	Momenti di una popolazione	8
2.9	Probabilità e densità di probabilità	9
2.10	Probabilità e densità di probabilità	10
2.11	Proprietà degli operatori	10
2.12	Correlazione e covarianza	10
2.13	Campioni	11
2.14	Stimatori	11
2.15	Stime	11
2.16	Stime	12
2.17	Valore atteso e varianza della media campionaria	13
2.18	Gradi di libertà	14
3	Qualche domanda	14
3.1	Nota la media di un campione è possibile calcolare la varianza?	14
3.2	Covarianza campionaria	15

3.3	Varianza della media campionaria	15
4	Distribuzioni	15
4.1	Distribuzioni	16
5	Distribuzioni discrete	18
5.1	Distribuzione binomiale o di Bernoulli	18
5.2	Distribuzione di Poisson	19
5.3	Distribuzione geometrica	21
6	Distribuzioni continue	22
6.1	Distribuzione Uniforme	22
6.2	Distribuzione normale o gaussiana	23
6.3	Teorema del limite centrale (enunciato)	25
6.4	Teorema del limite centrale (significato)	25
6.5	Distribuzione Chi-quadro	25
6.6	Distribuzione T di Student	27
6.7	Distribuzione F di Snedecor	29
6.8	Funzioni di distribuzione	30
7	Qualche domanda	33
7.1	Gioco del lotto	33
7.2	PDF e CDF	33
8	Statistica inferenziale	34
8.1	Ipotesi statistiche	34
8.2	Matrice di confusione	34
8.3	Test di Student	35
8.4	Test di Student	36
8.5	Test di Student	37
8.6	Test di Student	38
8.7	Test di Student	38
8.8	Test di Student	38
8.9	Test di Student	39
8.10	Tabella dei quantili	40
8.11	Varianti del test di Student	41
8.12	Varianti del test di Student	42
8.13	Omoschedasticità	43
8.14	Il test di Student accoppiato	43
8.15	L'intervallo di confidenza	43
8.16	Intervallo di confidenza	44
8.17	Potenza del test di Student	44

9	Qualche domanda	45
9.1	Test di Student	45
9.2	Calcolatrice	46
9.3	Anomalie	47
9.4	Anomalie: metodo grafico	47
9.5	Anomalie: test statistici	48
9.6	Analisi di normalità	49
9.7	Analisi di normalità: istogramma	49
9.8	Sturges e Scott	50
9.9	Analisi di normalità: grafico quantile-quantile	51
9.10	Analisi di normalità: grafico quantile-quantile	53
9.11	Analisi di normalità: test del Chi-Quadro	53
9.12	Analisi di normalità: test di Shapiro-Wilk	54
9.13	Verifica di correlazione	54
10	Analisi della Varianza	55
10.1	Fattori	55
10.2	Esperimenti a un fattore e più livelli	56
10.3	Esperimenti a un fattore e più livelli	57
10.4	Esperimenti a un fattore e più livelli	57
10.5	Decomposizione della varianza	58
10.6	Decomposizione della varianza	58
10.7	Decomposizione della varianza	59
10.8	Decomposizione della varianza	59
10.9	Teorema di Cochran	60
10.10	ANOVA (<i>ANalysis Of VAriance</i>)	60
10.11	Test di Tukey	61
10.12	Test di Tukey	61
11	Qualche domanda	63
11.1	Test di Tukey	63
11.2	ANOVA	63
12	La spiegazione frequentista	63
12.1	Il significato del p -value	63
12.2	E se cambiamo n ?	65
12.3	E per la potenza?	66

1 Link alle slide



2 Statistica descrittiva

La Statistica Descrittiva serve a descrivere il comportamento di variabili aleatorie

2.1 Variabili aleatorie (o stocastiche)

Una variabile stocastica è una variabile che assume valori casuali ad ogni osservazione, cioè tali per cui non è possibile prevedere il valore esatto della prossima osservazione, nemmeno conoscendo le osservazioni precedenti

. . .

La **misurazione** è il processo che porta alla valutazione oggettiva del **misurando**. Il risultato di una misurazione è chiamato **misura**

. . .

Le variabili stocastiche sono di particolare interesse per l'ingegneria e per l'industria in genere, dato che ogni **misurazione** produce, come risultato, un valore che ha un contenuto casuale ed è quindi rappresentabile come una variabile stocastica

. . .

A sua volta, il contributo casuale ad una misura è chiamato **incertezza**

. . .


Dato che ogni attività produttiva è indissolubilmente legata a delle misurazioni, è quindi evidente quanto sia fondamentale trattare in maniera coerente e robusta i contributi casuali alle misure

2.2 Effetto scala

```

N <- 30
m <- 25
df <- tibble(i=1:N, x=rnorm(N, m, 0.01))
df %>% ggplot(aes(x=i, y=x)) +
  geom_point() +
  coord_cartesian(ylim=c(0, 50)) +
  labs(x="indice", y="misura (mm)")

```




2.3 Effetto scala

```

df %>% ggplot(aes(x=i, y=x)) +
  geom_point() +
  labs(x="indice", y="misura (mm)")

```



2.4 Effetto scala

In altre parole, la componente stocastica di una misura è affetta da un effetto scala: tanto più grande è il rapporto tra il **valore medio** misurato e la **variabilità** tipica dello strumento (cioè la sua **precisione**), tanto meno sarà apprezzabile l'effetto di casualità

È quindi essenziale definire in maniera precisa ed efficace concetti intuitivi come **variabilità** e **valore medio** che abbiamo sopra espresso

2.5 Popolazioni

In statistica, una **popolazione** è un insieme di valori, oggetti o eventi di interesse per una qualche analisi o esperimento.

Per studiare la statura dei residenti nella città di Trento, la **popolazione** di interesse è l'intero insieme degli abitanti di Trento.

Per studiare il comportamento meccanico della lega d'Alluminio prodotta da un certo impianto, la **popolazione di interesse** può essere l'intera quantità di lega prodotta da un certo lotto di materia prima

Ma per studiare anche gli effetti di variabilità delle materie prime (tra un lotto e l'altro), delle condizioni ambientali, ecc., sarebbe più opportuno **definire come popolazione un insieme più ampio**

Quindi spesso la definizione della popolazione di interesse è **arbitraria**

2.6 Popolazioni


Quindi:

- la definizione della popolazione dipende **dall'obiettivo dell'analisi**
- la dimensione di una popolazione è **generalmente molto ampia e potenzialmente non limitata**
- di conseguenza è **spesso impraticabile** considerare l'intera popolazione
- si lavora quindi su **sottoinsiemi estratti casualmente** dalla popolazione, chiamati **campioni**
- essendo estratti casualmente, i **campioni approssimano la popolazione**, tanto meglio quanto più sono numerosi

2.7 Popolazione

Osservando una popolazione possiamo identificare un **valore centrale** e una **variabilità**

```
N <- 300
m <- 25
df <- tibble(i=1:N, x=rnorm(N, m, 0.01))
df %>% ggplot(aes(x=i, y=x)) +
  geom_point() +
  geom_hline(yintercept=mean(df$x), color="red") +
  geom_hline(yintercept = mean(df$x) + c(-1, 1) * sd(df$x) * 3, color="blue") +
  coord_cartesian(ylim=c(-0.05,0.05)+m) +
  labs(x="indice", y="misura (mm)")
```



2.8 Momenti di una popolazione

Il valore centrale è chiamato **valore atteso** e la variabilità è chiamata **varianza**

- Valore atteso:

- per v.a. discrete: $\mu = E(x) := \sum_{i=1}^N x_i p(x_i)$
- per v.a. continue: $\mu = E(x) := \int_{-\infty}^{+\infty} x f(x) \, dx$

- Varianza:

- per v.a. discrete: $\sigma^2 = V(x) := \sum_{i=1}^N (x_i - \mu)^2 p(x_i)$
- per v.a. continue: $\sigma^2 = V(x) := \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) \, dx$

dove $E()$ e $V()$ sono gli **operatori valore atteso e varianza**, rispettivamente; x_i (e x) è la generica osservazione della v.a., e $p(x_i)$ e $f(x)$ sono la **probabilità** e la **densità di probabilità** di riscontrare un dato valore


Le proprietà di una popolazione si indicano con lettere greche: μ e σ^2

NOTA: Risulta $\sigma^2 = E[(x - \mu)^2]$

2.9 Probabilità e densità di probabilità

- **Probabilità (o frequenza)**: per una v.a. discreta, corrisponde al rapporto tra il numero di osservazioni di un dato valore e il numero totale di osservazioni
- **Densità di probabilità**: per una v.a. continua, la probabilità di riscontrare esattamente un dato valore è nulla, quindi ci si riferisce ad una probabilità di riscontrare un valore minore (o maggiore) di un dato valore. La densità di probabilità è la derivata di tale probabilità

```
lim <- c(-1,1) * 3  
ggplot() +  
  geom_function(fun=pnorm, aes(color="CDF"), xlim=lim) +  
  geom_function(fun=dnorm, aes(color="PDF"), xlim=lim) +  
  labs(x=TeX("x"), y=TeX("p(x)"), color="funzione")
```



- **Probabilità cumulata** (*Cumulated Distribution Function*): $p(x_0) = P(x \leq x_0)$
- **Densità di probabilità** (*Probability Density Function*): $f(x) = \frac{d}{dx}p(x)$
- Vale anche $p(x_0) = \int_{-\infty}^{x_0} f(x)dx$

2.10 Probabilità e densità di probabilità

Inoltre, si noti che probabilità e frequenza devono **sommare a 1**: rispettivamente:

$$\sum_i p(x_i) = 1$$
$$\int_{-\infty}^{\infty} f(x) \, dx = 1$$

Questo perché ovviamente la probabilità di riscontrare un qualsiasi valore deve essere certa, cioè 1

2.11 Proprietà degli operatori

Gli operatori valore atteso e varianza godono delle seguenti proprietà:

$$\begin{aligned} E(c) &= c \\ E(x) &= \mu \\ E(cx) &= cE(x) = c\mu \\ V(c) &= 0 \\ V(x) &= \sigma^2 \\ V(cx) &= c^2V(x) = c^2\sigma^2 \\ E(x+y) &= E(x) + E(y) = \mu_x + \mu_y \\ \text{Cov}(x, y) &= E[(x - \mu_x)(y - \mu_y)] \\ V(x+y) &= V(x) + V(y) + 2 \text{Cov}(x, y) \\ V(x-y) &= V(x) + V(y) - 2 \text{Cov}(x, y) \end{aligned}$$

dove c indica una costante

2.12 Correlazione e covarianza

L'operatore **covarianza** è un indice di quanto due variabili stocastiche siano interdipendenti

Più utile della covarianza (che non è limitata) è la **correlazione** che ha il vantaggio di essere compresa nell'intervallo $[-1, 1]$:

$$\text{Corr}(x, y) = \frac{E[(x - \mu_x)(y - \mu_y)]}{\sigma_x \sigma_y} = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$

- vicina a zero significa nessuna correlazione
- vicina a 1 significa forte correlazione positiva (se aumenta x aumenta anche y)
- vicina a -1 significa forte correlazione **negativa** (se aumenta x diminuisce y).

Covarianza e correlazione sono anche indicate come σ_{xy}^2 e ρ_{xy} , rispettivamente.

2.13 Campioni

Una popolazione può essere eccessivamente numerosa per essere analizzata direttamente

Quindi si analizzano dei sottoinsiemi ottenuti per campionatura, cioè estrazione casuale

L'estrazione casuale di un campione **sufficientemente grande** non altera le **proprietà di distribuzione** della popolazione

Da una popolazione di N elementi è possibile estrarre un numero di campioni di dimensione n **differenti** descritto dal **coefficiente binomiale**:

$$\binom{N}{n} = \frac{N!}{(N-n)!n!}, \quad N > n$$

2.14 Stimatori

Per ogni proprietà della popolazione è possibile definire uno **stimatore**, o **statistica**, costruito sul campione

Si definiscono **media e varianza campionarie**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad (2)$$

Un particolare valore assunto da uno stimatore è detto **stima**

Al posto della varianza S^2 si usa spesso la **deviazione standard** S (stesse unità di misura)

2.15 Stime


Dato che ogni campione è estratto casualmente, **ogni stima è una variabile aleatoria**

Più grande è il campione, più la stima si avvicina alla proprietà corrispondente: si ha **convergenza in distribuzione**

```

N <- 5000
n <- c(20, 500)
mu <- 10
ns <- 50
set.seed(123)
pop <- rnorm(N, mu, 0.1)
samples <- 1:ns
m1 <- c()
m2 <- c()
for (i in samples) {
  m1 <- c(m1, mean(sample(pop, n[1])))
  m2 <- c(m2, mean(sample(pop, n[2])))
}
tibble(i=samples, m=m) %>% ggplot() +
  geom_point(aes(x=i, y=m1, fill="20"), shape=22, size=3) +
  geom_point(aes(x=i, y=m2, fill="500"), shape=21, size=3) +
  geom_hline(yintercept=mu) +
  labs(x="# campione", y=TeX("$\\bar{x}_i$"), fill="Dimensione campione")

```




2.16 Stime

Ancora meglio, per un campione di $N = 5000$ elementi:

```

pop <- rnorm(N, mu, 0.1)
sample_sizes <- 10:N
means <- c()
for (n in sample_sizes) {
  means <- c(means, mean(sample(pop, n)))
}
tibble(n=sample_sizes, m=means) %>% ggplot(aes(x=n, y=m)) +
  # geom_line(color=gray(0.5)) +
  geom_point(alpha=0.2) +
  geom_hline(yintercept=mean(pop)) +
  labs(x="Dimensione campione", y=TeX("$\\bar{x}$"))

```



2.17 Valore atteso e varianza della media campionaria

Valore atteso della media:

$$E(\bar{x}) = E\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) = \frac{1}{n} [E(x_1 + x_2 + \dots + x_n)] \quad (3)$$

$$= \frac{1}{n} [E(x_1) + E(x_2) + \dots + E(x_n)] = \frac{1}{n} nE(x) \quad (4)$$

$$E(\bar{x}) = \mu \quad (5)$$

Varianza della media:

$$V(\bar{x}) = V\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) = \frac{1}{n^2} [V(x_1 + x_2 + \dots + x_n)] \quad (6)$$

$$= \frac{1}{n^2} [V(x_1) + V(x_2) + \dots + V(x_n)] = \frac{nV(x)}{n^2} = \frac{V(x)}{n} \quad (7)$$

$$V(\bar{x}) = \frac{\sigma^2}{n} \quad (8)$$

2.18 Gradi di libertà

I gradi di libertà di una statistica (GdF o *DoF*) sono il numero di elementi **indipendenti** che compaiono nella sua definizione. Dalla definizione della varianza risulta che

$$\sigma^2 = E\left(\frac{\sum (x_i - \bar{x})^2}{n-1}\right) = E\left(\frac{SS}{\nu}\right)$$

Cioè la varianza è il valore atteso della **somma quadratica** (*Sum of Squares*) divisa per il suo numero di gradi di libertà ν , cioè di elementi indipendenti.

Che questi ultimi siano $n-1$ è dimostrato dalla seguente relazione:

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n (x_i) - n\bar{x} =: 0$$

quindi non tutti gli n elementi nella definizione di SS possono essere indipendenti, dato che il valore di uno di essi è prevedibile dai restanti $n-1$ grazie alla definizione di $\bar{x}$

3 Qualche domanda

3.1 Nota la media di un campione è possibile calcolare la varianza?

- Sì
- No

3.2 Covarianza campionaria

Date due v. a. x e y di cui si considerano due campioni, sia $\sigma_{xy} = -7.52$. Allora:

- x e y sono fortemente correlate in senso positivo
- x e y sono fortemente correlate in senso negativo
- x e y sono debolmente correlate
- x e y sono di certo anti-correlate
- Non è possibile affermare quanto siano correlate

3.3 Varianza della media campionaria

Da una stessa popolazione estraggo una serie di campioni di 16 elementi e una seconda serie di campioni di 64 elementi. Considerando la varianza delle due medie campionarie:

- È uguale per entrambe le serie
- Quella della seconda serie è circa un quarto di quella della prima
- Quella della prima serie è circa il doppio di quella della seconda
- Quella della seconda serie è un quarto di quella della prima
- Quella della prima serie è il doppio di quella della seconda

4 Distribuzioni

Valore atteso e varianza non sono le uniche due proprietà di una popolazione.

Due popolazioni possono avere gli stessi parametri valore atteso e varianza ma avere **forme** differenti. La *forma* di una popolazione si chiama **distribuzione**

```
N <- 1000
k <- 20
a <- -sqrt(6*k) + k
b <- sqrt(6*k) + k

tibble(pop1=runif(N, a, b), pop2=rchisq(N, k)) %>%
  pivot_longer(cols=1:2, names_to="pop", values_to="value") %>%
  add_column(i=1:(2*N), .before="pop") %>%
  arrange(pop) %>%
  add_column(ig=1:(2*N), .after="i") %>%
  ggplot() +
  geom_point(aes(x=ig, y=value, col=pop, shape=pop)) +
  labs(x="indice", y="valore", color="popolazione") +
  scale_shape(name="popolazione")
```




- **pop1** mostra la stessa probabilità tra 9 e 31 circa
- pop2 mostra maggiore probabilità attorno a 20 che dirada verso l'alto e verso il basso
- Eppure hanno lo stesso valore atteso e la stessa varianza

4.1 Distribuzioni


Distribuzioni discrete

```
tibble(q=0:20, p=dgeom(q, 0.1)) %>%
  ggplot(aes(x=q, y=p)) +
  geom_col(width=0.1) +
  geom_point() +
  labs(x="x", y="p(x)")
```

Distribuzioni continue

```
tibble(x=seq(-3.5,3.5,0.01), p=dnorm(x, 0, 1)) %>%
  ggplot(aes(x=x, y=p)) +
  geom_area(fill=gray(0.75)) +
  geom_step(direction = "mid") +
  geom_label(x=0, y=0.2, label="Area = 1") +
  labs(x=TeX("x"), y="PDF(x)")
```



5 Distribuzioni discrete

5.1 Distribuzione binomiale o di Bernoulli

5.1.1 Descrizione

Un **processo di Bernoulli** è una serie di n eventi con risultati $z_1, z_2, \dots, z_n$ tali per cui:

- gli eventi z_i sono tutti *indipendenti*
- ogni z_i è rappresentabile con 0 o con 1
- la probabilità di successo $p_s \in [0, 1]$ di ciascun evento è costante

La distribuzione binomiale descrive la probabilità di ottenere $x \in [0, n]$ successi in n eventi

5.1.2 Definizioni

- Si dice che $x \sim \text{Binom}(n, p_s)$ o anche $x \sim \mathcal{B}(n, p_s)$ quando la probabilità è:

$$p(x) = \binom{n}{x} p_s^x (1 - p_s)^{n-x}, \quad x \in 0, 1, \dots, n$$


- Momenti:

$$\mu = np_s, \quad \sigma^2 = np_s(1 - p_s)$$

5.1.3 Esempi

- probabilità di ottenere 8 volte testa lanciando 10 volte una moneta

```
tibble(q=0:20, p=dbinom(q, 20, 0.5)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_col(width=0.1) +  
  geom_point() +  
  labs(x=TeX("x"), y="p(x)") +  
  labs(title="Binom(20, 0.5)")
```



5.2 Distribuzione di Poisson

5.2.1 Descrizione

- Probabilità di avere un numero $x \in \mathbb{N}^+$ di eventi che si verificano successivamente ed indipendentemente in un dato intervallo di tempo (o spazio...)
- Mediamente si verificano $\lambda \in \mathbb{R}^+$ eventi nello stesso intervallo
- È nota anche come **legge degli eventi rari**

5.2.2 Definizioni

- Si dice che $x \sim \text{Poisson}(\lambda)$ oppure $x \sim \mathcal{P}(\lambda)$ quando la probabilità è:

$$p(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad \forall x \in \mathbb{N}^+$$


- Momenti:

$$\mu = \lambda, \quad \sigma^2 = \lambda$$

5.2.3 Esempi

- probabilità di riscontrare difetti su 1 m di filo, quando ci sono mediamente 3 difetti ogni 100 m: $\lambda = 3/100$
- probabilità di ricevere telefonate nei prossimi 10' in un centralino che ne riceve mediamente 250 al giorno: $\lambda = \frac{250}{24 \cdot 60}/10$
- probabilità di avere dipendenti malati in stagione di influenza, in cui mediamente 5 dipendenti a settimana sono malati: $\lambda = 5$

```
tibble(q=1:20, p=dpois(q, 5)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_col(width=0.1) +  
  geom_point() +  
  labs(x=TeX("x"), y="p(x)") +  
  labs(title="Poisson(5)")
```



5.3 Distribuzione geometrica

5.3.1 Descrizione

È la distribuzione di probabilità di ottenere in un processo di Bernoulli un successo dopo $x \in \mathbb{N}^+$ fallimenti

5.3.2 Definizioni

- Si dice che $x \sim \text{Geom}(p_s)$ oppure $x \sim \mathcal{G}(p_s)$ quando la probabilità è:

$$p(x) = p_s(1 - p_s)^{x-1}, \quad x \in \mathbb{N}^+$$


- Momenti:

$$\mu = (1 - p_s)/p_s, \quad \sigma^2 = (1 - p_s)/p_s^2$$

5.3.3 Esempi

- La probabilità di ottenere per la prima volta un dato numero dopo x lanci di un dado a sei facce ($p_s = 1/6$)

```
tibble(q=0:20, p=dgeom(q, 1/6)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_col(width=0.1) +  
  geom_point() +  
  labs(x=TeX("x"), y="p(x)") +  
  labs(title="Geom(1/6)")
```



6 Distribuzioni continue

6.1 Distribuzione Uniforme

6.1.1 Descrizione

- distribuzione in cui tutti i valori della v.a. hanno la stessa probabilità
- può essere sia discreta che continua

6.1.2 Definizioni

- Si dice $x \sim \mathcal{U}(a, b)$ quando la PDF è:

$$f(x) = \begin{cases} 1/(b-a), & x \in [a, b] \\ 0, & \text{altrimenti} \end{cases}$$


- Momenti:

$$\mu = (b+a)/2, \quad \sigma^2 = \frac{(b-a)^2}{12}$$

6.1.3 Esempi

- Il lancio di un dado a 6 facce (discreta)
- L'estrazione di un numero della tombola (discreta)
- L'angolo di arresto di una ruota in rotazione libera (continua)

```
tibble(q=0:20, p=dunif(q, 1, 6)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_col(width=0.1) +  
  geom_point() +  
  labs(x=TeX("x"), y="p(x)") +  
  labs(title="Unif(0,1) Discreta")
```



6.2 Distribuzione normale o gaussiana

6.2.1 Descrizione

- Rappresenta il caso in cui la probabilità di riscontrare valori via via più lontani dal valore atteso decresce asintoticamente a 0
- La probabilità di un qualsiasi valore **non è mai nulla**

6.2.2 Definizioni

- Si dice che $x \sim \text{Norm}(\mu, \sigma^2)$ oppure $x \sim \mathcal{N}(\mu, \sigma^2)$ quando la PDF è:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left[\frac{x-\mu}{\sigma}\right]^2}$$

- Momenti: coincidono con i due parametri μ e σ^2


6.2.3 Nota

Se $x \sim \mathcal{N}(\mu, \sigma^2)$ allora

$$\frac{x - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

e la distribuzione $\mathcal{N}(0, 1)$ è detta **normale standard**.

```
tibble(q=seq(-3.5,3.5,0.01), p=dnorm(q, 0, 1)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_area(fill=gray(0.75)) +  
  geom_step(direction = "mid") +  
  labs(x=TeX("x"), y="f(x)") +  
  labs(title="Norm(0,1)")
```



Note

È una distribuzione che gioca un ruolo centrale, in virtù del **teorema del limite centrale**

6.3 Teorema del limite centrale (enunciato)

Teorema

Se $x_1, x_2, \dots, x_n$ sono n variabili aleatorie **indipendenti e identicamente distribuite** (IID) con $E(x_i) = \mu$ e $V(x_i) = \sigma^2 \quad \forall i = 1, 2, \dots, n$ (entrambi finiti), e $y = x_1 + x_2 + \dots + x_n$, allora:

$$z_n = \frac{y - n\mu}{\sqrt{n\sigma^2}}$$

approssima una distribuzione $\mathcal{N}(0, 1)$, nel senso che se $F_n(z)$ è la funzione di distribuzione di z_n e $\Phi(z)$ è la funzione di distribuzione di $\mathcal{N}(0, 1)$, allora:

$$\lim_{n \rightarrow +\infty} \frac{F_n(z)}{\Phi(z)} = 1$$

6.4 Teorema del limite centrale (significato)

- Fondamentale nel **campo delle misure**:
 - una misura è somma di una serie di eventi
 - ogni evento può avere una distribuzione ignota
 - sommando molte distribuzioni il risultato converge alla normale
 - quindi il risultato di una misura è **spesso** normale
- La convergenza è spesso molto rapida (una decina di elementi)
- **Nota**: sommando o moltiplicando una distribuzione per una costante cambiano i suoi momenti ma la distribuzione rimane la stessa. Invece, operazioni tra v.a. **cambiano la distribuzione risultante!**

6.5 Distribuzione Chi-quadro

6.5.1 Descrizione

- È la distribuzione di una somma di distribuzioni **normali standard**
- Cioè, sia $x = z_1^2 + z_2^2 + \dots + z_k^2$, con $z_i \sim \mathcal{N}(0, 1) \quad \forall i = 1, 2, \dots, k$, allora la distribuzione di x è una Chi-quadro
- Il numero di normali sommate k è il **numero di gradi di libertà** della distribuzione

6.5.2 Definizioni

- Si dice che $x \sim \chi_k^2$ quando la PDF è:

$$f(x) = \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}$$

- Momenti:

$$\mu = k, \quad \sigma^2 = 2k$$

6.5.3 Nota


Considerando la somma quadratica di un campione di k elementi y_i , ciascuno proveniente da una distribuzione $\mathcal{N}(\mu, \sigma^2)$, risulta che:

$$\frac{(y_i - \bar{y})}{\sigma} \sim \mathcal{N}(0, 1) \quad \forall i = 1, 2, \dots, k$$

e quindi:

$$\frac{SS}{\sigma^2} = \frac{\sum_{i=1}^k (y_i - \bar{y})^2}{\sigma^2} \sim \chi_{k-1}^2$$

```
tibble(q=seq(-0,40,0.1), p=dchisq(q, 10)) %>%
  ggplot(aes(x=q, y=p)) +
  geom_area(fill=gray(0.75)) +
  geom_line() +
  labs(x=TeX("x"), y="f(x)") +
  labs(title=TeX("$\\chi^2_{10}$"))
```



6.6 Distribuzione T di Student

6.6.1 Descrizione

Siano due v.a.

$$z \sim \mathcal{N}(0, 1), \quad x \sim \chi_k^2$$

allora la loro combinazione

$$x = \frac{z}{\sqrt{x/k}}$$

è distribuita come una T di Student

6.6.2 Definizioni

- Si dice che $x \sim T_k$ oppure $x \sim \mathcal{T}_k$ quando la PDF è:

$$f(x) = \frac{\Gamma((k-1)/2)}{\sqrt{k\pi}\Gamma(k/2)} \frac{1}{((x^2/k) + 1)^{(k+1)/2}}$$

- Momenti:

$$\mu = 0, \quad \sigma^2 = k/(k-2)$$


6.6.3 Nota

La T di Student è un caso particolare della $\mathcal{N}(0, 1)$:

$$\lim_{k \rightarrow +\infty} t_k = \mathcal{N}(0, 1)$$

La convergenza è **molto rapida**: già per $k > 30$ la differenza tra le due funzioni di distribuzione diventa trascurabile

```
tibble(q=seq(-3.5,3.5,0.1), p=dt(q, 3), n=dnorm(q, 0, 1)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_area(fill=gray(0.75)) +  
  geom_line() +  
  geom_line(aes(x=q, y=n),lty=2) +  
  labs(x=TeX("x"), y="f(x)") +  
  labs(title=TeX("$T_3$"))
```



i Note

La figura confronta la T di Student con la normale standard (tratteggiata)

6.7 Distribuzione F di Snedecor

6.7.1 Descrizione

Siano due v.a.

$$x_u \sim \mathcal{X}_u^2, \quad x_v \sim \mathcal{X}_v^2$$

e si definisce x come:

$$x = \frac{x_u/u}{x_v/v}$$

allora x è una v.a. distribuita come una F di Snedecor

6.7.2 Definizioni


- Si dice che $x \sim F_{u,v}$ oppure $x \sim \mathcal{F}_{u,v}$ quando la PDF è:

$$f(x) = \frac{\Gamma\left(\frac{u+v}{2}\right) \left(\frac{u}{v}\right)^{u/2} x^{(u/2)-1}}{\Gamma\left(\frac{u}{2}\right) \Gamma\left(\frac{v}{2}\right) \left(\frac{u}{v}x + 1\right)^{(u+v)/2}}$$

- Momenti:

$$\mu = \frac{v}{v-2}, \quad \sigma^2 = \frac{2v^2(u+v-2)}{u(v-2)^2(v-4)}$$

```
tibble(q=seq(0,5,0.01), p=df(q, 10,10)) %>%  
  ggplot(aes(x=q, y=p)) +  
  geom_area(fill=gray(0.75)) +  
  geom_line() +  
  labs(x=TeX("x"), y="f(x)") +  
  labs(title=TeX("$F_{10,10}$"))
```



6.8 Funzioni di distribuzione

Una distribuzione è descritta da tre funzioni, tra loro correlate:


- **funzione di densità di distribuzione**, PDF
- **funzione di distribuzione cumulata**, CDF, è l'integrale progressivo della PDF:

$$\begin{aligned} \text{CDF}^-(x) &= \int_{-\infty}^x \text{PDF}(x) \, dx \\ \text{CDF}^+(x) &= \int_x^{+\infty} \text{PDF}(x) \, dx \end{aligned}$$

- **funzione quantile**, è l'inversa della CDF; è definita solo in $[0, 1]$


6.8.1 PDF

```
ggplot() +
  geom_function(fun=dnorm, args=list(mean=0, sd=1), xlim=c(-3,3)) +
  labs(x=TeX("x"), y="PDF(x)") +
  labs(title="Norm(0,1)")
```




6.8.2 CDF

```
ggplot() +
  geom_function(aes(color="bassa"), fun=pnorm, args=list(mean=0, sd=1), xlim=c(-3,3)) +
  geom_function(aes(color="alta"), fun=pnorm, args=list(mean=0, sd=1, lower.tail=F), xlim=c(-3,3)) +
  labs(x=TeX("x"), y="CDF(x)", color="coda:") +
  labs(title="Norm(0,1)")
```



6.8.3 Quantile

```
ggplot() +
  geom_function(aes(color="alta"), fun=qnorm, args=list(mean=0, sd=1), xlim=c(0,1), n=1001) +
  geom_function(aes(color="bassa"), fun=qnorm, args=list(mean=0, sd=1, lower.tail=F), xlim=c(0,1), n=1001) +
  labs(x=TeX("x"), y=TeX("Q(x)"), color="coda:") +
  labs(title="Norm(0,1)")
```

7 Qualche domanda

7.1 Gioco del lotto

Nel gioco del lotto, la probabilità di vincere giocando sempre gli stessi numeri:

- Aumenta ad ogni estrazione, come predetto dalla distribuzione $\mathcal{B}$
- Aumenta ad ogni estrazione, come predetto dalla distribuzione $\mathcal{P}$
- Aumenta ad ogni estrazione, come predetto dalla distribuzione $\mathcal{G}$
- È costante ad ogni estrazione

7.2 PDF e CDF

Quali di queste affermazioni sono corrette:

- Qualsiasi CDF è monotona crescente
- Esistono distribuzioni con PDF definita solo per valori positivi
- Per ogni CDF possono esistere più di una PDF che la generano
- $\text{PDF}(-x) = -\text{PDF}(x)$
- $\text{CDF}^+(x) = \text{CDF}^-(x)$
- $\text{CDF}^+(x) = 1 - \text{CDF}^-(x)$

- Una funzione quantile può avere un dominio illimitato a destra o sinistra

8 Statistica inferenziale

Studia le operazioni di **inferenza**, cioè ricavare informazioni sulla popolazione a partire da un suo campione

8.1 Ipotesi statistiche

- Si è visto che media e varianza campionaria sono due **stimatori** e rappresentano delle **variabili aleatorie**
- Quindi prelevando due campioni da una popolazione le due **stime** di media e varianza saranno sempre differenti
- Come faccio a sapere se due campioni con media diversa provengono dalla stessa popolazione?
- Posso formulare una **coppia di ipotesi alternative**:

$$H_0 : \mu_1 = \mu_2 \quad (9)$$

$$H_1 : \mu_1 \neq \mu_2 \quad (10)$$

$$(11)$$

Note

H_0 è detta **ipotesi nulla**, o debole; H_1 è detta **ipotesi alternativa**, o forte

8.2 Matrice di confusione

Un **test di ipotesi** può avere due tipi di errore:

- Errore di tipo I: falso positivo, o falso allarme
- Errore di tipo II: falso negativo, o mancato allarme

Lo scopo della statistica inferenziale è associare una probabilità a questi errori

```
tribble(
  ~"Ipotesi nulla", ~vera, ~falsa,
  "accettata", "OK", "Errore tipo II",
  "rifiutata", "Errore tipo I", "OK"
) %>%
  knitr::kable()
```

Ipotesi nulla	vera	falsa
accettata	OK	Errore tipo II
rifiutata	Errore tipo I	OK

La probabilità di un Errore di tipo I è α , la probabilità di un Errore di tipo II è β .

Il valore $1 - \beta$ è la **potenza** P del test

i Note

Nota: $\alpha \neq 1 - \beta$

8.3 Test di Student



Figure 1: William S. Gosset

- **William S. Gosset**, detto *Student*, mastro birraio Guinness a Dublino, ~1900
- **Problema:** come capire se due medie diverse su campioni di processo indicano due diversi processi?
- Siano i due campioni **normali e indipendenti** $y_{1,i}$, $i = 1, 2, \dots, n_1$ e $y_{2,i}$, $i = 1, 2, \dots, n_2$, sarà ovviamente $\bar{y}_1 \neq \bar{y}_2$, quindi come faccio a capire se vale H_0 o H_1 ?

Ovviamente la risposta è **probabilistica**: posso solo associare una probabilità d'errore α al

test di ipotesi

$$H_0 : \mu_1 = \mu_2 \quad (12)$$


$$H_1 : \mu_1 \neq \mu_2 \quad (13)$$

$$(14)$$

8.4 Test di Student

- I campioni **C1** e C3 non avranno valori comuni: è molto probabile che vengano da popolazioni differenti
- I campioni **C1** e C2 invece sono più difficili da distinguere
- Intuitivamente, H_1 è tanto più probabile quanto più le medie sono distanti e le varianze strette

```
set.seed(0)
mu <- c(5.1, 5.25, 4.2)
sd <- 0.1
N <- 15
c <- tibble(
  c1=rnorm(N, mu[1], sd),
  c2=rnorm(N, mu[2], sd),
  c3=rnorm(N, mu[3], sd),
)
tibble(
  x=seq(3.5, 6.5, length.out=200),
  p1=dnorm(x, mu[1], sd),
  p2=dnorm(x, mu[2], sd),
  p3=dnorm(x, mu[3], sd)) %>%
ggplot(aes(x=x)) +
  geom_line(aes(y=p1, color="C1")) +
  geom_line(aes(y=p2, color="C2")) +
  geom_line(aes(y=p3, color="C3")) +
  geom_rug(aes(x=c1, color="C1"), length=unit(0.05, "npc"), data=c) +
  geom_rug(aes(x=c2, color="C2"), data=c) +
  geom_rug(aes(x=c3, color="C3"), data=c) +
  labs(x="grado alcolico (%)", y="PDF(x)", color="popolazione:")
```



Note

Nel grafico, i **trattini verticali in basso** rappresentano i valori di 10 campioni casuali estratti dalle rispettive popolazioni

8.5 Test di Student

Per i due campioni $y_{1,i}$ e $y_{2,i}$ è possibile definire la variabile:

$$t_0 = \frac{\bar{y}_2 - \bar{y}_1}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

dove S_p^2 è chiamata **varianza comune** (*pooled variance*) e vale:

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

La t_0 è il rapporto tra una v.a. normale al numeratore e una v.a. χ^2 al denominatore. Di conseguenza è essa stessa una v.a. ed è definita come una T di Student.

- Il **numero di gradi di libertà** è lo stesso della χ^2 ed è $n_1 + n_2 - 2$
- t_0 è detta **statistica di test** e vale che $t_0 \sim t_{n_1+n_2-2}$

8.6 Test di Student

- È evidente che casi come **C1** vs. C3 nel grafico precedente avranno un valore di $|t_0|$ più alto che casi come **C1** vs. C2 (rapporto tra distanza e varianza)
- Ma data una coppia di campioni provenienti dalla stessa popolazione la probabilità di valori elevati di $|t_0|$ è molto bassa
- Dato che conosciamo la **distribuzione** di t_0 possiamo quindi calcolare la probabilità di riscontrare un dato valore **assumendo che valga** H_0
- In altre parole, la probabilità di sbagliare rifiutando H_0 quando essa è vera è pari alla probabilità di riscontrare un valore pari o superiore a t_0 nella distribuzione di Student
- In realtà, il segno di t_0 è arbitrario, quindi bisogna verificare la probabilità di riscontrare un valore **esterno all'intervallo** $[-|t_0|, |t_0|]$

8.7 Test di Student

In definitiva, la probabilità di un errore di tipo I nel test di Student risulta:

$$p\text{-value} = 2\text{CDF}_t^+(|t_0|, n_1 + n_2 - 2)$$

dove CDF_t^+ è la **distribuzione cumulata, coda alta**, di una T di Student con $n_1 + n_2 - 2$ g.d.l. e dove il fattore 2 tiene in considerazione l'ultimo punto della pagina precedente

La probabilità d'errore di un qualunque test statistico è chiamata **p-value**

- Più piccolo è il p -value, più siamo spinti a rifiutare H_0
- Tipicamente, si tende a rifiutare H_0 quando il p -value diventa minore del 5%

8.8 Test di Student

Spesso nei test statistici si accetta o rifiuta H_0 sulla base di una soglia di probabilità d'errore di tipo I, indicata con α

1. Si fissa un α a priori in funzione del **rischio associato** al test
2. Si calcola il valore di $t_{0,\max}$ che corrisponde a α
3. Se risulta $|t_0| \geq t_{0,\max}$ **si rifiuta** H_0 con una probabilità d'errore **minore di** α

Il valore di soglia si calcola mediante la **funzione quantile** e si rifiuta H_0 quando:

$$|t_0| \geq t_{0,\max} = t_{\alpha/2, n_1 + n_2 - 2}$$


dove $t_{\alpha/2, n_1 + n_2 - 2}$ è appunto la funzione quantile, coda alta, della T di Student valutata per la probabilità $\alpha/2$ e per $n_1 + n_2 - 2$ g.d.l.

8.9 Test di Student

```
N <- 15
a <- 0.1
t0 <- qt(a/2, N, lower.tail=F)
df <- tibble(
  x=seq(-4,4,length.out=101),
  d=dt(x, N),
  p=pt(x, N, lower.tail=F)
)
df %>%
  ggplot(aes(x=x)) +
    geom_hline(yintercept=a/2, color=gray(1/3), lty=2) +
    geom_vline(xintercept=t0, color=gray(1/3), lty=2) +
    geom_area(aes(y=d), data=filter(df, x > t0), fill=gray(2/3), alpha=0.5) +
    geom_area(aes(y=d), data=filter(df, x < -t0), fill=gray(2/3), alpha=0.5) +
    geom_line(aes(y=d, color="PDF")) +
    geom_line(aes(y=p, color="CDF+")) +
    geom_label(aes(x=t0, y=0.5), label=TeX("$t_0$")) +
    geom_label(aes(x=0, y=a/2), label=TeX("$\\alpha/2$")) +
    labs(x="t", y="p", color="curva:")
```

Warning in geom_label(aes(x = t0, y = 0.5), label = TeX("\$t_0\$")): All aesthetics have length 1
Please consider using `annotate()` or provide this layer with data containing a single row.

Warning in geom_label(aes(x = 0, y = a/2), label = TeX("\$\\alpha/2\$")): All aesthetics have length 1
Please consider using `annotate()` or provide this layer with data containing a single row.



Note:

- L'ordinata della CDF^+ in t_0 è uguale all'area sottesa dalla PDF in $[t_0, +\infty)$ (in grigio)
- Il segno del numeratore in t_0 è arbitrario, quindi $CDF^+(t_0)$ è la metà della probabilità d'errore di tipo I complessiva, cioè $\alpha/2$

8.10 Tabella dei quantili

In assenza dei calcolatori, il Test di Student veniva effettuato predeterminando α e decidendo se rifiutare H_0 sulla base della **tabella dei quantili**:

```
N <- 30
df <- tibble(dof=1:N)
for (i in c(0.1, 0.05, 0.025, 0.01, 0.005, 0.0025, 0.001)) {
  df[,as.character(i)] <- qt(i, df$dof, lower.tail=F)
}
knitr::kable(head(df, n=10), digits=3)
```

dof	0.1	0.05	0.025	0.01	0.005	0.0025	0.001
1	3.078	6.314	12.706	31.821	63.657	127.321	318.309
2	1.886	2.920	4.303	6.965	9.925	14.089	22.327
3	1.638	2.353	3.182	4.541	5.841	7.453	10.215

dof	0.1	0.05	0.025	0.01	0.005	0.0025	0.001
4	1.533	2.132	2.776	3.747	4.604	5.598	7.173
5	1.476	2.015	2.571	3.365	4.032	4.773	5.893
6	1.440	1.943	2.447	3.143	3.707	4.317	5.208
7	1.415	1.895	2.365	2.998	3.499	4.029	4.785
8	1.397	1.860	2.306	2.896	3.355	3.833	4.501
9	1.383	1.833	2.262	2.821	3.250	3.690	4.297
10	1.372	1.812	2.228	2.764	3.169	3.581	4.144

```

N <- 20
df <- tibble(dof=11:N)
for (i in c(0.1, 0.05, 0.025, 0.01, 0.005, 0.0025, 0.001)) {
  df[,as.character(i)] <- qt(i, df$dof, lower.tail=F)
}
knitr::kable(df, digits=3)

```

dof	0.1	0.05	0.025	0.01	0.005	0.0025	0.001
11	1.363	1.796	2.201	2.718	3.106	3.497	4.025
12	1.356	1.782	2.179	2.681	3.055	3.428	3.930
13	1.350	1.771	2.160	2.650	3.012	3.372	3.852
14	1.345	1.761	2.145	2.624	2.977	3.326	3.787
15	1.341	1.753	2.131	2.602	2.947	3.286	3.733
16	1.337	1.746	2.120	2.583	2.921	3.252	3.686
17	1.333	1.740	2.110	2.567	2.898	3.222	3.646
18	1.330	1.734	2.101	2.552	2.878	3.197	3.610
19	1.328	1.729	2.093	2.539	2.861	3.174	3.579
20	1.325	1.725	2.086	2.528	2.845	3.153	3.552

Ad esempio, per un campione con 8 g.d.l. e $\alpha = 0.1$ risulta un valore critico di $t_0 = 1.86$: ogni valore di t_0 calcolato superiore a tale valore (in modulo) comporta il rifiuto di H_0 con una probabilità d'errore inferiore al 10%

8.11 Varianti del test di Student

Il test di Student sopra visto vale per il caso più generico. Esistono varianti del test per le seguenti condizioni, che possono combinarsi per dare luogo a 4 diversi test:

- test a uno o due campioni
- test a uno o due lati (in H_1 la disuguaglianza è sostituita con un $>$ o un $<$)

Inoltre, nel caso di test a due campioni è possibile assumere che i campioni siano **omoschedastici** oppure no

i Note

Due campioni sono detti **omoschedastici** quando provengono da popolazioni con **identica varianza**

8.12 Varianti del test di Student

- Test a un campione:

$$H_0 : \mu = \mu_0 \quad (15)$$

$$H_1 : \mu \neq \mu_0 \quad (16)$$

$$t_0 = \frac{\mu_0 - \bar{y}}{S/\sqrt{n}}$$

- Test a un lato:

$$H_0 : \mu_1 = \mu_2 \quad (17)$$

$$H_1 : \mu_1 \geq \mu_2 \quad (18)$$

$$t_0 \geq \pm t_{\alpha, k} \quad (19)$$

$$p\text{-value} = CDF_t^\pm(t_0, k) \quad (20)$$

Nota: il test a un lato, a pari valore di t_0 , ha una soglia di rifiuto di H_0 più bassa, ed è quindi **più potente**

8.13 Omoschedasticità

Il test a due campioni sopra visto assume che i due campioni siano **omoschedastici**. Se non lo sono, è necessario rivedere la definizione di t_0 come segue (**Test di Welch**):

$$t_0 = \frac{\bar{y}_1 - \bar{y}_2}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}; \quad \nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

L'ipotesi di omoschedasticità va preliminarmente verificata con un **test della varianza**:

$$\begin{aligned} H_0 : \sigma_1^2 &= \sigma_2^2 \\ H_1 : \sigma_1^2 &\neq \sigma_2^2, \end{aligned} \quad F_0 = \frac{S_1^2}{S_2^2} \sim \mathcal{F}_{n_1-1, n_2-1}$$

Cioè se il p -value associato a F_0 è piccolo, si assume che i campioni non siano omoschedastici e quindi si effettua il test di Welch; altrimenti vale il test di Student

8.14 Il test di Student accoppiato

Nel caso di test di Student a due campioni, quando essi **hanno la stessa dimensione e sono raccolti due a due in condizioni molto simili**, è opportuno accoppiarli e effettuare il test di Student accoppiato

Ogni misura è esprimibile come:

$$y_{ij} = \mu_i + \beta_j + \varepsilon_{ij}; \quad \begin{cases} i = 1, 2 \\ j = 1, 2, \dots, n \end{cases}$$

Se definisco $d_j = y_{1j} - y_{2j}$, ricordando le proprietà dell'operatore $E(\cdot)$, risulta $\mu_d = \mu_1 - \mu_2$. Quindi posso riformulare una coppia di ipotesi equivalenti:

$$H_0 : \mu_d = 0 \tag{21}$$

$$H_1 : \mu_d \neq 0 \tag{22}$$

Quindi il test accoppiato è un test a un campione, con il vantaggio che **gli effetti casuali tra coppie di osservazioni non influiscono sul risultato del test**

8.15 L'intervallo di confidenza

Dato parametro ignoto ϑ , vogliamo definire due statistiche L e U , tali per cui la probabilità: $P(L \leq \vartheta \leq U) = 1 - \alpha$. In questo caso l'intervallo $[L, U]$ è detto **intervallo di confidenza** per il parametro ϑ .

Consideriamo un T-test ad un campione. Sappiamo che:

$$t_0 = \frac{\bar{x} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Se c è $t_{\alpha/2, n-1}$, allora, per definizione: $P(-c \leq t_0 \leq c) = 1 - \alpha$

Sostituendo t_0 otteniamo:

$$P(\bar{x} - cS/\sqrt{n} \leq \mu \leq \bar{x} + cS/\sqrt{n}) = 1 - \alpha$$

8.16 Intervallo di confidenza

In pratica, significa che il valore atteso della popolazione (che è ignoto!) ha la probabilità $1 - \alpha$ di ricadere nell'**intervallo** $[\bar{x} - cS/\sqrt{n}, \bar{x} + cS/\sqrt{n}]$, **detto di confidenza**

Se il μ_0 del corrispondente test sta al di fuori dell'intervallo di confidenza, allora possiamo rifiutare H_0 con un errore inferiore a α .

Per un **test a due campioni** risulta:

$$P\left(-t_{\alpha/2, n_1+n_2-2} \leq \frac{(\bar{y}_1 - \bar{y}_2) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \leq t_{\alpha/2, n_1+n_2-2}\right) = 1 - \alpha$$

Quindi l'intervallo di confidenza $[L, U]$ è definito da:


$$\left[(\bar{y}_1 - \bar{y}_2) - t_{\alpha/2, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, (\bar{y}_1 - \bar{y}_2) + t_{\alpha/2, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$$

8.17 Potenza del test di Student

La **potenza** di un test statistico è la probabilità di rifiutare l'ipotesi nulla quando essa è falsa, cioè $1 - \beta$. È l'**affidabilità** del test. Essa dipende ovviamente dalla dimensione dei campioni. È possibile calcolare le **curve di potenza** per diverse dimensioni dei campioni e per diverse dimensioni di dello **scarto relativo** $\delta = (\mu_1 - \mu_2)/\sigma$.

```
expand_grid(
  n=c(3:10, 12, 15, 20),
  alpha=c(0.005, 0.01, 0.05, 0.1),
  delta = seq(0, 4, 0.05),
) %>%
```

```
mutate(
  power = power.t.test(n=n, delta=delta, sig.level=alpha)$power,
  n=factor(n)
) %>%
ggplot(aes(x=delta, y=power, color=n)) +
geom_line() +
facet_wrap(~alpha) +
geom_hline(yintercept=0.9, linetype=2) +
labs(y="Potenza del test", x=TeX("$\\delta=(\\mu_1 - \\mu_2)/\\sigma$")) +
theme(legend.position="right")
```



- La potenza del test diminuisce con la differenza tra le medie
- La potenza del test aumenta con la dimensione dei campioni
- La potenza del test aumenta con α
- Con $\alpha = 0.05$ e $n = 10$, la potenza del test è ≥ 0.9 per $\delta \geq 1.5$

9 Qualche domanda

9.1 Test di Student

Ho due campioni di dati, uno con $n_1 = 10$, $\bar{y}_1 = 13.59213$, $S_1 = 4.33921$ e l'altro con $n_2 = 10$, $\bar{y}_2 = 10.30381$, $S_2 = 2.24028$. Voglio confrontare le medie dei due campioni con un test di Student, assumendo $\alpha = 0.05$:

- $\mu_1 \neq \mu_2$, con un p -value pari a 0.0473
- $\mu_1 = \mu_2$, con un p -value pari a 0.0522
- $\mu_1 \neq \mu_2$, con un p -value pari a 0.0623
- $\mu_1 = \mu_2$, con un p -value pari a 1.39E-4
- $\mu_1 \neq \mu_2$, con un p -value pari a 0.0487

9.2 Calcolatrice

Usare il riquadro sottostante per risolvere l'esercizio precedente (provare anche con la [tabella dei quantili](#))

9.2.1 Esercizio

```
#| exercise: "t_test"
n1=10; n2=10
y1=13.59213; y2=10.30381
s1=4.33921; s2=2.24027
# calcolo probabilità dalla T di Student:
pt(1.38, df=n1, lower.tail=F)
# calcolo probabilità dalla F:
pf(2, n1, n2, lower.tail=F)
```

9.2.2 Suggerimento

Calcolare prima F_0 per un test della varianza e il suo p -value, ricordando che il test della varianza è a due lati.

Poi calcolare t_0 e il suo p -value, utilizzando il test di Student o di Welch a seconda del risultato del test della varianza.

Nota: la radice quadrata si ottiene con `sqrt(x)`, l'elevamento a potenza con `x^y`.

9.2.3 Soluzione

Solution.

```
#| setup: true
#| exercise: "t_test_sol"
n1=10; n2=10
y1=13.59213; y2=10.30381
s1=4.33921; s2=2.24027
```

```
#| exercise: "t_test_sol"
# verifico la omoschedasticità:
F0=s1^2/s2^2
2*pf(F0, n1-1, n2-1, lower.tail=F)
# p-value è > 0.05, quindi campioni omoschedastici

Sp = sqrt(((n1-1)*s1^2 + (n2-1)*s2^2)/(n1+n2-2))
T0 = (y1-y2)/(Sp*sqrt(1/n1 + 1/n2))
2*pt(T0, df=n1+n2-2, lower.tail=F)
# quindi  $\mu_1 \neq \mu_2$ , con p-value = 0.0473
```

9.3 Anomalie

La raccolta dei dati relativi ad un campione può essere **affetta da errori**:

- nell'operazione di misura
- nell'operazione di trascrittura del dato

Questi errori ovviamente hanno un'elevata probabilità di **non concordare con il resto dei dati**, cioè di essere troppo lontani dalla media in rapporto alla varianza tipica del processo.

Questi errori sono chiamati **anomalie** ed è buona norma identificarli ed eliminarli **immediatamente dopo aver concluso la raccolta dei dati**

Note

In Inglese le anomalie sono note come *outlier*


9.4 Anomalie: metodo grafico

Il più comune metodo grafico per individuare le anomalie è il *box-plot*

```

set.seed(0)
tibble(
  d1=c(rnorm(10, 3, 0.5), 5),
  d2=c(rnorm(10, 4.8, 0.8), 5)
) %>%
  pivot_longer(d1:d2) %>%
  ggplot(aes(x=name, y=value)) +
  geom_boxplot() +
  coord_flip() +
  labs(y="valore", x="campione")

```



- il box va dal primo al terzo quartile (metà dei dati)
- la linea nel box è la mediana
- i baffi vanno dal minimo al punto più lontano ma non oltre 1.5 volte l'interquartile
- i punti oltre i baffi sono **possibili anomalie**

9.5 Anomalie: test statistici

9.5.1 Criterio di Chauvenet

Non è un vero test ma un criterio in base al quale eliminare il punto più lontano dalla media (uno solo!)

Dati $\langle x_1, x_2, \dots, x_n \rangle$ con **distribuzione normale**, si calcola la massima differenza assoluta $s_0 = \max_{i=1, \dots, n} \left(\frac{|x_i - \bar{x}|}{S_x} \right)$

Per via della normalità degli x_i è evidente che $|x_i - \bar{x}|/S_x \sim \mathcal{N}(0, 1)$. Possiamo quindi calcolare la probabilità di un valore maggiore o uguale a s_0 dalla funzione di ripartizione, coda superiore:

$$P_s = \text{CDF}_{\mathcal{N}}^+(s_0)$$

Su n osservazioni normali ci aspettiamo nP_s valori più grandi di s_0 . Quindi, se risulta $nP_s < 0.5$, mentre noi abbiamo **un** punto sospetto, allora possiamo scartare l'anomalia

9.5.2 Test di Grubb

Il test di Grubb è un vero e proprio **test statistico**, basato su una coppia di ipotesi (H_1 porta allo scarto della sospetta anomalia), su una statistica di test e sul calcolo di un **p-value**.

In breve:

$$G_0 = \frac{\max_{i=1, \dots, n} |y_i - \bar{y}|}{S_x} \quad (23)$$

$$G_0 > \frac{n-1}{n} \sqrt{\frac{t_{\alpha/(2n), n-2}^2}{n-2 + t_{\alpha/(2n), n-2}^2}} \Rightarrow \neg H_0 \quad (24)$$

9.6 Analisi di normalità

I test visti fin qui assumono sempre che i campioni su cui si opera **derivino da una distribuzione normale**, per quanto a parametri incogniti

Prima di effettuare un qualsiasi test, quindi, è necessario verificare l'ipotesi di normalità

Come per l'analisi delle anomalie, anche in questo caso è possibile utilizzare sia metodi grafici che test statistici

In generale, i test statistici sono sempre preferibili, perché


- sono meno soggetti a interpretazione personale
- consentono l'**automazione** della scelta all'interno di **algoritmi**

9.7 Analisi di normalità: istogramma

```

set.seed(0)
N <- 3000
df <- tibble(
  c=rnorm(N, 10, 3)
)
df %>% ggplot() +
  geom_histogram(aes(x=c, y=after_stat(density)), bins=nclass.Sturges(df$c), alpha=0.5, color="grey") +
  geom_function(fun=dnorm, args=list(mean=mean(df$c), sd=sd(df$c))) +
  labs(x="valore", y="densità di probabilità", title="3000 elementi")
df[1:100,] %>% ggplot() +
  geom_histogram(aes(x=c, y=after_stat(density)), bins=nclass.Sturges(1:100), alpha=0.5, color="grey") +
  geom_function(fun=dnorm, args=list(mean=mean(df$c), sd=sd(df$c))) +
  labs(x="valore", y="densità di probabilità", title="100 elementi")

```




Per il numero di canne, o *bin*, si usa la **formula di Sturges**: $K = \lceil \log_2 n \rceil + 1$ o la **formula di Scott**: $h = 3.49s / \sqrt[3]{n}$ (h è l'ampiezza della canna)

9.8 Sturges e Scott

```

df <- tibble(
  n = seq(10, 5000, by=1),
)
df$Sturges <- map_dbl(df$n, ~nclass.Sturges(1:..))
df$Scott <- map_dbl(df$n, ~nclass.scott(rnorm(..)))
df %>%
  pivot_longer(Sturges:Scott) %>%
  ggplot() +
  geom_line(aes(x=n, y=value, color=name)) +
  labs(x="dimensione campione", y="numero di canne", color="metodo")

```



9.9 Analisi di normalità: grafico quantile-quantile


Tabella campionaria:

```
set.seed(0)
N <- 10
df <- tibble(
  i = 1:N,
  x = sort(rnorm(N)),
  f = (i-3/8)/(N+1-3/4),
  q = qnorm(f)
)
knitr::kable(df, digits=3)
```

i	x	f	q
1	-1.540	0.061	-1.547
2	-0.929	0.159	-1.000
3	-0.326	0.256	-0.655
4	-0.295	0.354	-0.375
5	-0.006	0.451	-0.123
6	0.415	0.549	0.123

i	x	f	q
7	1.263	0.646	0.375
8	1.272	0.744	0.655
9	1.330	0.841	1.000
10	2.405	0.939	1.547

```
x <- qnorm(c(0.25, 0.75))
y <- as.vector(quantile(df$x, probs = c(0.25, 0.75), names = FALSE, na.rm = TRUE))
pts <- tibble(x=x, y=y)
slope <- diff(y)/diff(x)
int <- y[1] - slope * x[1]
df %>% ggplot(aes(x=q, y=x)) +
  geom_abline(slope=slope, intercept=int) +
  geom_point(data=pts, aes(x=x, y=y), color="red", shape=3, size=4, stroke=1.5) +
  geom_point() +
  labs(y="quantili reali (x)", x="quantili teorici (q)")
```




La colonna **x** sono le osservazioni ordinate; la ripartizione dei punti, colonna **f**, è corretta con la **formula di Bloom**: $f = (1 - 3/8)/(n + 1 - 3/4)$; la colonna **q** rappresenta i quantili normali standard di **f**.

La diagonale sul grafico passa per i due punti del primo e terzo quartile

9.10 Analisi di normalità: grafico quantile-quantile

```
set.seed(0)
N <- 100
tibble(
  n=rnorm(N, mean=5),
  u=runif(N,2,8)
) %>% ggplot() +
  geom_qq(aes(sample=n, color="normale")) +
  geom_qq_line(aes(sample=n, color="normale")) +
  geom_qq(aes(sample=u, color="uniforme")) +
  geom_qq_line(aes(sample=u, color="uniforme")) +
  labs(color="distribuzione:", y="quantili reali", x="quantili teorici")
```



9.11 Analisi di normalità: test del Chi-Quadro

È un test statistico per verificare l'ipotesi nulla che un dato campione provenga da una data (a scelta!) distribuzione

- Raggruppiamo $\langle x_1, x_2, \dots, x_n \rangle$ in k classi, t.c ogni classe abbia almeno 4-5 elementi. La larghezza di ciascun intervallo può essere diversa

- Sia O_i , $i = 1, 2, \dots, k$ il numero di osservazioni in ogni classe, e E_i il numero di osservazioni attese (*expected*) in ogni classe per la distribuzione ipotizzata
- Le differenze tra O_i e E_i saranno tanti più grandi quanto più varrà H_1 . Quindi si definisce la statistica di test:

$$X_0^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi_{k-p-1}^2$$

dove p è il numero di parametri della distribuzione ipotizzata (2 per la normale)

9.12 Analisi di normalità: test di Shapiro-Wilk

Tra i test di **normalità** è quello con la **potenza** maggiore per un dato livello di significatività


La statistica di test è basata su una **distribuzione anonima** e nota solo numericamente

Per campioni **sufficientemente grandi**, il test è così potente da evidenziare anche piccole deviazioni dalla normalità, dovute ad esempio a anomalie. In questi casi è opportuno accompagnarlo con un grafico Quantile-Quantile per discriminare questi effetti

9.13 Verifica di correlazione

- Il T-test vale per campioni **normali e indipendentemente distribuiti** (*IID*)
- È necessario **verificare questa ipotesi**
- Se riporto in un grafico i valori dei due campioni nell'ordine in cui sono stati acquisiti posso osservare correlazione (s_1 vs. s_3) o mancanza di correlazione (s_1 vs. s_2)
- È evidente che $\rho_{s_1 s_2}$ sarà vicina a 0, mentre $\rho_{s_1 s_3}$ sarà vicina a 1

```
set.seed(0)
N <- 50
df <- tibble(s1 = rnorm(N, 3, 1),
             s2 = rnorm(N, 5, 1),
             s3 = 2 + s1 + rnorm(N, 0, 0.5))
df %>% ggplot(aes(x=s1, y=s2)) +
  geom_point(aes(x=s1, y=s2, color="s2", shape="s2"), size=3) +
  geom_point(aes(x=s1, y=s3, color="s3", shape="s3"), size=3) +
  labs(y="s2, s3", color="campione", shape="campione")
```



Esiste un **test di correlazione di Pearson** che fornisce un p -value associato all'ipotesi alternativa che i due campioni **siano correlati**.

10 Analisi della Varianza

Il Test di Student considera un unico **fattore** con uno o due livelli.

Cosa succede se abbiamo più di due livelli o più di un fattore?

10.1 Fattori

- Un **fattore** è un parametro che determina il risultato di un processo
- È possibile avere fattori **quantitativi** o **qualitativi**
 - Fattori quantitativi assumono livelli rappresentabili da numeri reali
 - Fattori qualitativi assumono livelli non ordinati e non misurabili
- I livelli di un fattore sono chiamati **trattamenti**
- Il valore misurato come uscita del processo è chiamato **resa** (*yield*)

10.2 Esperimenti a un fattore e più livelli


Esempio: resistenza a trazione di un filato in funzione della percentuale di fibre di cotone (fattore quantitativo)

- Ogni trattamento è ripetuto 5 volte
- Il boxplot è utile come orientamento ma per campioni così piccoli l'indicazione delle anomalie non è affidabile

```
df <- expand.grid(Cotton=seq(15,35,5), Run=1:5) %>% tibble()
df$Strength <- c(
  7, 12, 14, 19, 7,
  7, 17, 18, 25, 10,
  15, 12, 18, 22, 11,
  11, 18, 19, 19, 15,
  9, 18, 19, 23, 11
)
df %>%
  select("% Cotone"=Cotton, Run, Strength) %>%
  pivot_wider(names_from = Run, names_prefix="#", values_from = Strength) %>%
  knitr::kable()
```

% Cotone	#1	#2	#3	#4	#5
15	7	7	15	11	9
20	12	17	12	18	18
25	14	18	18	19	19
30	19	25	22	19	23
35	7	10	11	15	11

```
df %>% ggplot(aes(x=factor(Cotton), y=Strength)) +
  geom_boxplot() +
  labs(x="Contenuto in cotone (%)",
       y="Resistenza a trazione (N)", title="Boxplot")
```

10.3 Esperimenti a un fattore e più livelli

La domanda è: i trattamenti producono variazioni di resa **statisticamente significative**?

Ogni singolo valore di resa può essere espresso come (**modello delle medie**):

$$y_{ij} = \mu_i + \varepsilon_{ij}, \quad \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, n \end{cases}$$

dove i sono i trattamenti, j sono le ripetizioni, ε_{ij} sono i **residui**, cioè la componente puramente stocastica e a media nulla della variabile aleatoria y_{ij} , mentre μ_i è la componente deterministica

Possiamo separare $\mu_i = \mu + \tau_i$, dove τ_i è il contributo del trattamento alla media complessiva μ (**modello degli effetti**):

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad \begin{cases} i = 1, 2, \dots, a \\ j = 1, 2, \dots, n \end{cases}$$

10.4 Esperimenti a un fattore e più livelli

- Possiamo sfruttare i modelli precedenti per studiare la **significatività** del fattore
- Usando il **modello delle medie** abbiamo la coppia di ipotesi:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_a \quad (25)$$

$$H_1 : \mu_i \neq \mu_j \text{ per almeno una coppia } (i, j) \quad (26)$$

- Equivalentemente, usando il **modello degli effetti**:

$$H_0 : \tau_1 = \tau_2 = \dots = \tau_a = 0 \quad (27)$$

$$H_1 : \tau_i \neq 0 \text{ per almeno un } i \quad (28)$$

- Per sciogliere l'ipotesi dobbiamo formulare una **statistica di test appropriata**

10.5 Decomposizione della varianza

Definizioni:

- Notazione abbreviata per le somme:

$$y_{i.} = \sum_{j=1}^n y_{ij}, \bar{y}_{i.} = y_{i.}/n, i = 1, 2, \dots, a \quad (29)$$

$$y_{..} = \sum_{i=1}^a \sum_{j=1}^n y_{ij}, \bar{y}_{..} = y_{..}/N, N = na \quad (30)$$

- Introduciamo la **somma quadratica totale corretta**:

$$SS_T = \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = (N-1)V(y_{ij}) \quad (31)$$

10.6 Decomposizione della varianza

Considerando che:

$$SS_T = \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^a \sum_{j=1}^n [(\bar{y}_{i.} - \bar{y}_{..}) + (y_{ij} - \bar{y}_{i.})]^2$$

ovvero:

$$SS_T = n \sum_{i=1}^a (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{i.})^2 + 2 \sum_{i=1}^a \sum_{j=1}^n (\bar{y}_{i.} - \bar{y}_{..})(y_{ij} - \bar{y}_{i.})$$

e siccome $\sum_{j=1}^n (y_{ij} - \bar{y}_{i.}) = y_{i.} - n\bar{y}_{i.} = 0$, ne consegue che la SS_T può essere decomposta come:

$$SS_T = \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = n \sum_{i=1}^a (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{i.})^2 = SS_{tr} + SS_E$$

10.7 Decomposizione della varianza

Abbiamo decomposto la SS_T (che è parente stretta della varianza) nelle **somme quadratiche medie**:

- SS_{tr} , che misura la variabilità tra un trattamento e l'altro
- SS_E , che misura la variabilità all'interno dei trattamenti

Ricordando quanto detto nella definizione della distribuzione χ^2 :

$$\frac{SS}{\sigma^2} = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sigma^2} \sim \chi_{n-1}^2$$

risulta che:

$$\sum_{i=1}^a \sum_{j=1}^n \frac{(y_{ij} - \bar{y}_{..})^2}{\sigma^2} = \frac{SS_T}{\sigma^2} \sim \chi_{N-1}^2, \quad \frac{SS_E}{\sigma^2} \sim \chi_{N-a}^2, \quad \frac{SS_{tr}}{\sigma^2} \sim \chi_{a-1}^2$$

10.8 Decomposizione della varianza

- Il rapporto tra una somma quadratica e il relativo numero di g.d.l. è uguale alla varianza
- Quindi, **se vale H_0** deve essere $E(SS_{tr}/(a-1)) = E(SS_E/(N-a))$, dato che si tratta del valore atteso di diversi campioni tratti dallo stesso gruppo di osservazioni, tutte provenienti dalla stessa popolazione (H_0 significa che i trattamenti **non sono significativi**)
- Ma allora possiamo scrivere:

$$F_0 = \frac{SS_{tr}/(a-1)}{SS_E/(N-a)} = \frac{MS_{tr}}{MS_E} \sim F_{a-1, N-a}$$

Dove MS sono dette **somme quadratiche medie**

Sulla base dell'ultima equazione possiamo calcolare il p -value associato all'ipotesi H_1 : per valori piccoli possiamo affermare che **almeno un trattamento ha effetto statisticamente significativo**

10.9 Teorema di Cochran

La definizione di F_0 presuppone che MS_{tr} e MS_E **siano indipendenti**. Dato che sono il risultato della decomposizione di SS_T in $SS_{tr} + SS_E$, ciò non è scontato. Vale però il **teorema**:

Teorema

Siano $Z_i \sim \mathcal{N}(0, 1)$, $i = 1, 2, \dots, \nu$ **campioni indipendenti**, con $\sum_{i=1}^{\nu} Z_i^2 = Q_1 + Q_2 + \dots + Q_s$ dove $s \leq \nu$ e Q_i ha ν_i gradi di libertà ($i = 1, 2, \dots, s$).

Allora, $Q_1, Q_2, \dots, Q_s$ sono **variabili casuali indipendenti** distribuite come χ^2 con $\nu_1, \nu_2, \dots, \nu_s$ gradi di libertà, se e soltanto se

$$\nu = \nu_1 + \nu_2 + \dots + \nu_s$$

Siccome $(N - a) + (a - 1) = (N - 1)$, consegue che SS_{tr}/σ^2 e SS_E/σ^2 sono variabili casuali indipendenti distribuite come χ^2_{a-1} e χ^2_{N-a} , rispettivamente.

10.10 ANOVA (*ANalysis Of VAriance*)

Tornando all'esempio della resistenza dei filati misti, possiamo applicare la decomposizione della varianza ottenendo:

```
df <- df %>% mutate(Cotton=factor(Cotton))
df.lm <- lm(Strength~Cotton, data=df)
knitr::kable(anova(df.lm))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Cotton	4	475.76	118.94	14.75682	9.1e-06
Residuals	20	161.20	8.06	NA	NA

La tabella soprastante è detta **tabella ANOVA**

Il p -value molto basso ci consente di rifiutare l'ipotesi nulla e affermare che **almeno un trattamento ha effetti statisticamente significativi**

Non sappiamo comunque quanti e quali trattamenti siano significativi. Per studiare questo aspetto si utilizza il **Test di Tukey**

Demo interattiva

Su <https://pbosetti-anova-live.share.connect.posit.cloud> è possibile interagire con un'applicazione che consente di simulare esperimenti a un fattore e più livelli, e di calcolare la tabella ANOVA.

10.11 Test di Tukey

Il test valuta **contemporaneamente** tutte le seguenti coppie di ipotesi:

$$\left. \begin{array}{l} H_0 : \mu_i = \mu_j \\ H_1 : \mu_i \neq \mu_j \end{array} \right\} \forall i \neq j$$

Per ogni coppia (i, j) , $i \neq j$ si ha la statistica di test:

$$q_{0,ij} = \frac{|\bar{y}_{i.} - \bar{y}_{j.}|}{S_{p,ij} \sqrt{2/n}} \sim Q_{a,k}$$

dove n è la dimensione dei campioni, uguale per tutti, a è il numero di trattamenti e k è il numero di gradi di libertà di MS_E , cioè $N - a = an - a$.

Per ogni coppia si calcola quindi il p -value dalla CDF della **distribuzione dell'intervallo studentizzato** Q e si calcola l'intervallo di confidenza:

$$\bar{y}_{i.} - \bar{y}_{j.} - q_{\alpha,a,N-a} \frac{S_{p,ij}}{\sqrt{n}} \leq \mu_i - \mu_j \leq \bar{y}_{i.} - \bar{y}_{j.} + q_{\alpha,a,N-a} \frac{S_{p,ij}}{\sqrt{n}}$$

10.12 Test di Tukey

Generalmente, il risultato viene riportato in un grafico come a fianco

Le coppie per cui l'intervallo di confidenza è a cavallo di 0 non hanno differenze significative, e viceversa

Nota: compiere altrettanti test di Student separati aumenterebbe la probabilità d'errore complessivo, che risulterebbe dalla combinazione delle probabilità d'errore dei singoli test


```
GGTukey<-function(Tukey){
  A<-require("tidyverse")
  if(A==TRUE){
    library(tidyverse)
  } else {
    install.packages("tidyverse")
  }
}
```

```

library(tidyverse)
}
B<-as.data.frame(Tukey[1])
colnames(B)[1:3]<-c("diff", "min", "max")
B$id <- row.names(B)

D <- B %>% ggplot(aes(x=id)) +
  geom_point(aes(y=diff)) +
  geom_errorbar(aes(ymin=min, ymax=max), width=0.2) +
  geom_hline(yintercept=0, color="red") +
  coord_flip()
return(D)
}
tk <- TukeyHSD(aov(Strength~Cotton, data=df))
GGTukey(tk) +
  labs(y="Differenza tra le medie", x="Coppia di trattamenti", title="Tukey plot, intervallo

```



i Note

Cosa succede agli intervalli di confidenza passando da un intervallo al 95% ad un intervallo al 99%?

11 Qualche domanda

11.1 Test di Tukey

Se riduco α da 0.05 a 0.01, cosa succede agli intervalli di confidenza del test di Tukey?

- Si allargano tutti della stessa quantità
- Si allargano tutti, ma in misura diversa
- Si restringono tutti della stessa quantità
- Si restringono tutti, ma in misura diversa
- Rimangono invariati

11.2 ANOVA

Nell'[esperimento sopra riportato](#), una tabella ANOVA come la seguente è corretta oppure no?

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Cotton	1	33.62	33.62000	1.281632	0.269261
Residuals	23	603.34	26.23217	NA	NA

- Sì
- No, la colonna Df è sospetta
- No, la colonna Sum Sq è sospetta
- No, la colonna Mean Sq è sospetta
- No, la colonna F value è sospetta
- No, la colonna Pr(>F) è sospetta

12 La spiegazione frequentista

L'approccio *frequentista* è quello che definisce e studia la probabilità *a posteriori* cioè contando il numero di eventi relativamente al numero totale di osservazioni

12.1 Il significato del p -value

```
library(glue)
set.seed(5)
mu0 = 10.3
N <- 1000
```


```
pop <- rnorm(N*10, mean=mu0, sd=2.7)
alpha <- 0.05
n1 <- 15
```

Il significato del p -value è illustrato con un esempio: si consideri un esperimento in cui si effettuano 1000 test di Student su altrettanti campioni di $n = 15$ elementi, ciascuno con un livello di significatività α del 5%

Supponiamo che si tratti di test ad un campione, con ipotesi nulla $\mu = \mu_0$ e ipotesi alternativa $\mu \neq \mu_0$, e supponiamo che tutti i campioni siano prelevati dalla stessa popolazione con valore atteso μ_0

Allora il valore atteso delle predizioni errate (cioè quelle in cui vale H_1) è 5%

```
tibble(
  i = 1:N,
  p = map_dbl(1:N, ~t.test(sample(pop, n1), mu=mu0, conf.level=1-alpha)$p.value),
  hyp = ifelse(p<0.05, "H1", "H0")
) %>%
  {ggplot(data = .) +
    geom_point(aes(x=i, y=p, color=hyp, shape=hyp)) +
    geom_hline(yintercept=alpha, color="red") +
    scale_color_manual(values=c("H0"="darkgreen", "H1"="red"), name="Ipotesi") +
    scale_shape_manual(values=c("H0"=19, "H1"=17), name="Ipotesi") +
    geom_label(x=0, y=alpha, label=glue("{alpha*100}%")) +
    labs(
      title=glue("p-value di {N} T-test ({length(.$hyp[.$hyp == 'H1'])/N*100}% errori di tipo I"),
      x="# Test",
      y="p-value")}
```

Note

Nota 1: Lo stesso approccio **frequentista** è applicabile a qualsiasi altro test statistico di cui si calcoli il p -value

Nota 2: Vedi la versione interattiva qui: <https://p4010.shinyapps.io/frequentista/>

12.2 E se cambiamo n ?


```
set.seed(5)
mu0 = 10.3
n2 <- 50
```

Se aumentiamo la dimensione dei campioni da 15 a 50, la probabilità di errore di tipo I rimane sempre la stessa, a pari condizioni

Com'è possibile?

Aumentando la dimensione del campione aumenta la **potenza** del test, cioè la sua capacità di discriminare anche piccoli differenze. Ma per un certo test, per una certa differenza, il p -value non dipende dalla dimensione del campione, perché è proprio calcolato *compensando* l'effetto della dimensione del campione

```
tibble(
  i = 1:N,
  p = map_dbl(1:N, ~t.test(sample(pop, n2), mu=mu0, conf.level=1-alpha)$p.value),
  hyp = ifelse(p<0.05, "H1", "H0")
) %>%
  {ggplot(data = .) +
    geom_point(aes(x=i, y=p, color=hyp, shape=hyp)) +
    geom_hline(yintercept=alpha, color="red") +
    scale_color_manual(values=c("H0"="darkgreen", "H1"="red"), name="Ipotesi") +
    scale_shape_manual(values=c("H0"=19, "H1"=17), name="Ipotesi") +
    geom_label(x=0, y=alpha, label=glue("{alpha*100}%")) +
    labs(
      title=glue("p-value di {N} T-test ({length(.$hyp[.$hyp == 'H1'])}/N*100}% errori di tipo I)",
      x="# Test",
      y="p-value")}
```



12.3 E per la potenza?

Consideriamo i test in cui l'ipotesi nulla sia

$$H_0 : \mu = \mu_0 + \sigma \quad (32)$$

$$H_1 : \mu \neq \mu_0 + \sigma \quad (33)$$

cioè una differenza di un σ dal valore atteso della popolazione


Allora in gran parte dei casi avremo un p -value piccolo, che ci spinge a rigettare H_0 (*Caso A*)

Se però passiamo da campioni da 15 elementi a campioni da 30 elementi (*Caso B*) la **potenza** del test aumenta sensibilmente, a pari condizioni

12.3.1 Caso A

```
library(glue)
set.seed(5)
mu0 = 10.3
sd = 2.7
N <- 1000
pop <- rnorm(N*10, mean=mu0, sd=sd)
alpha <- 0.05
n3 <- 15

tibble(
  i = 1:N,
  p = map_dbl(1:N, ~t.test(sample(pop, n3), mu=mu0+1*sd, conf.level=1-alpha)$p.value),
  hyp = ifelse(p<0.05, "H1", "H0")
) %>%
  {ggplot(data = .) +
    geom_point(aes(x=i, y=p, color=hyp, shape=hyp)) +
    geom_hline(yintercept=alpha, color="red") +
    scale_color_manual(values=c("H0"="darkgreen", "H1"="red"), name="Ipotesi") +
    scale_shape_manual(values=c("H0"=19, "H1"=17), name="Ipotesi") +
    geom_label(x=0, y=alpha, label=glue("{alpha*100}%")) +
    ylim(0,0.5) +
    labs(
      title=glue("p-value di {N} T-test, campioni da {n3} elementi"),
      x="# Test",
      y="p-value")}
```



12.3.2 Caso B

```
n3 <- 30
tibble(
  i = 1:N,
  p = map_dbl(1:N, ~t.test(sample(pop, n3), mu=mu0+1*sd, conf.level=1-alpha)$p.value),
  hyp = ifelse(p<0.05, "H1", "H0")
) %>%
  {ggplot(data = .) +
    geom_point(aes(x=i, y=p, color=hyp, shape=hyp)) +
    geom_hline(yintercept=alpha, color="red") +
    scale_color_manual(values=c("H0"="darkgreen", "H1"="red"), name="Ipotesi") +
    scale_shape_manual(values=c("H0"=19, "H1"=17), name="Ipotesi") +
    geom_label(x=0, y=alpha, label=glue("{alpha*100}%")) +
    ylim(0,0.5) +
    labs(
      title=glue("p-value di {N} T-test, campioni da {n3} elementi"),
      x="# Test",
      y="p-value")}
```

