

Regressione

Analisi Dati e Statistica, 2026–27



Paolo Bosetti

Ultimo aggiornamento: 12/09/2026

Indice

1	Regressione	2
1.1	Basi	2
1.2	Tipi di regressione	3
2	Regressione Lineare	3
2.1	Basi	3
2.2	Basi	4
2.3	Esempio	4
3	Regressione ai Minimi Quadrati	6
3.1	Regressione ai Minimi Quadrati	6
4	Qualità della regressione	6
4.1	Coefficiente di Determinazione	7
4.2	Sotto-adattamento	9
4.3	Sovra-adattamento	11
4.4	Bande di Predizione	12
4.5	Bande di Confidenza	13
5	Regressione Lineare Generalizzata	14
5.1	Basi	15
5.2	Basi	15
5.3	Regressione Logistica	16
5.4	Regressione Logistica	19

6	Presentazione dei dati	20
6.1	Confronto grafico di serie	20
6.2	Senza un modello di riferimento	22
6.3	Con un modello	23

1 Regressione

Ogni **modello** di un sistema o processo fisico dipende da **parametri**. Questi parametri devono essere calcolati **adattando** il modello alle osservazioni sperimentali (misure)

L'operazione di adattamento (*fit*) di un modello è effettuata mediante **regressione**

1.1 Basi

- Un modello di un sistema fisico può essere espresso come:

$$y = f(x_1, x_2, \dots, x_n, c_1, c_2, \dots, c_m)$$

dove x_i sono le variabili (aleatorie) fisiche, dette **regressori** o **predittori**, mentre le c_i sono i **parametri** (costanti) del modello

- Se $n = 1$ c'è un unico predittore e il modello si dice **semplice**
- Ad esempio, $y = a + bx + cx^2$ è un modello semplice con parametri a, b, c
- **regredire il modello** significa effettuare delle misurazioni di y per diversi valori di x e determinare i valori dei parametri a, b, c che **minimizzano la distanza** tra il modello e le osservazioni sperimentali

1.2 Tipi di regressione

Prenderemo in considerazione tre tipi di regressione:

- Regressione lineare: il modello è una **combinazione lineare dei parametri**
- Regressione lineare generalizzata
- Regressione ai minimi quadrati: i parametri sono combinati in modo non lineare

2 Regressione Lineare

Valida per ogni modello **lineare nei parametri** (mentre i predittori possono comparire con grado diverso da 1)

2.1 Basi

Definizioni

Si definisce il **modello statistico** del processo da regredire come segue:

$$y_i = f(x_{1i}, x_{2i}, \dots, x_{ni}, c_1, c_2, \dots, c_{n+1}) + \varepsilon_i = \hat{y}_i + \varepsilon_i, \quad i = 1, 2, \dots, N$$

dove i è l'indice di osservazione ($N \geq n + 1$ in totale), $\hat{y}_i$ è il **valore regredito**, o **predizione**, in corrispondenza dell'osservazione i , e ε_i sono i **residui**

- Il valore regredito corrisponde alla **componente deterministica**
- Il residuo è la **componente aleatoria**
- Si assume l'ipotesi di **normalità dei residui**, cioè che $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$

Se la $f(\cdot)$ è una funzione analitica e lineare nei coefficienti, allora possiamo esprimerla come $\mathbf{A}\mathbf{k} = \mathbf{y}$, dove

- $\mathbf{y}$ è il vettore delle y_i , $i = 1 \dots N$
- $\mathbf{k}$ è il vettore dei parametri c_j , $j = 1 \dots n + 1$
- $\mathbf{A}$ una matrice $N \times (n + 1)$ così composta:

$$\mathbf{A} = \begin{bmatrix} x_1^{n-1} & x_1^{n-2} & \dots & x_1 & 1 \\ x_2^{n-1} & x_2^{n-2} & \dots & x_2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_N^{n-1} & x_N^{n-2} & \dots & x_N & 1 \end{bmatrix}$$

2.2 Basi

L'equazione lineare può essere risolta con il metodo della **pseudo-inversa**:

$$\mathbf{A}^T \mathbf{A} \cdot \mathbf{k} = \mathbf{A}^T \cdot \mathbf{y} \quad (1)$$

$$(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{A} \cdot \mathbf{k} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \cdot \mathbf{y} \quad (2)$$

$$\mathbf{k} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \cdot \mathbf{y} \quad (3)$$

Questa relazione rende evidente cosa si intende per **regressione lineare**: non ha nulla a che fare con il **grado della funzione regredita**, ma solo con l'equazione lineare nei parametri che rappresenta il modello

NOTE:

- dalla equazione matriciale precedente è evidente che la regressione può essere eseguita se e solo se $N \geq n + 1$, cioè se il numero di osservazioni è almeno pari al numero di parametri
- anche nel caso di una $f(\cdot)$ con più predittori, se essa è lineare nei coefficienti è sempre possibile esprimerla come $\mathbf{A}\mathbf{k} = \mathbf{y}$ e quindi risolverla con il metodo della pseudo-inversa


2.3 Esempio

Sia il modello da regredire del tipo $y_i = (ax_i + b) + \varepsilon_i$; allora può essere rappresentato come:

$$\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{bmatrix} \cdot \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

```
library(modelr)
set.seed(1)
df <- tibble(x=1:10, y=3+2*x+rnorm(length(x), sd=3))
df.lm <- lm(y~x, data=df)
df <- add_predictions(df, df.lm)
df <- add_residuals(df, df.lm)
ggplot(df, aes(x=x, y=y)) +
  geom_line(aes(y=pred), color="red") +
  geom_linerange(aes(ymin=pred, ymax=pred+resid), color="blue", size=1) +
  geom_point(size=2)
```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
i Please use `linewidth` instead.



La figura mostra le osservazioni come punti di coordinate (x_i, y_i) , il modello regredito come una **retta rossa** (modello lineare nei coefficienti a , b e di primo grado del predittore x) e i residui ε_i come segmenti blu che rappresentano la differenza tra le y_i e il corrispondente valore regredito $\hat{y}_i$

3 Regressione ai Minimi Quadrati

Se il modello non è lineare nei parametri, è comunque possibile effettuare la regressione con il metodo dei **minimi quadrati**

3.1 Regressione ai Minimi Quadrati

Si cerca cioè l'insieme di valori dei parametri che **minimizza la distanza** tra il modello e le osservazioni. Questa minimizzazione può essere realizzata definendo un **indice di merito** che rappresenta la distanza tra modello e osservazioni **in funzione dei parametri**:

$$\Phi(c_1, c_2, \dots, c_m) = \sum_{i=1}^N (y_i - f(x_{1i}, x_{2i}, \dots, x_{ni}, c_1, c_2, \dots, c_m))^2$$

- Se la $f(\cdot)$ è analitica e differenziabile, allora possiamo **minimizzare** $\Phi(\cdot)$ per derivazione, cioè risolvendo il sistema di m equazioni

$$\frac{\partial \Phi}{\partial c_i}(c_1, c_2, \dots, c_m) = 0$$

- Se la $f(\cdot)$ **non è differenziabile**, il minimo di $\Phi(\cdot)$ può comunque essere calcolato per via numerica (ad es. metodo di Newton-Raphson)

4 Qualità della regressione

Ad un dato insieme di osservazioni è possibile adattare **un numero infinito di modelli**

È possibile definire alcuni **parametri di merito** e alcuni **metodi di verifica** che consentono di valutare la qualità di una regressione e, quindi, individuare il modello che meglio si adatta alle osservazioni


4.1 Coefficiente di Determinazione

- Il coefficiente di merito più utilizzato per valutare una regressione è il **coefficiente di determinazione** R^2
- È definito come $R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$, dove $SS_{\text{res}} = \sum \varepsilon_i^2$ e $SS_{\text{tot}} = \sum (y_i - \bar{y})^2$
- Se i valori regrediti corrispondono ai valori osservati $y_i = \hat{y}_i$, allora i residui sono tutti nulli e vale $R^2 = 1$
- La qualità della regressione diminuisce al diminuire di R^2

4.1.1 Due set di dati


```
set.seed(0)
N <- 20
df <- tibble(
  x=runif(N, 0, 10),
  y1=5*x+12 + rnorm(N,sd=4.45),
  y2=0.5*x^2 + 1*x + 3 + rnorm(N,sd=1)
)
lm1 <- lm(y1~x, data=df)
df <- add_predictions(df, lm1, var="y1_hat")
lm2 <- lm(y2~x, data=df)
df <- add_predictions(df, lm2, var="y2_hat")
lm3 <- lm(y2~poly(x, degree=2, raw=T), data=df)
df <- add_predictions(df, lm3, var="y3_hat")
r <- c(summary(lm1)$r.squared, summary(lm2)$r.squared, summary(lm3)$r.squared)

df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y1, color="primo set")) +
  geom_line(aes(y=y1_hat, color="primo set")) +
  geom_point(aes(y=y2, color="secondo set")) +
  geom_line(aes(y=y2_hat, color="secondo set")) +
  labs(color="dati:", title=TeX(glue("$R^2_1={r[1]}$", "$R^2_2={r[2]}$")), x="predittore", y="osservato")
theme(legend.position = "bottom")
```



4.1.2 Stesso set, due modelli

```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y2)) +
  geom_line(aes(y=y2_hat, color="primo grado")) +
  geom_line(aes(y=y3_hat, color="secondo grado")) +
  labs(color="modello:", title=TeX(glue("$R^2_1={r[2]}$", "$R^2_2={r[3]}$")), x="predittore", y=
  theme(legend.position = "bottom")
```



Nota: come si osserva, non è necessario che i valori dei regressori siano equispaziati!

4.2 Sotto-adattamento

Si ha **sotto-adattamento** (o *under-fitting*) quando il modello ha un grado inferiore all'apparente comportamento delle osservazioni


Può essere evidenziato, oltre che da un R^2 basso, studiando la distribuzione dei residui: se c'è sotto-adattamento i residui possono essere non-normali e, soprattutto, mostrare degli **andamenti**, o *pattern*

Un *pattern* è un andamento regolare dei residui in funzione dei regressori


Dal numero di massimi e minimi presenti nell'eventuale *pattern* è possibile stimare **quanti gradi mancano**

4.2.1 Sotto-adattamento

```
df %>% ggplot(aes(x=x)) +  
  geom_point(aes(y=y2)) +  
  geom_line(aes(y=y2_hat)) +  
  labs(x="predittore", y="osservazioni", title="modello di primo grado")
```




```
df %>% ggplot(aes(x=x)) +  
  geom_point(aes(y=lm2$residuals)) +  
  labs(x="predittore", y="residui")
```




4.2.2 Adattamento corretto

```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y2)) +
  geom_line(aes(y=y3_hat)) +
  labs(x="predittore", y="osservazioni", title="modello di secondo grado")
```



```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=lm3$residuals)) +
  labs(x="predittore", y="residui")
```



4.3 Sovra-adattamento


Se il grado del modello è eccessivo, il modello tende a **inseguire i singoli punti**

Il valore di R^2 cresce, raggiungendo 1 quando il grado è uguale al numero di osservazioni meno 1

Tuttavia il modello **perde di generalità** e non riesce più a predire correttamente **nuovi valori** acquisiti in un secondo momento (le crocette rosse in figura)

Il sovra-adattamento ha effetti particolarmente drammatici in caso di **estrapolazione**, cioè quando si valuta il modello al di fuori dell'intervallo in cui è stato regredito

```
set.seed(0)
N <- 8
df <- tibble(
  x=1:N,
  y=3*x+4 + rnorm(N, sd=2),
  y2=3*x+4 + rnorm(N, sd=2)
)
dfp <- tibble(x=seq(-1, N+2, length.out=101))
lm1 <- lm(y~x, data=df)
dfp <- add_predictions(dfp, lm1, var="pred.lm1")
lm2 <- lm(y~poly(x, deg=6, raw=T), data=df)
dfp <- add_predictions(dfp, lm2, var="pred.lm2")
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y)) +
  geom_point(aes(y=y2, color="red", shape=3)) +
  geom_line(aes(x=x, y=pred.lm1, color="grado 1"), data=dfp) +
  geom_line(aes(x=x, y=pred.lm2, color="grado 6"), data=dfp) +
  coord_cartesian(ylim=c(5,27), xlim=c(0,9)) +
  labs(color="modello:", x="predittore", y="osservazioni") +
  theme(legend.position = "bottom")
```



4.4 Bande di Predizione


È una banda **simmetrica rispetto alla regressione** all'interno della quale le osservazioni (presenti e future) hanno una probabilità assegnata di ricadere

In generale, per un numero di osservazioni sufficientemente grande (> 50) la banda di predizione al 95% contiene il 95% delle osservazioni

Il metodo più robusto per identificare il sovra-adattamento è detto ***K-fold cross-validation***, vedi anche <https://paolobosetti.quarto.pub/kfold.html>

```
set.seed(1)
f <- function(x, offset) 0.3*(x-offset)^2+1*(x-offset)
N <- 20
offset <- 5
df <- tibble(
  x=seq(0, 10, length.out=N),
  y= f(x, offset) + rnorm(N, sd=1)
)
dfp <- tibble(
  x=seq(0, 10, length.out=N*10),
  y=f(x, offset) + rnorm(N, sd=1)
)
lm <- lm(y~poly(x, deg=2, raw=T), data=df)
dfp <- cbind(dfp, predict(lm, dfp, interval="prediction"), level=0.95)
```

```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y)) +
  geom_line(aes(x=x, y=fit), data=dfp, color="blue", linewidth=1) +
  geom_line(aes(x=x, y=upr), data=dfp, color="red", linetype=2) +
  geom_line(aes(x=x, y=lwr), data=dfp, color="red", linetype=2) +
  geom_point(aes(x=x, y=y), data=dfp, color=gray(2/3), shape=3) +
  coord_cartesian(ylim=c(-4,15)) +
  labs(x="predittore", y="osservazioni", title="Banda di predizione al 95%")
```




4.5 Bande di Confidenza

È una banda simmetrica rispetto alla regressione all'interno della quale **il valore atteso del modello** ha una probabilità assegnata di ricadere

È sempre più stretta rispetto alla banda di predizione

È l'equivalente multi-dimensionale dell'intervallo di confidenza per un T-test: come questo è l'intervallo all'interno del quale ha una assegnata probabilità di rientrare il valore corrispondente all'ipotesi nulla, qui possiamo assumere che il modello “*vero*” rientri con una certa probabilità nella banda di confidenza

```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y)) +
  geom_line(aes(x=x, y=fit), data=dfp) +
  geom_smooth(aes(y=y), method="lm", formula=lm$call$formula, level=0.95) +
  coord_cartesian(ylim=c(-4,15)) +
  labs(x="predittore", y="osservazioni", title="Banda di confidenza al 95%")
```



È ottenuto calcolando gli intervalli di confidenza sui parametri della regressione, calcolando poi—per ogni valore del predittore—il valore massimo e minimo della regressione corrispondente ai valori estremi dei parametri nei loro intervalli di confidenza

5 Regressione Lineare Generalizzata

La regressione lineare classica assume l'ipotesi di **normalità dei residui**

Quando quest'ipotesi non è vera, ma il **modello è comunque lineare nei parametri**, si può utilizzare la regressione lineare generalizzata

5.1 Basi

Nel caso della regressione lineare:

$$y_i = f(\mathbf{x}_i, \mathbf{k}) + \varepsilon_i = \hat{y}_i + \varepsilon_i \quad (4)$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2) \quad (5)$$

Nel caso della **regressione lineare generalizzata**:

$$y_i = \hat{y}_i + \varepsilon_i \quad (6)$$

$$\varepsilon_i \sim D(p_1, p_2, \dots, p_k) \quad (7)$$

dove D è una generica distribuzione a k parametri facente parte della **famiglia delle distribuzioni esponenziali** (normale, binomiale, gamma, normale inversa, Poisson, quasinormale, quasibinomiale e quasipoissoniana)

Il problema può essere risolto con l'introduzione di una **funzione di collegamento** che riscalda i residui proiettandoli su una distribuzione normale

5.2 Basi

La **funzione di collegamento** (*link function*) $g(\cdot)$ è tale per cui:

$$y_i = \hat{y}_i + g(\varepsilon_i) \quad (8)$$


$$\varepsilon_i \sim D(p_1, p_2, \dots, p_k); \quad g(\varepsilon_i) \sim \mathcal{N}(0, \sigma^2) \quad (9)$$

Le funzioni di collegamento per le distribuzioni più comuni sono:

Distribuzione	Funzione di collegamento
Normale	$g(x) = x$
Binomiale	$g(x) = \text{logit}(x)$
Poisson	$g(x) = \log(x)$
Gamma	$g(x) = 1/x$

In particolare, vale: $\text{logit}(x) = \frac{1}{1+e^{-p(x-x_0)}}$

```
logit <- function(x, p=1, x0=0) 1/(1+exp(-p*(x-x0)))
tibble(x=seq(-6, 6, 0.1), y1=logit(x, 1, 1), y2=logit(x, -4, 1)) %>%
  ggplot(aes(x=x)) +
  geom_hline(yintercept=c(0, 0.5, 1), lty=2) +
  geom_vline(xintercept=1, lty=2) +
  geom_line(aes(y=y1, color="p=1")) +
  geom_line(aes(y=y2, color="p=-4")) +
  labs(y="logit(x, x0=2, p=1)", color="pendenza:") +
  theme(legend.position = "bottom")
```



5.3 Regressione Logistica

Il caso tipico di regressione logistica è il classificatore di **eventi binomiali**

consideriamo un processo che, in funzione di uno o più predittori, possa fornire un risultato che può valere solo una di due alternative (successo|fallimento, rotto|integro, vero|falso, 1|0). Vogliamo **identificare la soglia dei predittori** che commuta il risultato


Una regressione lineare non è adatta alla situazione: è evidente che i **residui non sono normali** e che la pendenza della regressione dipende molto da quanti punti sono raccolti nelle zone “sicure”

5.3.1 Dati

```
library(PearsonDS)
set.seed(0)
N <- 50
N2 <- 0
v0 <- c(90, 102)
sd <- 5
m1 <- list(m=90, variance=5, skewness=1.1, kurtosis=4)
m2 <- list(m=99, variance=5, skewness=-1.1, kurtosis=4)
df <- tibble(
  OK=c(rep(c(T, F), N), rep(T, N2))
) %>%
  arrange(OK) %>%
  mutate(OKv = as.numeric(OK), val=c(
    rpearson(N, moments=m1), rpearson(N, moments=m2), runif(N2, 100, 120)))


df.lm <- lm(OKv~val, data=df)
df <- add_predictions(df, df.lm, var="pred.lm")
df <- add_residuals(df, df.lm, var="res.lm")

df %>% ggplot(aes(x=val,y=OKv)) +
  geom_point(aes(color=OK)) +
  geom_line(aes(y=pred.lm), color="blue") +
  coord_cartesian(ylim=c(0,1)) +
  labs(x="valore", y="successo", color="successo:") +
  theme(legend.position = "bottom")
```




5.3.2 Residui modello lineare

```
df %>% ggplot(aes(x=val, y=res.lm)) +  
  geom_point() +  
  labs(x="valore", y="residui", title="Residui")
```



```
df %>% ggplot(aes(sample=res.lm)) +  
  geom_qq() +  
  geom_qq_line() +  
  labs(x="quantili teorici", y="quantili campionari", title="Grafico Q-Q")
```



5.4 Regressione Logistica


La funzione logistica regredita fornisce il parametro x_0 che identifica il valore che separa una **uguale quantità di falsi positivi e falsi negativi**

Inoltre, è possibile individuare la soglia opportuna per ottenere una prefissata probabilità di falsi positivi (o falsi negativi)

Questo è il tipo più semplice di **machine learning**: un classificatore binomiale

```
df.glm <- glm(OKv~val, family=binomial(), data=df)
df <- add_predictions(df, df.glm, var="pred.glm", type="response")
df <- add_residuals(df, df.glm, var="res.glm")

df %>% ggplot(aes(x=val, y=OKv)) +
  geom_point(aes(color=OK)) +
  geom_line(aes(x=val, y=pred.glm), color="blue") +
  geom_line(aes(y=pred.lm), color=gray(2/3), linetype=2) +
  coord_cartesian(ylim=c(0,1)) +
  labs(x="valore", y="successo", color="successo:") +
  theme(legend.position = "bottom")
```



6 Presentazione dei dati

Il concetto di **banda di confidenza** è essenziale nella presentazione grafica di dati provenienti da più serie

6.1 Confronto grafico di serie

```
set.seed(0)
r <- 8
alpha <- 0.05
df.n <- tibble(
  x=seq(100, 900, 100),
  S1=c(300, 310, 318, 330, 290, 305, 358, 290, 180),
  S2=c(315, 315, 322, 340, 272, 315, 340, 285, 185),
  n=c(10, 10, 25, 10, 10, 7, 20, 10, 10)
) %>% mutate(S2=S2-15)

df <- expand.grid(
  r=1:r,
  x=df.n$x
) %>% mutate(
  S1=map_dbl(x, ~df.n[df.n$x==.,]$S1),
  S2=map_dbl(x, ~df.n[df.n$x==.,]$S2)
```

```

) %>%
tibble() %>%
pivot_longer(S1:S2, names_to="s", values_to="nominal", cols_vary = "slowest")

df <- df %>%
  group_by(s, x) %>%
  group_modify(~ {.x$noise=rnorm(8, sd=df.n[df.n$x==.y$x,]$n); .x}) %>%
  mutate(value=nominal+noise)

df.s <- df %>% group_by(s, x) %>% summarise(
  n=n(),
  ci=sd(value)/sqrt(n) * qt(alpha/2, n - 1, lower.tail = F),
  value=mean(value),
  lwr=value-ci,
  upr=value+ci
)

```

`summarise()` has regrouped the output.

- i Summaries were computed grouped by *s* and *x*.
- i Output is grouped by *s*.
- i Use ``summarise(groups = "drop_last")`` to silence this message.
- i Use ``summarise(.by = c(s, x))`` for per-operation grouping (``?dplyr::dplyr_by``) instead.

Supponiamo di avere un processo il cui valore dipende da una variabile *x*

Supponiamo che un parametro *S* di processo possa influire sul valore in uscita. Ad esempio:


- il valore è la durezza di un metallo, *x* è la temperatura, il parametro *S* è la quantità di un elemento in lega
- il valore è la produttività di un impianto, *x* è un parametro quantitativo di processo, il parametro *S* è il tipo di macchina utilizzato

```

df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=value, group=s, color=s, shape=s)) +
  labs(color="Serie:", shape="Serie:", y="valore", title="Dati grezzi") +

```

```
coord_cartesian(xlim=c(50,950), ylim=c(150,400)) +
scale_x_continuous(breaks=df.n$x) +
theme(legend.position = "bottom")
```



Supponiamo di ripetere 8 volte una misurazione del valore in uscita per le varie combinazioni di x e di S , ottenendo i risultati in figura: **quali differenze sono significative?**

6.2 Senza un modello di riferimento


Senza un modello di riferimento che esprima $v = f(x, S)$ **non ha senso effettuare una regressione**

Tuttavia posso riportare, per ogni **trattamento**

- il valor medio, unendo le serie con una spezzata al solo scopo di raggruppare visivamente i dati
- i limiti dell'intervallo di confidenza per ogni serie e per ogni trattamento
- oppure, unire i limiti con una banda che rappresenta la **confidenza sulla media**

```
df.s %>% ggplot(aes(x=x)) +
  geom_ribbon(aes(ymin=lwr, ymax=upr, group=s), alpha=1/6) +
  geom_line(aes(y=value, group=s, color=s), linewidth=0.5) +
  geom_point(aes(x=x, y=value, group=s, color=s, shape=s), data=df) +
```

```
labs(color="Serie:", shape="Serie:", y="valore", title="Confidenza al 95%") +
geom_errorbar(aes(ymin=lwr, ymax=upr, group=s, color=s), alpha=2/3, position="dodge", width=1) +
coord_cartesian(xlim=c(50,950), ylim=c(150,400)) +
scale_x_continuous(breaks=df.n$x) +
scale_shape_manual(values=c(1, 2)) +
theme(legend.position = "bottom")
```



Zone in cui le bande sono sovrapposte sono statisticamente indistinguibili

6.3 Con un modello

Solo se ho un modello $v = f(x, S)$ posso effettuare una regressione

Anche in questo caso, la regressione va accompagnata con bande di confidenza

Di nuovo, **zone in cui le bande sono sovrapposte sono statisticamente indistinguibili**

```
df %>% ggplot(aes(x=x)) +
  geom_smooth(aes(y=value, group=s, color=s)) +
  geom_point(aes(y=value, group=s, color=s, shape=s)) +
  labs(color="Serie:", shape="Serie:", y="valore", title="Confidenza al 95%") +
  coord_cartesian(xlim=c(50,950), ylim=c(150,400)) +
```

```
scale_x_continuous(breaks=df.n$x) +  
theme(legend.position = "bottom")
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~
x'

