

Regressione

Analisi Dati e Statistica, 2025–26



Paolo Bosetti

Università di Trento, Dipartimento di Ingegneria Industriale

Ultimo aggiornamento: 17/06/2026

Indice

1	Regressione	1
1.1	Basi	2
1.2	Tipi di regressione	2
2	Regressione Lineare	2
2.1	Basi	2
2.2	Basi	3
2.3	Esempio	4
3	Regressione ai Minimi Quadrati	5
3.1	Regressione ai Minimi Quadrati	5
4	Qualità della regressione	5
4.1	Coefficiente di Determinazione	5
4.2	Sotto-adattamento	7
4.3	Sovra-adattamento	9
4.4	Bande di Predizione	10
4.5	Bande di Confidenza	12
5	Regressione Lineare Generalizzata	13
5.1	Basi	13
5.2	Basi	14
5.3	Regressione Logistica	15
5.4	Regressione Logistica	17
6	Presentazione dei dati	18
6.1	Confronto grafico di serie	18
6.2	Senza un modello di riferimento	20
6.3	Con un modello	21

1 Regressione

Ogni **modello** di un sistema o processo fisico dipende da **parametri**. Questi parametri devono essere calcolati **adattando** il modello alle osservazioni sperimentali (misure)

L'operazione di adattamento (*fit*) di un modello è effettuata mediante **regressione**

1.1 Basi

- Un modello di un sistema fisico può essere espresso come:

$$y = f(x_1, x_2, \dots, x_n, c_1, c_2, \dots, c_m)$$

dove x_i sono le variabili (aleatorie) fisiche, dette **regressori** o **predittori**, mentre le c_i sono i **parametri** (costanti) del modello

- Se $n = 1$ c'è un unico predittore e il modello si dice **semplice**
- Ad esempio, $y = a + bx + cx^2$ è un modello semplice con parametri a, b, c
- **regredire il modello** significa effettuare delle misurazioni di y per diversi valori di x e determinare i valori dei parametri a, b, c che **minimizzano la distanza** tra il modello e le osservazioni sperimentali

1.2 Tipi di regressione

Prenderemo in considerazione tre tipi di regressione:

- Regressione lineare: il modello è una **combinazione lineare dei parametri**
- Regressione lineare generalizzata
- Regressione ai minimi quadrati: i parametri sono combinati in modo non lineare

2 Regressione Lineare

Valida per ogni modello **lineare nei parametri** (mentre i predittori possono comparire con grado diverso da 1)

2.1 Basi

Definizioni

Si definisce il **modello statistico** del processo da regredire come segue:

$$y_i = f(x_{1i}, x_{2i}, \dots, x_{ni}, c_1, c_2, \dots, c_{n+1}) + \varepsilon_i = \hat{y}_i + \varepsilon_i, i = 1, 2, \dots, N$$

dove i è l'indice di osservazione ($N \geq n + 1$ in totale), $\hat{y}_i$ è il **valore regredito**, o **predizione**, in corrispondenza dell'osservazione i , e ε_i sono i **residui**

- Il valore regredito corrisponde alla **componente deterministica**
- Il residuo è la **componente aleatoria**
- Si assume l'ipotesi di **normalità dei residui**, cioè che $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$

Se la $f(\cdot)$ è una funzione analitica e lineare nei coefficienti, allora possiamo esprimerla come $\mathbf{A}\mathbf{k} = \mathbf{y}$, dove

- $\mathbf{y}$ è il vettore delle y_i , $i = 1 \dots N$
- $\mathbf{k}$ è il vettore dei parametri c_j , $j = 1 \dots n + 1$
- $\mathbf{A}$ una matrice $N \times (n + 1)$ così composta:

$$\mathbf{A} = \begin{bmatrix} x_1^{n-1} & x_1^{n-2} & \dots & x_1 & 1 \\ x_2^{n-1} & x_2^{n-2} & \dots & x_2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_N^{n-1} & x_N^{n-2} & \dots & x_N & 1 \end{bmatrix}$$

2.2 Basi

L'equazione lineare può essere risolta con il metodo della **pseudo-inversa**:

$$\begin{aligned} \mathbf{A}^T \mathbf{A} \cdot \mathbf{k} &= \mathbf{A}^T \cdot \mathbf{y} \\ (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{A} \cdot \mathbf{k} &= (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \cdot \mathbf{y} \\ \mathbf{k} &= (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \cdot \mathbf{y} \end{aligned}$$

Questa relazione rende evidente cosa si intende per **regressione lineare**: non ha nulla a che fare con il **grado della funzione regredita**, ma solo con l'equazione lineare nei parametri che rappresenta il modello

NOTE:

- dalla equazione matriciale precedente è evidente che la regressione può essere eseguita se e solo se $N \geq n + 1$, cioè se il numero di osservazioni è almeno pari al numero di parametri
- anche nel caso di una $f(\cdot)$ con più predittori, se essa è lineare nei coefficienti è sempre possibile esprimerla come $\mathbf{A}\mathbf{k} = \mathbf{y}$ e quindi risolverla con il metodo della pseudo-inversa


2.3 Esempio

Sia il modello da regredire del tipo $y_i = (ax_i + b) + \varepsilon_i$; allora può essere rappresentato come:

$$\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{bmatrix} \cdot \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

```
library(modelr)
set.seed(1)
df <- tibble(x=1:10, y=3+2*x+rnorm(length(x), sd=3))
df.lm <- lm(y~x, data=df)
df <- add_predictions(df, df.lm)
df <- add_residuals(df, df.lm)
ggplot(df, aes(x=x, y=y)) +
  geom_line(aes(y=pred), color="red") +
  geom_linerange(aes(ymin=pred, ymax=pred+resid),
color="blue", size=1) +
  geom_point(size=2)
```

```
Warning: Using `size` aesthetic for lines was
deprecated in ggplot2
3.4.0.
i Please use `linewidth` instead.
```



La figura mostra le osservazioni come punti di coordinate (x_i, y_i) , il modello regredito come una **retta rossa** (modello lineare nei

coefficienti a, b e di primo grado del predittore x) e i residui ε_i come segmenti blu che rappresentano la differenza tra le y_i e il corrispondente valore regredito $\hat{y}_i$

3 Regressione ai Minimi Quadrati

Se il modello non è lineare nei parametri, è comunque possibile effettuarne la regressione con il metodo dei **minimi quadrati**

3.1 Regressione ai Minimi Quadrati

Si cerca cioè l'insieme di valori dei parametri che **minimizza la distanza** tra il modello e le osservazioni. Questa minimizzazione può essere realizzata definendo un **indice di merito** che rappresenta la distanza tra modello e osservazioni **in funzione dei parametri**:

$$\Phi(c_1, c_2, \dots, c_m) = \sum_{i=1}^N (y_i - f(x_{1i}, x_{2i}, \dots, x_{ni}, c_1, c_2, \dots, c_m))^2$$

- Se la $f(\cdot)$ è analitica e differenziabile, allora possiamo **minimizzare** $\Phi(\cdot)$ per derivazione, cioè risolvendo il sistema di m equazioni

$$\frac{\partial \Phi}{\partial c_i}(c_1, c_2, \dots, c_m) = 0$$

- Se la $f(\cdot)$ **non è differenziabile**, il minimo di $\Phi(\cdot)$ può comunque essere calcolato per via numerica (ad es. metodo di Newton-Raphson)

4 Qualità della regressione

Ad un dato insieme di osservazioni è possibile adattare **un numero infinito di modelli**

È possibile definire alcuni **parametri di merito** e alcuni **metodi di verifica** che consentono di valutare la qualità di una regressione e, quindi, individuare il modello che meglio si adatta alle osservazioni

4.1 Coefficiente di Determinazione


- Il coefficiente di merito più utilizzato per valutare una regressione è il **coefficiente di determinazione** R^2
- È definito come $R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$, dove $SS_{\text{res}} = \sum \varepsilon_i^2$ e $SS_{\text{tot}} = \sum (y_i - \bar{y})^2$

- Se i valori regrediti corrispondono ai valori osservati $y_i = \hat{y}_i$, allora i residui sono tutti nulli e vale $R^2 = 1$
- La qualità della regressione diminuisce al diminuire di R^2

4.1.a Due set di dati


```
set.seed(0)
N <- 20
df <- tibble(
  x=runif(N, 0, 10),
  y1=5*x+12 + rnorm(N,sd=4.45),
  y2=0.5*x^2 + 1*x + 3 + rnorm(N,sd=1)
)
lm1 <- lm(y1~x, data=df)
df <- add_predictions(df, lm1, var="y1_hat")
lm2 <- lm(y2~x, data=df)
df <- add_predictions(df, lm2, var="y2_hat")
lm3 <- lm(y2~poly(x, degree=2, raw=T), data=df)
df <- add_predictions(df, lm3, var="y3_hat")
r <- c(summary(lm1)$r.squared, summary(lm2)$r.squared,
summary(lm3)$r.squared)

df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y1, color="primo set")) +
  geom_line(aes(y=y1_hat, color="primo set")) +
  geom_point(aes(y=y2, color="secondo set")) +
  geom_line(aes(y=y2_hat, color="secondo set")) +
  labs(color="dati:", title=TeX(glue("$R^2_1={r[1]}$,
$R^2_2={r[2]}$")), x="predittore", y="osservazioni") +
  theme(legend.position = "bottom")
```



4.1.b Stesso set, due modelli

```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y2)) +
  geom_line(aes(y=y2_hat, color="primo grado")) +
  geom_line(aes(y=y3_hat, color="secondo grado")) +
  labs(color="modello:",
        title=TeX(glue("$R^2_1={r[2]}$, $R^2_2={r[3]}$")),
        x="predittore", y="osservazioni") +
  theme(legend.position = "bottom")
```



Nota: come si osserva, non è necessario che i valori dei regressori siano equispaziati!

4.2 Sotto-adattamento

Si ha **sotto-adattamento** (o *under-fitting*) quando il modello ha un grado inferiore all'apparente comportamento delle osservazioni


Può essere evidenziato, oltre che da un R^2 basso, studiando la distribuzione dei residui: se c'è sotto-adattamento i residui possono essere non-normali e, soprattutto, mostrare degli **andamenti**, o *pattern*

Un *pattern* è un andamento regolare dei residui in funzione dei regressori


Dal numero di massimi e minimi presenti nell'eventuale *pattern* è possibile stimare **quanti gradi mancano**

4.2.a Sotto-adattamento

```
df %>% ggplot(aes(x=x)) +  
  geom_point(aes(y=y2)) +  
  geom_line(aes(y=y2_hat)) +  
  labs(x="predittore", y="osservazioni",  
       title="modello di primo grado")
```




```
df %>% ggplot(aes(x=x)) +  
  geom_point(aes(y=lm2$residuals)) +  
  labs(x="predittore", y="residui")
```




4.2.b Adattamento corretto

```
df %>% ggplot(aes(x=x)) +  
  geom_point(aes(y=y2)) +  
  geom_line(aes(y=y3_hat)) +  
    labs(x="predittore", y="osservazioni",  
  title="modello di secondo grado")
```



```
df %>% ggplot(aes(x=x)) +  
  geom_point(aes(y=lm3$residuals)) +  
  labs(x="predittore", y="residui")
```



4.3 Sovra-adattamento

Se il grado del modello è eccessivo, il modello tende a **inseguire i singoli punti**

Il valore di R^2 cresce, raggiungendo 1 quando il grado è uguale al numero di osservazioni meno 1


Tuttavia il modello **perde di generalità** e non riesce più a predire correttamente **nuovi valori** acquisiti in un secondo momento (le crocette rosse in figura)

Il sovra-adattamento ha effetti particolarmente drammatici in caso di **estrapolazione**, cioè quando si valuta il modello al di fuori dell'intervallo in cui è stato regredito

```

set.seed(0)
N <- 8
df <- tibble(
  x=1:N,
  y=3*x+4 + rnorm(N, sd=2),
  y2=3*x+4 + rnorm(N, sd=2)
)
dfp <- tibble(x=seq(-1, N+2, length.out=101))
lm1 <- lm(y~x, data=df)
dfp <- add_predictions(dfp, lm1, var="pred.lm1")
lm2 <- lm(y~poly(x, deg=6, raw=T), data=df)
dfp <- add_predictions(dfp, lm2, var="pred.lm2")
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y)) +
  geom_point(aes(y=y2, color="red", shape=3)) +
  geom_line(aes(x=x, y=pred.lm1, color="grado 1"),
data=dfp) +
  geom_line(aes(x=x, y=pred.lm2, color="grado 6"),
data=dfp) +
  coord_cartesian(ylim=c(5,27), xlim=c(0,9)) +
  labs(color="modello:", x="predittore",
y="osservazioni") +
  theme(legend.position = "bottom")

```



4.4 Bande di Predizione


È una banda **simmetrica rispetto alla regressione** all'interno della quale le osservazioni (presenti e future) hanno una probabilità assegnata di ricadere

Il metodo più robusto per identificare il sovra-adattamento è detto ***K-fold cross-validation***, vedi anche <https://paolobosetti.quarto.pub/kfold.html>

In generale, per un numero di osservazioni sufficientemente grande (> 50) la banda di predizione al 95% contiene il 95% delle osservazioni

```
set.seed(1)
f <- function(x, offset) 0.3*(x-offset)^2+1*(x-offset)
N <- 20
offset <- 5
df <- tibble(
  x=seq(0, 10, length.out=N),
  y= f(x, offset) + rnorm(N, sd=1)
)
dfp <- tibble(
  x=seq(0, 10, length.out=N*10),
  y=f(x, offset) + rnorm(N, sd=1)
)
lm <- lm(y~poly(x, deg=2, raw=T), data=df)
dfp <- cbind(dfp, predict(lm, dfp,
interval="prediction"), level=0.95)

df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y)) +
  geom_line(aes(x=x, y=fit), data=dfp, color="blue",
linewidth=1) +
  geom_line(aes(x=x, y=upr), data=dfp, color="red",
linetype=2) +
  geom_line(aes(x=x, y=lwr), data=dfp, color="red",
linetype=2) +
  geom_point(aes(x=x, y=y), data=dfp, color=gray(2/3),
shape=3) +
  coord_cartesian(ylim=c(-4,15)) +
  labs(x="predittore", y="osservazioni", title="Banda
di predizione al 95%")
```




4.5 Bande di Confidenza

È una banda simmetrica rispetto alla regressione all'interno della quale **il valore atteso del modello** ha una probabilità assegnata di ricadere

È sempre più stretta rispetto alla banda di predizione

È l'equivalente multi-dimensionale dell'intervallo di confidenza per un T-test: come questo è l'intervallo all'interno del quale ha una assegnata probabilità di rientrare il valore corrispondente all'ipotesi nulla, qui possiamo assumere che il modello “vero” rientri con una certa probabilità nella banda di confidenza

```
df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=y)) +
  geom_line(aes(x=x, y=fit), data=dfp) +
  geom_smooth(aes(y=y), method="lm",
    formula=lm$call$formula, level=0.95) +
  coord_cartesian(ylim=c(-4,15)) +
  labs(x="predittore", y="osservazioni", title="Banda
di confidenza al 95%")
```



È ottenuto calcolando gli intervalli di confidenza sui parametri della regressione, calcolando poi—per ogni valore del predittore—il valore massimo e minimo della regressione corrispondente ai valori estremi dei parametri nei loro intervalli di confidenza

5 Regressione Lineare Generalizzata

La regressione lineare classica assume l'ipotesi di **normalità dei residui**

Quando quest'ipotesi non è vera, ma il **modello è comunque lineare nei parametri**, si può utilizzare la regressione lineare generalizzata

5.1 Basi

Nel caso della regressione lineare:

$$y_i = f(\mathbf{x}_i, \mathbf{k}) + \varepsilon_i = \hat{y}_i + \varepsilon_i$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Nel caso della **regressione lineare generalizzata**:

$$y_i = \hat{y}_i + \varepsilon_i$$

$$\varepsilon_i \sim D(p_1, p_2, \dots, p_k)$$

dove D è una generica distribuzione a k parametri facente parte della **famiglia delle distribuzioni esponenziali** (normale, binomiale, gamma, normale inversa, Poisson, quasinormale, quasibinomiale e quasipoissoniana)

Il problema può essere risolto con l'introduzione di una **funzione di collegamento** che riscalda i residui proiettandoli su una distribuzione normale

5.2 Basi

La **funzione di collegamento** (*link function*) $g(\cdot)$ è tale per cui:

$$y_i = \hat{y}_i + g(\varepsilon_i)$$


$$\varepsilon_i \sim D(p_1, p_2, \dots, p_k); g(\varepsilon_i) \sim \mathcal{N}(0, \sigma^2)$$

Le funzioni di collegamento per le distribuzioni più comuni sono:

Distribuzione	Funzione di collegamento
Normale	$g(x) = x$
Binomiale	$g(x) = \text{logit}(x)$
Poisson	$g(x) = \log(x)$
Gamma	$g(x) = 1/x$

In particolare, vale: $\text{logit}(x) = \frac{1}{1+e^{-p(x-x_0)}}$

```
logit <- function(x, p=1, x0=0) 1/(1+exp(-p*(x-x0)))
tibble(x=seq(-6, 6, 0.1), y1=logit(x, 1, 1),
y2=logit(x, -4, 1)) %>%
  ggplot(aes(x=x)) +
  geom_hline(yintercept=c(0, 0.5, 1), lty=2) +
  geom_vline(xintercept=1, lty=2) +
  geom_line(aes(y=y1, color="p=1")) +
  geom_line(aes(y=y2, color="p=-4")) +
  labs(y="logit(x, x0=2, p=1)", color="pendenza:") +
  theme(legend.position = "bottom")
```



5.3 Regressione Logistica

Il caso tipico di regressione logistica è il classificatore di **eventi binomiali**

consideriamo un processo che, in funzione di uno o più predittori, possa fornire un risultato che può valere solo una di due alternative (successo|fallimento, rotto|integro, vero|falso, 1|0). Vogliamo **identificare la soglia dei predittori** che commuta il risultato

Una regressione lineare non è adatta alla situazione: è evidente che i **residui non sono normali** e che la pendenza della regressione dipende molto da quanti punti sono raccolti nelle zone “sicure”

5.3.a Dati

```
library(PearsonDS)
set.seed(0)
N <- 50
N2 <- 0
v0 <- c(90, 102)
sd <- 5
m1 <- list(m=90, variance=5, skewness=1.1, kurtosis=4)
m2 <- list(m=99, variance=5, skewness=-1.1, kurtosis=4)
df <- tibble(
  OK=c(rep(c(T, F), N), rep(T, N2))
) %>%
  arrange(OK) %>%
  mutate(OKv = as.numeric(OK), val=c(
    rpearson(N, moments=m1), rpearson(N, moments=m2),
```


```

runif(N2, 100, 120)))

df.lm <- lm(OKv~val, data=df)
df <- add_predictions(df, df.lm, var="pred.lm")
df <- add_residuals(df, df.lm, var="res.lm")

df %>% ggplot(aes(x=val, y=OKv)) +
  geom_point(aes(color=OK)) +
  geom_line(aes(y=pred.lm), color="blue") +
  coord_cartesian(ylim=c(0,1)) +
  labs(x="valore", y="successo", color="successo:") +
  theme(legend.position = "bottom")

```




5.3.b Residui modello lineare


```

df %>% ggplot(aes(x=val, y=res.lm)) +
  geom_point() +
  labs(x="valore", y="residui", title="Residui")

```




```
df %>% ggplot(aes(sample=res.lm)) +
  geom_qq() +
  geom_qq_line() +
  labs(x="quantili teorici", y="quantili campionari",
  title="Grafico Q-Q")
```



5.4 Regressione Logistica


La funzione logistica regredita fornisce il parametro x_0 che identifica il valore che separa una **uguale quantità di falsi positivi e falsi negativi**

Inoltre, è possibile individuare la soglia opportuna per ottenere una prefissata probabilità di falsi positivi (o falsi negativi)

Questo è il tipo più semplice di **machine learning**: un classificatore binomiale

```
df.glm <- glm(OKv~val, family=binomial(), data=df)
df <- add_predictions(df, df.glm, var="pred.glm",
  type="response")
df <- add_residuals(df, df.glm, var="res.glm")

df %>% ggplot(aes(x=val, y=OKv)) +
  geom_point(aes(color=OK)) +
  geom_line(aes(x=val, y=pred.glm), color="blue") +
  geom_line(aes(y=pred.lm), color=gray(2/3),
  linetype=2) +
  coord_cartesian(ylim=c(0,1)) +
  labs(x="valore", y="successo", color="successo:") +
  theme(legend.position = "bottom")
```



6 Presentazione dei dati

Il concetto di **banda di confidenza** è essenziale nella presentazione grafica di dati provenienti da più serie

6.1 Confronto grafico di serie

```
set.seed(0)
r <- 8
alpha <- 0.05
df.n <- tibble(
  x=seq(100, 900, 100),
  S1=c(300, 310, 318, 330, 290, 305, 358, 290, 180),
  S2=c(315, 315, 322, 340, 272, 315, 340, 285, 185),
  n=c(10, 10, 25, 10, 10, 7, 20, 10, 10)
) %>% mutate(S2=S2-15)

df <- expand.grid(
  r=1:r,
  x=df.n$x
) %>% mutate(
  S1=map_dbl(x, ~df.n[df.n$x==.,]$S1),
  S2=map_dbl(x, ~df.n[df.n$x==.,]$S2)
) %>%
  tibble() %>%
  pivot_longer(S1:S2, names_to="s",
  values_to="nominal", cols_vary = "slowest")

df <- df %>%
  group_by(s, x) %>%
```

```

      group_modify(~      {.x$noise=rnorm(8,
sd=df.n[df.n$x==.y$x,]$n); .x}) %>%
  mutate(value=nominal+noise)

df.s <- df %>% group_by(s, x) %>% summarise(
  n=n(),
  ci=sd(value)/sqrt(n) * qt(alpha/2, n - 1, lower.tail
= F),
  value=mean(value),
  lwr=value-ci,
  upr=value+ci
)

```

```

`summarise()` has regrouped the output.
i Summaries were computed grouped by s and x.
i Output is grouped by s.
i Use `summarise(.groups = "drop_last")` to silence
this
  message.
i Use `summarise(.by = c(s, x))` for per-operation
grouping
  (`?dplyr::dplyr_by`) instead.

```

Supponiamo di avere un processo il cui valore dipende da una variabile x


Supponiamo che un parametro S di processo possa influire sul valore in uscita. Ad esempio:

- il valore è la durezza di un metallo, x è la temperatura, il parametro S è la quantità di un elemento in lega
- il valore è la produttività di un impianto, x è un parametro quantitativo di processo, il parametro S è il tipo di macchina utilizzato

```

df %>% ggplot(aes(x=x)) +
  geom_point(aes(y=value, group=s, color=s, shape=s)) +
  labs(color="Serie:", shape="Serie:", y="valore",
title="Dati grezzi") +
  coord_cartesian(xlim=c(50,950), ylim=c(150,400)) +
  scale_x_continuous(breaks=df.n$x) +
  theme(legend.position = "bottom")

```



Supponiamo di ripetere 8 volte una misurazione del valore in uscita per le varie combinazioni di x e di S , ottenendo i risultati in figura: **quali differenze sono significative?**

6.2 Senza un modello di riferimento


Senza un modello di riferimento che esprima $v = f(x, S)$ **non ha senso effettuare una regressione**

Tuttavia posso riportare, per ogni **trattamento**

- il valor medio, unendo le serie con una spezzata al solo scopo di raggruppare visivamente i dati
- i limiti dell'intervallo di confidenza per ogni serie e per ogni trattamento
- oppure, unire i limiti con una banda che rappresenta la **confidenza sulla media**

```
df.s %>% ggplot(aes(x=x)) +
  geom_ribbon(aes(ymin=lwr, ymax=upr, group=s),
    alpha=1/6) +
  geom_line(aes(y=value, group=s, color=s),
    linewidth=0.5) +
  geom_point(aes(x=x, y=value, group=s, color=s,
    shape=s), data=df) +
  labs(color="Serie:", shape="Serie:", y="valore",
    title="Confidenza al 95%") +
  geom_errorbar(aes(ymin=lwr, ymax=upr, group=s,
    color=s), alpha=2/3, position="dodge", width=33,
    linewidth=1) +
  coord_cartesian(xlim=c(50,950), ylim=c(150,400)) +
```

```
scale_x_continuous(breaks=df.n$x) +
scale_shape_manual(values=c(1, 2)) +
theme(legend.position = "bottom")
```



Zone in cui le bande sono sovrapposte sono statisticamente indistinguibili

6.3 Con un modello

Solo se ho un modello $v = f(x, S)$ posso effettuare una regressione

Anche in questo caso, la regressione va accompagnata con bande di confidenza

Di nuovo, **zone in cui le bande sono sovrapposte sono statisticamente indistinguibili**

```
df %>% ggplot(aes(x=x)) +
  geom_smooth(aes(y=value, group=s, color=s)) +
  geom_point(aes(y=value, group=s, color=s, shape=s)) +
  labs(color="Serie:", shape="Serie:", y="valore",
title="Confidenza al 95%") +
  coord_cartesian(xlim=c(50,950), ylim=c(150,400)) +
  scale_x_continuous(breaks=df.n$x) +
  theme(legend.position = "bottom")
```

```
`geom_smooth()` using method = 'loess' and formula =
'y ~
x'
```

