

# Design of Experiments

Analisi Dati e Statistica, 2026–27



Paolo Bosetti

*Ultimo aggiornamento: 25/09/2026*

## Indice

|          |                                                    |          |
|----------|----------------------------------------------------|----------|
| <b>1</b> | <b>Link alle slide</b>                             | <b>3</b> |
| <b>2</b> | <b>Design (and Analysis) of Experiments</b>        | <b>3</b> |
| 2.1      | Esperimento industriale o esperimento scientifico? | 3        |
| 2.2      | Obiettivi di un esperimento . . . . .              | 4        |
| 2.3      | Dimensionalità di un esperimento . . . . .         | 4        |
| <b>3</b> | <b>Piani fattoriali</b>                            | <b>5</b> |
| 3.1      | Piano fattoriale . . . . .                         | 5        |
| 3.2      | Notazione di Yates . . . . .                       | 6        |
| 3.3      | Piano fattoriale . . . . .                         | 6        |
| 3.4      | Grafico di interazione . . . . .                   | 8        |
| 3.5      | Superficie di risposta . . . . .                   | 9        |
| 3.6      | Piani fattoriali $k^2$ . . . . .                   | 10       |
| 3.7      | Piani fattoriali $k^2$ . . . . .                   | 11       |
| 3.8      | Esempio . . . . .                                  | 11       |
| 3.9      | Esempio — passo 2. . . . .                         | 12       |
| 3.10     | Esempio — passo 3. . . . .                         | 13       |
| 3.11     | Esempio — passo 4. . . . .                         | 14       |
| 3.12     | Esempio — passo 5. . . . .                         | 17       |
| 3.13     | Esempio — passo 6. . . . .                         | 18       |
| 3.14     | Analisi di adeguatezza del modello . . . . .       | 19       |
| 3.15     | Piano fattoriale $2^n$ . . . . .                   | 20       |
| 3.16     | Piano fattoriale $2^n$ . . . . .                   | 20       |

|          |                                                 |           |
|----------|-------------------------------------------------|-----------|
| 3.17     | Piano fattoriale $2^n$                          | 22        |
| 3.18     | Piano fattoriale $2^n$ : modello statistico     | 23        |
| 3.19     | Piani fattoriali non replicati                  | 23        |
| 3.20     | Metodo di Daniel                                | 24        |
| 3.21     | Metodo di Daniel                                | 25        |
| <b>4</b> | <b>Trasformazioni</b>                           | <b>27</b> |
| 4.1      | Esempio                                         | 27        |
| 4.2      | Esempio                                         | 30        |
| 4.3      | Trasformazioni Box-Cox                          | 33        |
| 4.4      | Diagramma Box-Cox                               | 33        |
| <b>5</b> | <b>Estensioni e frazionamenti</b>               | <b>34</b> |
| 5.1      | Central Composite Design (CCD)                  | 34        |
| 5.2      | Piani fattoriali frazionati (FFP)               | 36        |
| 5.3      | Scegliere il frazionamento: relazioni definenti | 37        |
| 5.4      | <i>Alias</i> e informazioni perdute             | 38        |
| 5.5      | <i>Alias</i> e informazioni perdute             | 38        |
| 5.6      | PF Frazionati di tipo $2^{n-p}$                 | 39        |
| <b>6</b> | <b>Raccomandazioni finali</b>                   | <b>39</b> |
| 6.1      | Per fare un buon PF                             | 39        |

```
options(width = 60)
set.seed(0)
library(latex2exp)
library(glue)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ---- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2

-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(modelr)
theme_set(theme_gray()+theme(legend.position = "bottom"))
```

## 1 Link alle slide



## 2 Design (and Analysis) of Experiments

Gli **esperimenti industriali** spesso coinvolgono numerosi fattori corrispondenti a **modelli con regressori multipli** molto complessi

È quindi necessario **minimizzare il numero di trattamenti** e, quindi, il costo dell'esperimento, **a parità di informazioni** ottenute

Gli esperimenti devono poi essere analizzati con un approccio statistico

### 2.1 Esperimento industriale o esperimento scientifico?

Un **esperimento scientifico** viene generalmente condotto allo scopo di supportare o confutare una teoria

- è sempre basato su un **modello teorico** da verificare
- spesso il modello si focalizza sull'effetto di un numero limitato di fattori

In **campo industriale** spesso ciò non è possibile:

- spesso un **modello teorico** per l'oggetto dell'esperimento non è disponibile per motivi scientifici, tecnici o pratici
- l'**interazione** tra più fattori è spesso ciò che più interessa

. . .

Ai fini pratici, la **progettazione** dell'esperimento è tanto più importante quanto più è elevata la complessità (cioè il numero di fattori coinvolti)

## 2.2 Obiettivi di un esperimento

In generale, un esperimento serve a:

1. **confermare** un'ipotesi teorica (modello): si vuole verificare la forma  $y = f(\cdot)$  del modello teorico; la regressione del modello è affiancata allo studio degli intervalli di confidenza (analitici o bootstrap)
2. **calibrare** i parametri di un modello: la forma è nota e si vogliono ricavare i valori dei parametri; generalmente si effettua una regressione, raccogliendo i dati in condizioni operative realistiche
3. **identificare** i fattori che influiscono su un processo: il modello può essere ignoto e si vuole determinare la lista di fattori che compaiono nella  $y = f(\cdot)$ ; l'obiettivo è costruire un modello empirico approssimato, eventualmente utilizzabile come punto di partenza per la formulazione di un modello teorico

## 2.3 Dimensionalità di un esperimento

Se il **modello di interesse è semplice** (un regressore), l'esperimento consiste nell'analisi dell'uscita in corrispondenza di una sequenza di livelli per l'ingresso. Il numero di livelli è correlato con il grado atteso della risposta: per una regressione di grado  $l$  servono **almeno**  $l + 1$  livelli

Ma se il modello ha più di un regressore, cioè l'uscita dipende da  $n$  fattori, e ogni fattore viene indagato su  $l$  livelli, allora il numero di condizioni di test è  $l^n$

Se ogni condizione di test viene poi ripetuta  $r$  volte (per mediare i risultati), il numero di singoli esperimenti è  $rl^n$

Questo numero può diventare grande e economicamente insostenibile **molto in fretta**

## 3 Piani fattoriali

Se in un esperimento con un'unica variabile indipendente il fattore assume una **sequenza** di valori, in un esperimento con più variabili indipendenti gli  $n$  fattori assumono una **griglia**  $n$ -dimensionale di valori, detta **piano fattoriale**

Supponiamo di avere 4 parametri e 4 livelli, ripetendo ogni test 3 volte: il numero totale di prove è 768; se i parametri diventano 5, il numero cresce a 3072, cioè 4 volte tanto, rapporto che vale **anche per il costo**

### 3.1 Piano fattoriale


```
data <- tribble (~A, ~B, ~resa, ~Yates, ~An, ~Bn,
  "A-", "B-", 20, "(1)", -1, -1,
  "A+", "B-", 50, "a", 1, -1,
  "A-", "B+", 30, "b", -1, 1,
  "A+", "B+", 12, "ab", 1, 1
)
```

- Due fattori,  $A$  e  $B$
- Indaghiamo 2 livelli per ogni fattore indicato come  $X-$  e  $X+$
- Cambiamo **un livello alla volta**
- Valutiamo ogni trattamento **1 sola volta**
- Valutiamo gli **effetti** di  $A$  e  $B$ :

$$A = 50 - 20 = 30$$

$$B = 30 - 20 = 10$$

```
data[1:3,1:4] %>% ggplot(aes(x=A, y=B)) +
  geom_label(aes(x=A, y=B, label=resa))
```



### 3.2 Notazione di Yates

Quando i livelli di tutti i fattori sono solo due, si può usare l'**ordine di Yates** per indicare le combinazioni di livelli:

- Fattori ed effetti dei fattori si indicano con lettere maiuscole
- I trattamenti si indicano con combinazioni di lettere minuscole
  - lettera presente significa fattore a livello alto
  - lettera assente significa fattore a livello basso
  - se tutte le lettere sono assenti si scrive (1)

Nell'esempio alla slide precedente, i trattamenti sono (1),  $a$ ,  $b$

### 3.3 Piano fattoriale

```
A <- with(data, (resa[2]+resa[4])/2 - (resa[1]+resa[3])/2)
B <- with(data, (resa[3]+resa[4])/2 - (resa[1]+resa[2])/2)
AB <- with(data, (resa[1]+resa[4])/2 - (resa[2]+resa[3])/2)
```

Modificando un fattore alla volta non si individuano le **interazioni**

Si ha interazione quando l'**effetto** di un fattore dipende dal **livello** di un altro fattore

In questo secondo esempio misuriamo la risposta dei trattamenti (1),  $a$ ,  $b$ ,  $ab$


Possiamo stimare sia gli effetti di  $A$  e  $B$  che l'**interazione**  $AB$ :

$$A = \frac{a + ab}{2} - \frac{(1) + b}{2} = 6$$

$$B = \frac{b + ab}{2} - \frac{(1) + a}{2} = -14$$

$$AB = \frac{a + b}{2} - \frac{(1) + ab}{2} = -24$$

```
ggplot(data, aes(x=A, y=B)) +  
  geom_label(aes(x=A, y=B, label=paste0(Yates,"=",resa)))
```



```
A <- with(data, (resa[2]+resa[4])/2 - (resa[1]+resa[3])/2)  
B <- with(data, (resa[3]+resa[4])/2 - (resa[1]+resa[2])/2)  
AB <- with(data, (resa[1]+resa[4])/2 - (resa[2]+resa[3])/2)
```

### 3.4 Grafico di interazione

Il concetto di interazione è ben illustrato dai **grafici di interazione**


- Se i due segmenti sono **paralleli** non c'è interazione
- Se i due segmenti sono **incrociati** o convergenti c'è interazione
- È **indifferente** quale fattore è in ascissa e quale in serie

#### 3.4.1 Resa vs. A

```
ggplot(data, aes(x=A, y=resa, color=B, group=B)) +  
  geom_line(size=2) +  
  geom_point(size=4)
```


Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.

i Please use `linewidth` instead.



#### 3.4.2 Resa vs. B

```
ggplot(data, aes(x=B, y=resa, color=A, group=A)) +
  geom_line(size=2) +
  geom_point(size=4) +
  theme(legend.position = "bottom")
```



### 3.5 Superficie di risposta


I grafici di interazione non sono altro che **proiezioni** sull'asse di uno dei due fattori della **superficie di risposta**

Si usano generalmente **unità codificate**, riscalando l'intervallo di ciascun fattore sull'intervallo  $[-1, 1]$

In questo modo si ha la stessa sensibilità indipendentemente dall'intervallo della scala originale

```
model <- lm(resa~An*Bn, data)
grd <- expand.grid(An=seq(-1,1,0.1), Bn=seq(-1,1,0.1))
grd %>% mutate(
  resa = predict(model, newdata = grd)
) %>% ggplot(aes(x=An, y=Bn, z=resa)) +
  geom_contour_filled(show.legend=F) +
  labs(x="A", y="B", color="resa") +
  geom_segment(aes(x=-1, y=-1, xend=1, yend=-1, color="B-"), size=2) +
```

```
geom_segment(aes(x=-1, y=1, xend=1, yend=1, color="B+"), size=2) +
geom_point(aes(x=An, y=Bn, color=B), data=data, size=4) +
theme(legend.position = "bottom")
```



### ! Important

**NOTA:** né la superficie di risposta né i grafici di interazione danno alcuna informazione sulla **significatività statistica** degli effetti

## 3.6 Piani fattoriali $k^2$

In generale, un esperimento in cui si abbiano 2 fattori ciascuno testato su  $k$  livelli è un piano fattoriale  $k^2$ , perché il **numero totale di trattamenti** è  $N = rk^2$ , dove  $r$  è il numero di ripetizioni per ciascun trattamento

Il **modello statistico** e il modello di regressione associati all'esperimento sono:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}; \quad \hat{y} = \mu + \alpha x_1 + \beta x_2 + (\alpha\beta)x_1x_2$$

con  $x_1$  e  $x_2$  i valori dei due fattori in **unità codificate**

Come tale, l'esperimento può essere studiato con un'ANOVA a due fattori (o **ANOVA a due vie**):

$$\begin{aligned} \text{A)} \quad & \begin{cases} H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_a = 0 \\ H_1 : \alpha_i \neq 0 \quad \text{per almeno un } i \end{cases} \\ \text{B)} \quad & \begin{cases} H_0 : \beta_1 = \beta_2 = \dots = \beta_b = 0 \\ H_1 : \beta_j \neq 0 \quad \text{per almeno un } j \end{cases} \\ \text{AB)} \quad & \begin{cases} H_0 : (\alpha\beta)_{ij} = 0 \quad \forall (i, j) \\ H_1 : (\alpha\beta)_{ij} \neq 0 \quad \text{per almeno una } (i, j) \end{cases} \end{aligned}$$

### 3.7 Piani fattoriali $k^2$

A queste coppie di ipotesi corrisponde una decomposizione della **somma quadratica totale corretta**  $SS_{\text{tot}} = SS_A + SS_B + SS_{AB} + SS_E$

La tabella ANOVA corrispondente è:

| Effetto | $\nu$<br>(GdL)   | $SS$              | $MS$                               | $F_0$          | $p\text{-value}$                          |
|---------|------------------|-------------------|------------------------------------|----------------|-------------------------------------------|
| A       | $a - 1$          | $SS_A$            | $SS_A/\nu_A$                       | $MS_A/MS_E$    | $\text{CDF}^+(F_{0,A}, \nu_A, \nu_E)$     |
| B       | $b - 1$          | $SS_B$            | $SS_B/\nu_B$                       | $MS_B/MS_E$    | $\text{CDF}^+(F_{0,B}, \nu_B, \nu_E)$     |
| AB      | $(a - 1)(b - 1)$ | $SS_{AB}$         | $SS_{AB}/\nu_{AB}$                 | $MS_{AB}/MS_E$ | $\text{CDF}^+(F_{0,AB}, \nu_{AB}, \nu_E)$ |
| Errore  | $ab(-1)$         | $SS_E$            | $SS_E/\nu_E$                       | —              | —                                         |
| Totale  | $abn - 1$        | $SS_{\text{tot}}$ | $SS_{\text{tot}}/\nu_{\text{tot}}$ | —              | —                                         |

### 3.8 Esempio

Vogliamo studiare l'effetto della velocità di taglio (fattore  $A$ ) e dell'angolo di spoglia (fattore  $B$ ) di un utensile di tornitura sulla vita utensile

I due fattori sono entrambi **quantitativi**; decidiamo di indagare tre livelli per ciascun fattore, ripetendo 2 volte ogni trattamento: piano fattoriale  $2 \cdot 3^2$

1. preparazione della **griglia di test**
2. casualizzazione della sequenza operativa
3. conduzione degli esperimenti e raccolta dati
4. formulazione e verifica del modello statistico
5. analisi della varianza (ANOVA)
6. creazione della superficie di risposta

I punti 4 e 5 sono possibilmente iterati

```
df <- expand.grid(
  Angolo=c(15,20,25),
  Velocità=c(125,150,175),
  Ripetizione=c(1,2),
  Vita = NA) %>%
  mutate(StdOrder=1:n(), RunOrder=sample(n()), .before=Angolo) %>%
  mutate(A=scales::rescale(Angolo, to=c(-1,1)), .after=Angolo) %>%
  mutate(B=scales::rescale(Velocità, c(-1,1)), .after=Velocità)

df %>% filter(Ripetizione==1) %>%
  select(everything() & ! RunOrder) %>%
  knitr::kable()
```

| StdOrder | Angolo | A  | Velocità | B  | Ripetizione | Vita |
|----------|--------|----|----------|----|-------------|------|
| 1        | 15     | -1 | 125      | -1 | 1           | NA   |
| 2        | 20     | 0  | 125      | -1 | 1           | NA   |
| 3        | 25     | 1  | 125      | -1 | 1           | NA   |
| 4        | 15     | -1 | 150      | 0  | 1           | NA   |
| 5        | 20     | 0  | 150      | 0  | 1           | NA   |
| 6        | 25     | 1  | 150      | 0  | 1           | NA   |
| 7        | 15     | -1 | 175      | 1  | 1           | NA   |
| 8        | 20     | 0  | 175      | 1  | 1           | NA   |
| 9        | 25     | 1  | 175      | 1  | 1           | NA   |

### 3.9 Esempio — passo 2.

Nella griglia si genera una nuova colonna di interi  $\langle 1 \dots N \rangle$ ,  $N = r!^n$  ordinati casualmente

Per motivi di spazio la tabella riporta solo la prima metà delle righe, corrispondenti con la prima ripetizione

Si riordina la griglia secondo la nuova colonna, generalmente chiamata *Run Order*

```
df %>%
  arrange(RunOrder) %>%
  knitr::kable()
```

| StdOrder | RunOrder | Angolo | A  | Velocità | B  | Ripetizione | Vita |
|----------|----------|--------|----|----------|----|-------------|------|
| 4        | 1        | 15     | -1 | 150      | 0  | 1           | NA   |
| 5        | 2        | 20     | 0  | 150      | 0  | 1           | NA   |
| 10       | 3        | 15     | -1 | 125      | -1 | 2           | NA   |
| 2        | 4        | 20     | 0  | 125      | -1 | 1           | NA   |
| 12       | 5        | 25     | 1  | 125      | -1 | 2           | NA   |
| 15       | 6        | 25     | 1  | 150      | 0  | 2           | NA   |
| 3        | 7        | 25     | 1  | 125      | -1 | 1           | NA   |
| 18       | 8        | 25     | 1  | 175      | 1  | 2           | NA   |
| 17       | 9        | 20     | 0  | 175      | 1  | 2           | NA   |
| 14       | 10       | 20     | 0  | 150      | 0  | 2           | NA   |
| 8        | 11       | 20     | 0  | 175      | 1  | 1           | NA   |
| 13       | 12       | 15     | -1 | 150      | 0  | 2           | NA   |
| 6        | 13       | 25     | 1  | 150      | 0  | 1           | NA   |
| 1        | 14       | 15     | -1 | 125      | -1 | 1           | NA   |
| 11       | 15       | 20     | 0  | 125      | -1 | 2           | NA   |
| 7        | 16       | 15     | -1 | 175      | 1  | 1           | NA   |
| 16       | 17       | 15     | -1 | 175      | 1  | 2           | NA   |
| 9        | 18       | 25     | 1  | 175      | 1  | 1           | NA   |

### 3.10 Esempio — passo 3.

Si effettuano gli esperimenti secondo il *run order*

Eseguendo gli esperimenti secondo il *run order* eventuali effetti **ignoti e incontrollati** si distribuiscono casualmente su tutti i trattamenti:

- la varianza globale aumenta ( $SS_{\text{tot}}$ )
- l'effetto relativo dei fattori non viene alterato ( $SS_X$ )

### **i** Note

**Nota:** una *ripetizione* è una replica dell'intero esperimento, non della sola operazione di misura

```
df$Vita <- c(-2, 0, -1, -3, 1, 5, 2, 4, 0, -1, 2, 0, 0, 3, 6, 3, 6, -1)

df %>%
  arrange(RunOrder) %>%
  knitr::kable()
```

| StdOrder | RunOrder | Angolo | A  | Velocità | B  | Ripetizione | Vita |
|----------|----------|--------|----|----------|----|-------------|------|
| 4        | 1        | 15     | -1 | 150      | 0  | 1           | -3   |
| 5        | 2        | 20     | 0  | 150      | 0  | 1           | 1    |
| 10       | 3        | 15     | -1 | 125      | -1 | 2           | -1   |
| 2        | 4        | 20     | 0  | 125      | -1 | 1           | 0    |
| 12       | 5        | 25     | 1  | 125      | -1 | 2           | 0    |
| 15       | 6        | 25     | 1  | 150      | 0  | 2           | 6    |
| 3        | 7        | 25     | 1  | 125      | -1 | 1           | -1   |
| 18       | 8        | 25     | 1  | 175      | 1  | 2           | -1   |
| 17       | 9        | 20     | 0  | 175      | 1  | 2           | 6    |
| 14       | 10       | 20     | 0  | 150      | 0  | 2           | 3    |
| 8        | 11       | 20     | 0  | 175      | 1  | 1           | 4    |
| 13       | 12       | 15     | -1 | 150      | 0  | 2           | 0    |
| 6        | 13       | 25     | 1  | 150      | 0  | 1           | 5    |
| 1        | 14       | 15     | -1 | 125      | -1 | 1           | -2   |
| 11       | 15       | 20     | 0  | 125      | -1 | 2           | 2    |
| 7        | 16       | 15     | -1 | 175      | 1  | 1           | 2    |
| 16       | 17       | 15     | -1 | 175      | 1  | 2           | 3    |
| 9        | 18       | 25     | 1  | 175      | 1  | 1           | 0    |

### 3.11 Esempio — passo 4.

Formuliamo il modello di regressione completo di secondo grado:

$$\begin{aligned}\hat{y} = & \mu + \alpha_1 x_1 + \beta_1 x_2 + (\alpha\beta)_1 x_1 x_2 + \\ & + \alpha_2 x_1^2 + \beta_2 x_2^2 + (\alpha\beta)_{2,1} x_1^2 x_2 + \\ & + (\alpha\beta)_{1,2} x_1 x_2^2 + (\alpha\beta)_{2,2} x_1^2 x_2^2\end{aligned}$$

```
df.lm <- lm(Vita~Angolo*Velocità*I(Angolo^2)*I(Velocità^2), data=df)
```


dove, ricordiamo  $(\alpha\beta)$  non è un prodotto, ma rappresenta il coefficiente di un prodotto di fattori  $A$  e  $B$

### ! Important

È necessario valutare normalità e assenza di pattern nei residui


#### 3.11.1 $\varepsilon(A)$

```
df <- add_residuals(df, df.lm)
ggplot(df, aes(x=Angolo, y=resid)) + geom_point() +
  labs(x="angolo", y="residui")
```




### 3.11.2 $\varepsilon(B)$

```
ggplot(df, aes(x=Velocità, y=resid)) + geom_point() +  
  labs(x="velocità", y="residui")
```




### 3.11.3 $\varepsilon(r)$

```
ggplot(df, aes(x=RunOrder, y=resid)) + geom_point() +  
  labs(x="Run Order", y="residui")
```



### 3.11.4 Quantile-Quantile

```
ggplot(df, aes(sample=resid)) +
  geom_qq() +
  geom_qq_line()
```



### 3.12 Esempio — passo 5.

Scegliendo il 5% come soglia sul  $p$ -value, osserviamo che risultano **statisticamente non significativi** gli effetti:

- $B^2$ , corrispondente al termine  $\beta_2$  nella regressione
- $A^2B$ , corrispondente al termine  $(\alpha\beta)_{2,1}$  nella regressione

```
anova(df.lm) %>% tibble() %>%
  mutate(effetto=c("$A$", "$B$", "$A^2$", "$B^2$", "$AB$", "$A^2B$", "$AB^2$", "$A^2B^2$", "$\
  rename(`$\nu$`=Df, `$$SS$`=Sum Sq`, `$$MS$`=Mean Sq`, `$$F_0$`=F value`, `$$p$`=p-value,
  knitr::kable()
```

| effetto | $\nu$ | $SS$      | $MS$      | $F_0$     | $p$ -value |
|---------|-------|-----------|-----------|-----------|------------|
| $A$     | 1     | 8.333333  | 8.333333  | 5.769231  | 0.0397723  |
| $B$     | 1     | 21.333333 | 21.333333 | 14.769231 | 0.0039479  |
| $A^2$   | 1     | 16.000000 | 16.000000 | 11.076923 | 0.0088243  |

| effetto       | $\nu$ | $SS$      | $MS$      | $F_0$     | $p$ -value |
|---------------|-------|-----------|-----------|-----------|------------|
| $B^2$         | 1     | 4.000000  | 4.000000  | 2.769231  | 0.1304507  |
| $AB$          | 1     | 8.000000  | 8.000000  | 5.538462  | 0.0430650  |
| $A^2B$        | 1     | 2.666667  | 2.666667  | 1.846154  | 0.2073056  |
| $AB^2$        | 1     | 42.666667 | 42.666667 | 29.538462 | 0.0004137  |
| $A^2B^2$      | 1     | 8.000000  | 8.000000  | 5.538462  | 0.0430650  |
| $\varepsilon$ | 9     | 13.000000 | 1.444444  | NA        | NA         |

Quindi l'equazione di regressione diventa:

$$\begin{aligned}\hat{y} = & \mu + \alpha_1 x_1 + \beta_1 x_2 + (\alpha\beta)_{1,1} x_1 x_2 + \\ & + \alpha_2 x_1^2 + (\alpha\beta)_{1,2} x_1 x_2^2 + \\ & + (\alpha\beta)_{2,2} x_1^2 x_2^2\end{aligned}$$

### 3.13 Esempio — passo 6.


La **superficie di risposta** consente di identificare punti e direzioni notevoli:

- Il punto S è un punto di sella, in cui il gradiente è nullo in qualsiasi direzione: punto stabile
- Nel punto P, le direzioni tangenti all'isoipsa sono **direzioni a resa costante**
- Il punto M è un **massimo** della resa

```
p1 <- c(22.1, 164)
p2 <- c(17.55, 145)
p3 <- c(25.0, 150)
rs <- expand.grid(
  Angolo=seq(15,25,length.out=20),
  Velocità=seq(125,175,length.out=20))
add_predictions(rs, df.lm) %>%
  ggplot(aes(x=Angolo, y=Velocità, z=pred)) +
  geom_contour_filled() +
  geom_label(aes(x=p1[1], y=p1[2], label="S")) +
  geom_label(aes(x=p2[1], y=p2[2], label="P")) +
  geom_label(aes(x=p3[1], y=p3[2], label="M")) +
  labs(color="Vita utensile") +
  theme(legend.position = "bottom")
```

```
Warning in predict.lm(model, data): prediction from
rank-deficient fit; attr(*, "non-estim") has doubtful cases
```

```
Ignoring unknown labels:
* colour : "Vita utensile"
```



### 3.14 Analisi di adeguatezza del modello

Dopo aver eventualmente escluso alcuni effetti (ad esempio  $B^2$  e  $A^2B$ ) è necessario:

1. riformulare il modello
2. analizzare i residui del nuovo modello
3. confermare con una nuova ANOVA

In particolare, l'analisi dei residui è detta **verifica di adeguatezza del modello** (*Model Adequacy Check*, MAC) e consiste dipicamente in:


- verifica assenza di pattern nei residui in funzione dei fattori
- verifica assenza di pattern nei residui in funzione dell'ordine di test
- verifica di normalità dei residui (grafico Q-Q e test di Shapiro-Wilk)

In generale, una superficie di risposta è una **iper-superficie** in uno spazio  $n + 1$ -dimensionale, dove  $n$  è il numero di fattori

### 3.15 Piano fattoriale $2^n$

I piani fattoriali in cui tutti i fattori hanno due livelli (basso e alto, -1 e +1 in unità codificate) sono di particolare interesse

- consentono di regredire modelli soltanto del primo grado
- richiedono il minimo delle prove
- consentono comunque di definire la sensibilità del processo ai vari fattori, **escludendo i fattori non-significativi**
- sono il punto di partenza di qualsiasi analisi di processi complessi



### 3.16 Piano fattoriale $2^n$

- Ogni fattore ha due livelli: basso e alto. In **unità codificate** valgono -1 e +1, indicati in breve come - e +
- I **trattamenti**, cioè combinazioni di livelli per gli  $n$  fattori, sono indicati con la **notazione di Yates**
- la **matrice di progetto** si ottiene permutando tutti i fattori tra - e + con frequenze via via dimezzate

- la matrice di progetto è ripetuta per le  $r$  ripetizioni e riporta anche la colonna dell'**ordine casuale di esecuzione**
- la **matrice degli effetti** si ottiene aggiungendo le colonne per le interazioni, calcolate come prodotto dei segni relativi

### 3.16.1 Matrice di progetto

```
lv <- c("-", "+")
`%f*%` <- function(a, b) {
  an <- ifelse(a=="-", -1, 1)
  bn <- ifelse(b=="-", -1, 1)
  ifelse(an*bn == -1, "-", "+")
}
dm <- expand.grid(
  I="+",
  A=lv,
  B=lv,
  C=lv
) %>%
  mutate(AB=A%f*%B, .after=B) %>%
  mutate(AC=A%f*%C, BC=B%f*%C, ABC=A%f*%B%f*%C) %>%
  mutate(I="+") %>%
  mutate(trattamento=tolower(colnames(.)), .before="I")
tr <- tolower(colnames(dm))
dm$trattamento[1] <- "(1)"

dm %>%
  select(trattamento, A, B, C) %>%
  mutate(ripetizione=1, .after=trattamento) %>%
  mutate(ordine=sample(n())) %>%
  knitr::kable(align=c("l", rep("c", 8)))
```

| trattamento | ripetizione | A | B | C | ordine |
|-------------|-------------|---|---|---|--------|
| (1)         | 1           | - | - | - | 1      |
| a           | 1           | + | - | - | 7      |
| b           | 1           | - | + | - | 5      |
| ab          | 1           | + | + | - | 6      |

| trattamento | ripetizione | A | B | C | ordine |
|-------------|-------------|---|---|---|--------|
| c           | 1           | - | - | + | 8      |
| ac          | 1           | + | - | + | 4      |
| bc          | 1           | - | + | + | 2      |
| abc         | 1           | + | + | + | 3      |

### 3.16.2 Matrice degli effetti

```
dm %>%
  knitr::kable(align=c("l", rep("c", 8)))
```

| trattamento | I | A | B | AB | C | AC | BC | ABC |
|-------------|---|---|---|----|---|----|----|-----|
| (1)         | + | - | - | +  | - | +  | +  | -   |
| a           | + | + | - | -  | - | -  | +  | +   |
| b           | + | - | + | -  | - | +  | -  | +   |
| ab          | + | + | + | +  | - | -  | -  | -   |
| c           | + | - | - | +  | + | -  | -  | +   |
| ac          | + | + | - | -  | + | +  | -  | -   |
| bc          | + | - | + | -  | + | -  | +  | -   |
| abc         | + | + | + | +  | + | +  | +  | +   |

### 3.17 Piano fattoriale $2^n$

La matrice degli effetti contiene le informazioni per calcolare gli **effetti** e le somme quadratiche  $SS$  che, a loro volta, servono per completare la tabella ANOVA

Per gli effetti:

$$A = \frac{-(1) + a - b + ab}{2r}$$

$$B = \frac{-(1) - a + b + ab}{2r}$$

$$AB = \frac{+(1) - a - b + ab}{2r}$$

Per le somme quadratiche:

$$SS_A = \frac{(-1 + a - b + ab)^2}{4r}$$

$$SS_B = \frac{(-1 - a + b + ab)^2}{4r}$$

$$SS_{AB} = \frac{(+1 - a - b + ab)^2}{4r}$$

In generale:  $Ef(X) = \frac{2}{2^{n_r}} \text{Contrast}(X)$  e  $SS(X) = \frac{1}{2^{n_r}} \text{Contrast}(X)^2$  dove il **contrasto** del fattore  $\text{Contrast}(X)$  è calcolato usando i segni della relativa colonna  $X$  per i trattamenti nell'ordine di Yates (es.  $\text{Contrast}(AB) = +1 - a - b + ab$ )

### 3.18 Piano fattoriale $2^n$ : modello statistico

Il **modello statistico** di un piano fattoriale  $2^n$  è ovviamente un modello lineare di primo grado in tutti i fattori. Per  $n = 2$ , ad esempio:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}$$

Per  $n = 3$ :

$$y_{ijkl} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \gamma_k + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + \varepsilon_{ijkl}$$

e così via.

In R vedremo che questi modelli possono essere rispettivamente abbreviati come  $Y \sim A*B$  e  $Y \sim A*B*C$  e utilizzati per calcolare la tabella ANOVA

Esercizio: ricavare i modelli di regressione corrispondenti ai due modelli statistici sopra riportati

### 3.19 Piani fattoriali non replicati

Al crescere del numero di fattori, il numero di singoli test può diventare insostenibile

Il modo più semplice per ridurre il numero di test è **evitare le ripetizioni per i vari trattamenti**

Se un trattamento non è ripetuto, però, non è possibile calcolare la  $SS_E$  e quindi non si può completare la tabella ANOVA con le  $F_0$  e i  $p$ -value

La soluzione è stata proposta da C. Daniel e si basa sull'**ipotesi che almeno uno dei fattori o delle interazioni non sia significativo**

Quest'ipotesi è di solito ragionevole per i processi più complessi con  $n$  elevato, proprio i casi in cui è particolarmente importante ridurre il numero di test

L'idea è che gli **effetti non-significativi** siano statistiche calcolate su diversi sotto-campioni dello stesso campione omogeneo, e quindi siano normalmente distribuiti. Solo gli **effetti significativi** si dipartono dalla distribuzione normale degli altri

### 3.20 Metodo di Daniel

Quali effetti siano probabilmente significativi è quindi possibile determinarlo con un grafico quantile-quantile degli stessi

Il grafico è un primo screening che deve essere **conservativo**: serve solo per rimuovere effetti sicuramente non significativi (cioè molto allineati alla diagonale) e consentire l'esecuzione dell'ANOVA


La tabella ANOVA va comunque calcolata su un **modello statistico lineare ridotto**, in modo da confermare il risultato del metodo grafico o da rimuovere ulteriori effetti che risultassero effettivamente non-significativi

```
daniel <- expand.grid(  
  An = c(-1, 1),  
  Bn = c(-1, 1),  
  Cn = c(-1, 1),  
  Dn = c(-1, 1)  
) %>%  
  mutate(A=factor(An), B=factor(Bn),  
          C=factor(Cn), D=factor(Dn), .before=An) %>%  
  mutate(Yield=c(  
    45, 71, 48, 65, 68, 60, 80, 65,
```

```

43, 100, 45, 104, 75, 86, 70, 96
))
daniel.lm <- lm(Yield~A*B*C*D, data=daniel)
c <- effects(daniel.lm)
tibble(
  term = names(c),
  value = as.numeric(c)
) %>% slice_tail(n=length(c)-1) %>%
  ggplot(aes(sample=value)) +
  geom_hline(aes(yintercept=value), color=gray(0.7)) +
  geom_qq() +
  geom_qq_line() +
  geom_label(aes(y=value, x=-3., label=term), hjust="left") +
  coord_cartesian(xlim=c(-3,3)) +
  labs(x="Quantili teorici", y="Quantili campionari")

```



### 3.21 Metodo di Daniel


In questo caso risultano non-normali solo gli effetti  $A$ ,  $C$ ,  $D$  e le interazioni  $AC$  e  $AD$

Il modello statistico lineare può quindi essere rivisto come

$$y_{ijkl} = \mu + \alpha_i + \gamma_j + (\alpha\gamma)_{ij} + \delta_k + (\alpha\delta)_{ik} + \varepsilon_{ijkl} \quad (1)$$

Cioè possiamo già escludere che  $B$  sia di fatto un fattore. In questo modo, anziché un piano fattoriale  $2^4$  non replicato abbiamo a che fare con un  $2^3$  replicato due volte (cioè  $2 \cdot 2^3$ ), per il quale possiamo eseguire una normale analisi ANOVA

```
tibble(
  term = names(c),
  value = as.numeric(c)
) %>% slice_tail(n=length(c)-1) %>%
  ggplot(aes(sample=value)) +
  geom_hline(aes(yintercept=value), color=gray(0.7)) +
  geom_qq() +
  geom_qq_line() +
  geom_label(aes(y=value, x=-3., label=term), hjust="left") +
  coord_cartesian(xlim=c(-3,3)) +
  labs(x="Quantili teorici", y="Quantili campionari")
```



## 4 Trasformazioni

In generale, se i residui di un modello lineare risultano non-normali, allora i  $p$ -value non possono essere calcolati a partire dalle  $F_0$

Spesso, però, è possibile **trasformare** la risposta in modo da rendere normali i residui

La trasformazione può essere una qualunque funzione analitica applicata alla risposta

### 4.1 Esempio

```
data <- tibble(  
  x = factor(rep(1:4, 6)) %>% sort(),  
  resa = c(  
    0.34, 0.12, 1.23, 0.70, 1.75, 0.12,  
    0.91, 2.94, 2.14, 2.36, 2.86, 4.55,  
    6.31, 8.37, 9.75, 6.09, 9.82, 7.24,  
    17.15, 11.82, 10.95, 17.20, 14.35, 16.82)  
)  
  
data.lm <- lm(resa~x, data=data)  
data <- data %>%  
  add_residuals(data.lm) %>%  
  add_predictions(data.lm)  
  
data.lmt <- lm(sqrt(resa)~x, data=data)  
data <- data %>%  
  add_residuals(data.lmt, var="resid_sq") %>%  
  add_predictions(data.lmt, var="pred_sq")
```

Consideriamo i dati rappresentati in questo grafico


Non ha importanza l'origine dei dati: limitiamoci a costruire un modello lineare dei dati

$$y_{ij} = \mu + x_i + \varepsilon_{ij}$$

Si noti come i residui non sembrano normali e che ci sono degli evidenti **pattern**


#### 4.1.1 Dati

```
data %>% ggplot(aes(x=x, y=resa)) + geom_boxplot()
```




#### 4.1.2 Residui vs. x

```
data %>%  
  ggplot(aes(x=x, y=resid)) +  
  geom_point()
```




#### 4.1.3 Residui vs. $\hat{y}$

```
data %>%
  ggplot(aes(x=pred, y=resid)) +
  geom_point()
```



#### 4.1.4 Q-Q

```
data %>%  
  ggplot(aes(sample=resid)) +  
  geom_qq() +  
  geom_qq_line()
```



## 4.2 Esempio

Se osserviamo dal boxplot che la resa tende ad aumentare più che linearmente con  $x$ , possiamo pensare di riformulare il modello *trasformandolo* mediante un'elevazione al quadrato:

$$y_{ij} = (\mu + x_i + \varepsilon_{ij})^2$$


Il modello non sembra più lineare, ma considerando che può essere riscritto come

$$\sqrt{y_{ij}} = \mu + x_i + \varepsilon_{ij}$$

è evidente che si tratta ancora di un **modello lineare nei coefficienti**.


### 4.2.1 Residui vs. x

```
data %>%  
  ggplot(aes(x=x, y=resid_sq)) +  
  geom_point()
```




### 4.2.2 Residui vs. $\hat{y}$

```
data %>%  
  ggplot(aes(x=pred_sq, y=resid_sq)) +  
  geom_point()
```



### 4.2.3 Q-Q

```
data %>%
  ggplot(aes(sample=resid_sq)) +
  geom_qq() +
  geom_qq_line()
```



In seguito a questa trasformazione è quindi evidente che il nuovo modello è più adeguato, con residui privi di pattern e più compatibili con una distribuzione normale

### 4.3 Trasformazioni Box-Cox

Box e Cox hanno proposto un metodo per identificare la **miglior trasformazione** nella famiglia delle trasformazioni di potenza  $y^* = y^\lambda$ , con  $y^* = \ln(y)$  quando  $\lambda = 0$

Si calcola un grafico della **verosimiglianza logaritmica**  $\mathcal{L}$  (*log-likelihood*) della seguente  $y^{(\lambda)}$ :

$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda y^{\lambda-1}} & \lambda \neq 0 \\ y \ln y_i & \lambda = 0 \end{cases}, \quad \bar{y} = \exp \left[ (1/n) \sum \ln y_i \right], \quad i = 1, 2, \dots, n$$

La verosimiglianza  $\ln \mathcal{L}(\lambda|y)$  non è altro che la probabilità di estrarre un campione  $y$  dato un certo parametro  $\lambda$ . Il suo massimo coincide col valore di  $\lambda$  che rende il campione  $y$  più normale.

### 4.4 Diagramma Box-Cox


Il diagramma Box-Cox individua anche un intervallo corrispondente ad una variazione inferiore al 95%

Qualunque valore di  $\lambda$  interno a questo intervallo è statisticamente equivalente

Si sceglie quindi il valore incluso nell'intervallo **e che rappresenta una trasformazione “comoda”**

Ad es., se risultasse un  $\lambda$  ottimale pari a 0.58, sceglierei comunque  $\lambda = 0.5$ , che corrisponde alla trasformazione  $y^* = \sqrt{y}$

```
car::boxCox(data.lm)
```



**i** Note

Ogni volta che un modello lineare è **sospetto** (in una **regressione** o nell'**analisi di un piano fattoriale**) è opportuno tentare con una trasformazione Box-Cox. Nei PF, a volte la trasformazione Box-Cox può **semplificare il modello** (cioè ridurre il numero di fattori o interazioni significativi)

## 5 Estensioni e frazionamenti

Un piano fattoriale  $2^n$  assume che la risposta sia lineare: quest'ipotesi va verificata **estendendo** il piano a più di 2 livelli

Un piano fattoriale, anche  $2^n$  non replicato, può risultare comunque troppo oneroso: in questi casi è possibile **frazionarlo**, cioè dividere per potenze di 2 il numero di trattamenti, pena la perdita di informazioni sulle interazioni più complesse

### 5.1 Central Composite Design (CCD)


Verrebbe automatico **estendere** un PF da  $2^2$  a  $2^3$  per valutare gli effetti quadratici

In questo modo, però, la **sensibilità** nelle direzioni assiali sarebbe inferiore alla sensibilità nelle direzioni diagonali, essendo l'intervallo di valutazione più piccolo nel primo caso


Si preferisce quindi eseguire PF centrati con **simmetria rotazionale attorno all'origine**

Per due fattori, i punti assiali sono estesi a distanza  $\sqrt{2}$  dall'origine; nel generico caso  $n$ -dimensionale la distanza è  $(2^n)^{1/4}$

### 5.1.1 Due fattori



### 5.1.2 Tre fattori




## 5.2 Piani fattoriali frazionati (FFP)

Supponiamo di considerare **soltanto** i vertici opposti del PF in figura:  $(1), ab, ac, bc$

Stiamo considerando **metà del PF originale**, che comunque include tutti i livelli dei tre fattori

Sicuramente il frazionamento riduce la completezza del modello, ma consente di risparmiare molti test

- Come scegliere il frazionamento per dimensioni superiori?
- Quali informazioni perdiamo?



### 5.3 Scegliere il frazionamento: relazioni definenti

Osservando la **matrice degli effetti**, osserviamo che i trattamenti (1),  $ab$ ,  $ac$ ,  $bc$  corrispondono alle righe per cui vale la relazione  $I = -ABC$ . L'altra metà complementare corrisponde invece a  $I = ABC$

Queste relazioni sono chiamate **relazioni definenti** perché definiscono il PFF. È indifferente scegliere la metà positiva o quella negativa

```
dm %>%
  knitr::kable(align=c("l", rep("c", 8)))
```

| trattamento | I | A | B | AB | C | AC | BC | ABC |
|-------------|---|---|---|----|---|----|----|-----|
| (1)         | + | - | - | +  | - | +  | +  | -   |
| a           | + | + | - | -  | - | -  | +  | +   |
| b           | + | - | + | -  | - | +  | -  | +   |
| ab          | + | + | + | +  | - | -  | -  | -   |
| c           | + | - | - | +  | + | -  | -  | +   |

| trattamento | I | A | B | AB | C | AC | BC | ABC |
|-------------|---|---|---|----|---|----|----|-----|
| ac          | + | + | - | -  | + | +  | -  | -   |
| bc          | + | - | + | -  | + | -  | +  | -   |
| abc         | + | + | + | +  | + | +  | +  | +   |

## 5.4 *Alias* e informazioni perdute

In un PF frazionato  $2^{3-1}$  con relazione definente  $I = ABC$ , consideriamo questi effetti:

$$A = (-1 + a - b + ab - c + ac - bc + abc)/(2r)$$

$$BC = (+1 + a - b - ab - c - ac + bc + abc)/(2r)$$

Siccome i trattamenti sottolineati **non sono testati**, l'effetto  $A$  risulta indistinguibile dall'effetto  $BC$

Si dice che  $A$  è in *alias* con  $BC$

Data una certa relazione definente, le possibili strutture di alias possono essere ricavate dalla relazione stessa mediante un'algebra dedicata:  $I \cdot X = X$ ,  $X \cdot X = X$ ,  $X \cdot Y = XY$ .

Quindi, risulta  $A \cdot I = A \cdot ABC$  cioè  $A = BC$ , e altrettanto  $B = AC$  e  $C = AB$ .

## 5.5 *Alias* e informazioni perdute

Quindi, frazionando un PF si perdono informazioni: si perde la capacità di discriminare tra gli effetti in *alias*. È evidente che più lunga è la relazione definente, più elevato sarà il grado di interazioni in alias con gli effetti diretti (es.  $A = BCDEF$ )

In virtù del **principio di sparsità degli effetti**, tuttavia, questa perdita di informazioni non è drammatica. Il **principio** dice che in un processo la significatività di interazioni di alto livello è via via meno probabile all'aumentare del numro di fattori che le compongono

La matrice degli effetti per un PF frazionato  $2^{n-1}$  più la relazione definente individuano univocamente un piano fattoriale frazionato

Di conseguenza, un alias  $A = BCDEF$  può essere trascurato assumendo la significatività di  $A$  piuttosto che quella di  $BCDEF$  in virtù del PSdE

## 5.6 PF Frazionati di tipo $2^{n-p}$

È possibile frazionare un piano più di una volta, riducendo il numero di trattamenti a  $2^{n-p}$

Per ogni frazionamento è necessario scegliere una nuova relazione definente

Ad esempio, per  $2^{7-2}$  si possono scegliere le RD  $I = ABCDE$  e  $I = CDEFG$

Per queste due RD ne esiste una terza, dipendente:  $I = ABFG$ . Due qualsiasi di queste tre RD sono equivalenti

### 5.6.1 Minimum aberration design

- Si generano tutte le possibili  $p$ -uple di relazioni definenti, completandole con la dipendente
- Si conta il numero di lettere nelle  $(p + 1)$ -uple (es. precedente:  $\langle 5, 5, 4 \rangle$ )
- il *design* che minimizza il numero di stringhe con lunghezza minima è da preferire perché **ha meno alias**

## 6 Raccomandazioni finali

È molto comune assistere a DoE applicati solo parzialmente...

### 6.1 Per fare un buon PF

- Iniziare con un  $2^n$  per poi aumentarlo
- Valutare l'opportunità di frazionamento e scegliere con attenzione le relazioni definenti
- Eseguire **sempre** la verifica di adeguatezza del modello e raffinare il modello statistico di conseguenza

- Discutere le interazione e gli effetti **solo dopo aver raffinato il modello**
- Valutare gli effetti di *alias*

#### **6.1.1 Temi avanzati**

- *Blocking*
- *Minimum Aberration Design*
- Trasformazioni del modello e trasformazioni Box-Cox