

Design of Experiments

Analisi Dati e Statistica, 2026–27



Paolo Bosetti

Ultimo aggiornamento: 24/09/2026

Indice

1	Link alle slide	3
2	Design (and Analysis) of Experiments	3
2.1	Esperimento industriale o esperimento scientifico?	3
2.2	Obiettivi di un esperimento	4
2.3	Dimensionalità di un esperimento	4
3	Piani fattoriali	5
3.1	Piano fattoriale	5
3.2	Notazione di Yates	6
3.3	Piano fattoriale	6
3.4	Grafico di interazione	8
3.5	Superficie di risposta	9
3.6	Piani fattoriali k^2	10
3.7	Piani fattoriali k^2	11
3.8	Esempio	11
3.9	Esempio — passo 2.	12
3.10	Esempio — passo 3.	13
3.11	Esempio — passo 4.	14
3.12	Esempio — passo 5.	17
3.13	Esempio — passo 6.	18
3.14	Analisi di adeguatezza del modello	19
3.15	Piano fattoriale 2^n	20
3.16	Piano fattoriale 2^n	20

3.17	Piano fattoriale 2^n	22
3.18	Piano fattoriale 2^n : modello statistico	23
3.19	Piani fattoriali non replicati	23
3.20	Metodo di Daniel	24
3.21	Metodo di Daniel	25
4	Trasformazioni	27
4.1	Esempio	27
4.2	Esempio	30
4.3	Trasformazioni Box-Cox	33
4.4	Diagramma Box-Cox	33
5	Estensioni e frazionamenti	34
5.1	Central Composite Design (CCD)	34
5.2	Piani fattoriali frazionati (FFP)	36
5.3	Scegliere il frazionamento: relazioni definenti	37
5.4	<i>Alias</i> e informazioni perdute	38
5.5	<i>Alias</i> e informazioni perdute	38
5.6	PF Frazionati di tipo 2^{n-p}	39
6	Raccomandazioni finali	39
6.1	Per fare un buon PF	39

```
options(width = 60)
set.seed(0)
library(latex2exp)
library(glue)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ---- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2

-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(modelr)
theme_set(theme_gray()+theme(legend.position = "bottom"))
```

1 Link alle slide



2 Design (and Analysis) of Experiments

Gli **esperimenti industriali** spesso coinvolgono numerosi fattori corrispondenti a **modelli con regressori multipli** molto complessi

È quindi necessario **minimizzare il numero di trattamenti** e, quindi, il costo dell'esperimento, **a parità di informazioni** ottenute

Gli esperimenti devono poi essere analizzati con un approccio statistico

2.1 Esperimento industriale o esperimento scientifico?

Un **esperimento scientifico** viene generalmente condotto allo scopo di supportare o confutare una teoria

- è sempre basato su un **modello teorico** da verificare
- spesso il modello si focalizza sull'effetto di un numero limitato di fattori

In **campo industriale** spesso ciò non è possibile:

- spesso un **modello teorico** per l'oggetto dell'esperimento non è disponibile per motivi scientifici, tecnici o pratici
- l'**interazione** tra più fattori è spesso ciò che più interessa

. . .

Ai fini pratici, la **progettazione** dell'esperimento è tanto più importante quanto più è elevata la complessità (cioè il numero di fattori coinvolti)

2.2 Obiettivi di un esperimento

In generale, un esperimento serve a:

1. **confermare** un'ipotesi teorica (modello): si vuole verificare la forma $y = f(\cdot)$ del modello teorico; la regressione del modello è affiancata allo studio degli intervalli di confidenza (analitici o bootstrap)
2. **calibrare** i parametri di un modello: la forma è nota e si vogliono ricavare i valori dei parametri; generalmente si effettua una regressione, raccogliendo i dati in condizioni operative realistiche
3. **identificare** i fattori che influiscono su un processo: il modello può essere ignoto e si vuole determinare la lista di fattori che compaiono nella $y = f(\cdot)$; l'obiettivo è costruire un modello empirico approssimato, eventualmente utilizzabile come punto di partenza per la formulazione di un modello teorico

2.3 Dimensionalità di un esperimento

Se il **modello di interesse è semplice** (un regressore), l'esperimento consiste nell'analisi dell'uscita in corrispondenza di una sequenza di livelli per l'ingresso. Il numero di livelli è correlato con il grado atteso della risposta: per una regressione di grado l servono **almeno** $l + 1$ livelli

Ma se il modello ha più di un regressore, cioè l'uscita dipende da n fattori, e ogni fattore viene indagato su l livelli, allora il numero di condizioni di test è l^n

Se ogni condizione di test viene poi ripetuta r volte (per mediare i risultati), il numero di singoli esperimenti è rl^n

Questo numero può diventare grande e economicamente insostenibile **molto in fretta**

3 Piani fattoriali

Se in un esperimento con un'unica variabile indipendente il fattore assume una **sequenza** di valori, in un esperimento con più variabili indipendenti gli n fattori assumono una **griglia** n -dimensionale di valori, detta **piano fattoriale**

Supponiamo di avere 4 parametri e 4 livelli, ripetendo ogni test 3 volte: il numero totale di prove è 768; se i parametri diventano 5, il numero cresce a 3072, cioè 4 volte tanto, rapporto che vale **anche per il costo**

3.1 Piano fattoriale


```
data <- tribble (~A, ~B, ~resa, ~Yates, ~An, ~Bn,
  "A-", "B-", 20, "(1)", -1, -1,
  "A+", "B-", 50, "a", 1, -1,
  "A-", "B+", 30, "b", -1, 1,
  "A+", "B+", 12, "ab", 1, 1
)
```

- Due fattori, A e B
- Indaghiamo 2 livelli per ogni fattore indicato come $X-$ e $X+$
- Cambiamo **un livello alla volta**
- Valutiamo ogni trattamento **1 sola volta**
- Valutiamo gli **effetti** di A e B :

$$A = 50 - 20 = 30$$

$$B = 30 - 20 = 10$$

```
data[1:3,1:4] %>% ggplot(aes(x=A, y=B)) +
  geom_label(aes(x=A, y=B, label=resa))
```



3.2 Notazione di Yates

Quando i livelli di tutti i fattori sono solo due, si può usare l'**ordine di Yates** per indicare le combinazioni di livelli:

- Fattori ed effetti dei fattori si indicano con lettere maiuscole
- I trattamenti si indicano con combinazioni di lettere minuscole
 - lettera presente significa fattore a livello alto
 - lettera assente significa fattore a livello basso
 - se tutte le lettere sono assenti si scrive (1)

Nell'esempio alla slide precedente, i trattamenti sono (1), a , b

3.3 Piano fattoriale

```
A <- with(data, (resa[2]+resa[4])/2 - (resa[1]+resa[3])/2)
B <- with(data, (resa[3]+resa[4])/2 - (resa[1]+resa[2])/2)
AB <- with(data, (resa[1]+resa[4])/2 - (resa[2]+resa[3])/2)
```

Modificando un fattore alla volta non si individuano le **interazioni**

Si ha interazione quando l'**effetto** di un fattore dipende dal **livello** di un altro fattore

In questo secondo esempio misuriamo la risposta dei trattamenti (1), a , b , ab


Possiamo stimare sia gli effetti di A e B che l'**interazione** AB :

$$A = \frac{a + ab}{2} - \frac{(1) + b}{2} = 6$$

$$B = \frac{b + ab}{2} - \frac{(1) + a}{2} = -14$$

$$AB = \frac{a + b}{2} - \frac{(1) + ab}{2} = -24$$

```
ggplot(data, aes(x=A, y=B)) +  
  geom_label(aes(x=A, y=B, label=paste0(Yates,"=",resa)))
```



```
A <- with(data, (resa[2]+resa[4])/2 - (resa[1]+resa[3])/2)  
B <- with(data, (resa[3]+resa[4])/2 - (resa[1]+resa[2])/2)  
AB <- with(data, (resa[1]+resa[4])/2 - (resa[2]+resa[3])/2)
```

3.4 Grafico di interazione

Il concetto di interazione è ben illustrato dai **grafici di interazione**


- Se i due segmenti sono **paralleli** non c'è interazione
- Se i due segmenti sono **incrociati** o convergenti c'è interazione
- È **indifferente** quale fattore è in ascissa e quale in serie

3.4.1 Resa vs. A

```
ggplot(data, aes(x=A, y=resa, color=B, group=B)) +  
  geom_line(size=2) +  
  geom_point(size=4)
```


Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.

i Please use `linewidth` instead.



3.4.2 Resa vs. B


```
ggplot(data, aes(x=B, y=resa, color=A, group=A)) +
  geom_line(size=2) +
  geom_point(size=4) +
  theme(legend.position = "bottom")
```



3.5 Superficie di risposta


I grafici di interazione non sono altro che **proiezioni** sull'asse di uno dei due fattori della **superficie di risposta**

Si usano generalmente **unità codificate**, riscalando l'intervallo di ciascun fattore sull'intervallo $[-1, 1]$

In questo modo si ha la stessa sensibilità indipendentemente dall'intervallo della scala originale

```
model <- lm(resa~An*Bn, data)
grd <- expand.grid(An=seq(-1,1,0.1), Bn=seq(-1,1,0.1))
grd %>% mutate(
  resa = predict(model, newdata = grd)
) %>% ggplot(aes(x=An, y=Bn, z=resa)) +
  geom_contour_filled(show.legend=F) +
  labs(x="A", y="B", color="resa") +
  geom_segment(aes(x=-1, y=-1, xend=1, yend=-1, color="B-"), size=2) +
```

```
geom_segment(aes(x=-1, y=1, xend=1, yend=1, color="B+"), size=2) +
geom_point(aes(x=An, y=Bn, color=B), data=data, size=4) +
theme(legend.position = "bottom")
```



! Important

NOTA: né la superficie di risposta né i grafici di interazione danno alcuna informazione sulla **significatività statistica** degli effetti

3.6 Piani fattoriali k^2

In generale, un esperimento in cui si abbiano 2 fattori ciascuno testato su k livelli è un piano fattoriale k^2 , perché il **numero totale di trattamenti** è $N = rk^2$, dove r è il numero di ripetizioni per ciascun trattamento

Il **modello statistico** e il modello di regressione associati all'esperimento sono:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}; \quad \hat{y} = \mu + \alpha x_1 + \beta x_2 + (\alpha\beta)x_1x_2$$

con x_1 e x_2 i valori dei due fattori in **unità codificate**

Come tale, l'esperimento può essere studiato con un'ANOVA a due fattori (o **ANOVA a due vie**):

$$\begin{aligned} \text{A)} \quad & \begin{cases} H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_a = 0 \\ H_1 : \alpha_i \neq 0 \quad \text{per almeno un } i \end{cases} \\ \text{B)} \quad & \begin{cases} H_0 : \beta_1 = \beta_2 = \dots = \beta_b = 0 \\ H_1 : \beta_j \neq 0 \quad \text{per almeno un } j \end{cases} \\ \text{AB)} \quad & \begin{cases} H_0 : (\alpha\beta)_{ij} = 0 \quad \forall (i, j) \\ H_1 : (\alpha\beta)_{ij} \neq 0 \quad \text{per almeno una } (i, j) \end{cases} \end{aligned}$$

3.7 Piani fattoriali k^2

A queste coppie di ipotesi corrisponde una decomposizione della **somma quadratica totale corretta** $SS_{\text{tot}} = SS_A + SS_B + SS_{AB} + SS_E$

La tabella ANOVA corrispondente è:

Effetto	ν (GdL)	SS	MS	F_0	$p\text{-value}$
A	$a - 1$	SS_A	SS_A/ν_A	MS_A/MS_E	$\text{CDF}^+(F_{0,A}, \nu_A, \nu_E)$
B	$b - 1$	SS_B	SS_B/ν_B	MS_B/MS_E	$\text{CDF}^+(F_{0,B}, \nu_B, \nu_E)$
AB	$(a - 1)(b - 1)$	SS_{AB}	SS_{AB}/ν_{AB}	MS_{AB}/MS_E	$\text{CDF}^+(F_{0,AB}, \nu_{AB}, \nu_E)$
Errore	$ab(-1)$	SS_E	SS_E/ν_E	—	—
Totale	$abn - 1$	SS_{tot}	$SS_{\text{tot}}/\nu_{\text{tot}}$	—	—

3.8 Esempio

Vogliamo studiare l'effetto della velocità di taglio (fattore A) e dell'angolo di spoglia (fattore B) di un utensile di tornitura sulla vita utensile

I due fattori sono entrambi **quantitativi**; decidiamo di indagare tre livelli per ciascun fattore, ripetendo 2 volte ogni trattamento: piano fattoriale $2 \cdot 3^2$

1. preparazione della **griglia di test**
2. casualizzazione della sequenza operativa
3. conduzione degli esperimenti e raccolta dati
4. formulazione e verifica del modello statistico
5. analisi della varianza (ANOVA)
6. creazione della superficie di risposta

I punti 4 e 5 sono possibilmente iterati

```
df <- expand.grid(
  Angolo=c(15,20,25),
  Velocità=c(125,150,175),
  Ripetizione=c(1,2),
  Vita = NA) %>%
mutate(StdOrder=1:n(), RunOrder=sample(n()), .before=Angolo) %>%
mutate(A=scales::rescale(Angolo, to=c(-1,1)), .after=Angolo) %>%
mutate(B=scales::rescale(Velocità, c(-1,1)), .after=Velocità)

df %>% filter(Ripetizione==1) %>%
  select(everything() & ! RunOrder) %>%
  knitr::kable()
```

StdOrder	Angolo	A	Velocità	B	Ripetizione	Vita
1	15	-1	125	-1	1	NA
2	20	0	125	-1	1	NA
3	25	1	125	-1	1	NA
4	15	-1	150	0	1	NA
5	20	0	150	0	1	NA
6	25	1	150	0	1	NA
7	15	-1	175	1	1	NA
8	20	0	175	1	1	NA
9	25	1	175	1	1	NA

3.9 Esempio — passo 2.

Nella griglia si genera una nuova colonna di interi $\langle 1 \dots N \rangle$, $N = r!^n$ ordinati casualmente

Per motivi di spazio la tabella riporta solo la prima metà delle righe, corrispondenti con la prima ripetizione

Si riordina la griglia secondo la nuova colonna, generalmente chiamata *Run Order*

```
df %>%
  arrange(RunOrder) %>%
  knitr::kable()
```

StdOrder	RunOrder	Angolo	A	Velocità	B	Ripetizione	Vita
4	1	15	-1	150	0	1	NA
5	2	20	0	150	0	1	NA
10	3	15	-1	125	-1	2	NA
2	4	20	0	125	-1	1	NA
12	5	25	1	125	-1	2	NA
15	6	25	1	150	0	2	NA
3	7	25	1	125	-1	1	NA
18	8	25	1	175	1	2	NA
17	9	20	0	175	1	2	NA
14	10	20	0	150	0	2	NA
8	11	20	0	175	1	1	NA
13	12	15	-1	150	0	2	NA
6	13	25	1	150	0	1	NA
1	14	15	-1	125	-1	1	NA
11	15	20	0	125	-1	2	NA
7	16	15	-1	175	1	1	NA
16	17	15	-1	175	1	2	NA
9	18	25	1	175	1	1	NA

3.10 Esempio — passo 3.

Si effettuano gli esperimenti secondo il *run order*

Eseguendo gli esperimenti secondo il *run order* eventuali effetti **ignoti e incontrollati** si distribuiscono casualmente su tutti i trattamenti:

- la varianza globale aumenta (SS_{tot})
- l'effetto relativo dei fattori non viene alterato (SS_X)

i Note

Nota: una *ripetizione* è una replica dell'intero esperimento, non della sola operazione di misura

```
df$Vita <- c(-2, 0, -1, -3, 1, 5, 2, 4, 0, -1, 2, 0, 0, 3, 6, 3, 6, -1)

df %>%
  arrange(RunOrder) %>%
  knitr::kable()
```

StdOrder	RunOrder	Angolo	A	Velocità	B	Ripetizione	Vita
4	1	15	-1	150	0	1	-3
5	2	20	0	150	0	1	1
10	3	15	-1	125	-1	2	-1
2	4	20	0	125	-1	1	0
12	5	25	1	125	-1	2	0
15	6	25	1	150	0	2	6
3	7	25	1	125	-1	1	-1
18	8	25	1	175	1	2	-1
17	9	20	0	175	1	2	6
14	10	20	0	150	0	2	3
8	11	20	0	175	1	1	4
13	12	15	-1	150	0	2	0
6	13	25	1	150	0	1	5
1	14	15	-1	125	-1	1	-2
11	15	20	0	125	-1	2	2
7	16	15	-1	175	1	1	2
16	17	15	-1	175	1	2	3
9	18	25	1	175	1	1	0

3.11 Esempio — passo 4.

Formuliamo il modello di regressione completo di secondo grado:

$$\begin{aligned}\hat{y} = & \mu + \alpha_1 x_1 + \beta_1 x_2 + (\alpha\beta)_1 x_1 x_2 + \\ & + \alpha_2 x_1^2 + \beta_2 x_2^2 + (\alpha\beta)_{2,1} x_1^2 x_2 + \\ & + (\alpha\beta)_{1,2} x_1 x_2^2 + (\alpha\beta)_{2,2} x_1^2 x_2^2\end{aligned}$$

```
df.lm <- lm(Vita~Angolo*Velocità*I(Angolo^2)*I(Velocità^2), data=df)
```


dove, ricordiamo $(\alpha\beta)$ non è un prodotto, ma rappresenta il coefficiente di un prodotto di fattori A e B

! Important

È necessario valutare normalità e assenza di pattern nei residui


3.11.1 $\varepsilon(A)$

```
df <- add_residuals(df, df.lm)
ggplot(df, aes(x=Angolo, y=resid)) + geom_point() +
  labs(x="angolo", y="residui")
```




3.11.2 $\varepsilon(B)$

```
ggplot(df, aes(x=Velocità, y=resid)) + geom_point() +  
  labs(x="velocità", y="residui")
```




3.11.3 $\varepsilon(r)$

```
ggplot(df, aes(x=RunOrder, y=resid)) + geom_point() +  
  labs(x="Run Order", y="residui")
```



3.11.4 Quantile-Quantile

```
ggplot(df, aes(sample=resid)) +
  geom_qq() +
  geom_qq_line()
```



3.12 Esempio — passo 5.

Scegliendo il 5% come soglia sul p -value, osserviamo che risultano **statisticamente non significativi** gli effetti:

- B^2 , corrispondente al termine β_2 nella regressione
- A^2B , corrispondente al termine $(\alpha\beta)_{2,1}$ nella regressione

```
anova(df.lm) %>% tibble() %>%
  mutate(effetto=c("$A$", "$B$", "$A^2$", "$B^2$", "$AB$", "$A^2B$", "$AB^2$", "$A^2B^2$", "$\
  rename(`$\nu$`=Df, `$$SS$`=Sum Sq`, `$$MS$`=Mean Sq`, `$$F_0$`=F value`, `$$p$`=p-value,
  knitr::kable()
```

effetto	ν	SS	MS	F_0	p -value
A	1	8.333333	8.333333	5.769231	0.0397723
B	1	21.333333	21.333333	14.769231	0.0039479
A^2	1	16.000000	16.000000	11.076923	0.0088243

effetto	ν	SS	MS	F_0	p -value
B^2	1	4.000000	4.000000	2.769231	0.1304507
AB	1	8.000000	8.000000	5.538462	0.0430650
A^2B	1	2.666667	2.666667	1.846154	0.2073056
AB^2	1	42.666667	42.666667	29.538462	0.0004137
A^2B^2	1	8.000000	8.000000	5.538462	0.0430650
ε	9	13.000000	1.444444	NA	NA

Quindi l'equazione di regressione diventa:

$$\begin{aligned}\hat{y} = & \mu + \alpha_1 x_1 + \beta_1 x_2 + (\alpha\beta)_1 x_1 x_2 + \\ & + \alpha_2 x_1^2 + (\alpha\beta)_{1,2} x_1 x_2^2 + \\ & + (\alpha\beta)_{2,2} x_1^2 x_2^2\end{aligned}$$

3.13 Esempio — passo 6.


La **superficie di risposta** consente di identificare punti e direzioni notevoli:

- Il punto S è un punto di sella, in cui il gradiente è nullo in qualsiasi direzione: punto stabile
- Nel punto P, le direzioni tangenti all'isoipsa sono **direzioni a resa costante**
- Il punto M è un **massimo** della resa

```
p1 <- c(22.1, 164)
p2 <- c(17.55, 145)
p3 <- c(25.0, 150)
rs <- expand.grid(
  Angolo=seq(15,25,length.out=20),
  Velocità=seq(125,175,length.out=20))
add_predictions(rs, df.lm) %>%
  ggplot(aes(x=Angolo, y=Velocità, z=pred)) +
  geom_contour_filled() +
  geom_label(aes(x=p1[1], y=p1[2], label="S")) +
  geom_label(aes(x=p2[1], y=p2[2], label="P")) +
  geom_label(aes(x=p3[1], y=p3[2], label="M")) +
  labs(color="Vita utensile") +
  theme(legend.position = "bottom")
```

```
Warning in predict.lm(model, data): prediction from
rank-deficient fit; attr(*, "non-estim") has doubtful cases
```

```
Ignoring unknown labels:
* colour : "Vita utensile"
```



3.14 Analisi di adeguatezza del modello

Dopo aver eventualmente escluso alcuni effetti (ad esempio B^2 e A^2B) è necessario:

1. riformulare il modello
2. analizzare i residui del nuovo modello
3. confermare con una nuova ANOVA

In particolare, l'analisi dei residui è detta **verifica di adeguatezza del modello** (*Model Adequacy Check*, MAC) e consiste dipicamente in:


- verifica assenza di pattern nei residui in funzione dei fattori
- verifica assenza di pattern nei residui in funzione dell'ordine di test
- verifica di normalità dei residui (grafico Q-Q e test di Shapiro-Wilk)

In generale, una superfice di risposta è una **iper-superficie** in uno spazio $n + 1$ -dimensionale, dove n è il numero di fattori

3.15 Piano fattoriale 2^n

I piani fattoriali in cui tutti i fattori hanno due livelli (basso e alto, -1 e +1 in unità codificate) sono di particolare interesse

- consentono di regredire modelli soltanto del primo grado
- richiedono il minimo delle prove
- consentono comunque di definire la sensibilità del processo ai vari fattori, **escludendo i fattori non-significativi**
- sono il punto di partenza di qualsiasi analisi di processi complessi



3.16 Piano fattoriale 2^n

- Ogni fattore ha due livelli: basso e alto. In **unità codificate** valgono -1 e +1, indicati in breve come - e +
- I **trattamenti**, cioè combinazioni di livelli per gli n fattori, sono indicati con la **notazione di Yates**
- la **matrice di progetto** si ottiene permutando tutti i fattori tra - e + con frequenze via via dimezzate

- la matrice di progetto è ripetuta per le r ripetizioni e riporta anche la colonna dell'**ordine casuale di esecuzione**
- la **matrice degli effetti** si ottiene aggiungendo le colonne per le interazioni, calcolate come prodotto dei segni relativi

3.16.1 Matrice di progetto

```
lv <- c("-", "+")
`%f*%` <- function(a, b) {
  an <- ifelse(a=="-", -1, 1)
  bn <- ifelse(b=="-", -1, 1)
  ifelse(an*bn == -1, "-", "+")
}
dm <- expand.grid(
  I="+",
  A=lv,
  B=lv,
  C=lv
) %>%
  mutate(AB=A%f*%B, .after=B) %>%
  mutate(AC=A%f*%C, BC=B%f*%C, ABC=A%f*%B%f*%C) %>%
  mutate(I="+") %>%
  mutate(trattamento=tolower(colnames(.)), .before="I")
tr <- tolower(colnames(dm))
dm$trattamento[1] <- "(1)"

dm %>%
  select(trattamento, A, B, C) %>%
  mutate(ripetizione=1, .after=trattamento) %>%
  mutate(ordine=sample(n())) %>%
  knitr::kable(align=c("l", rep("c", 8)))
```

trattamento	ripetizione	A	B	C	ordine
(1)	1	-	-	-	1
a	1	+	-	-	7
b	1	-	+	-	5
ab	1	+	+	-	6

trattamento	ripetizione	A	B	C	ordine
c	1	-	-	+	8
ac	1	+	-	+	4
bc	1	-	+	+	2
abc	1	+	+	+	3

3.16.2 Matrice degli effetti

```
dm %>%
  knitr::kable(align=c("l", rep("c", 8)))
```

trattamento	I	A	B	AB	C	AC	BC	ABC
(1)	+	-	-	+	-	+	+	-
a	+	+	-	-	-	-	+	+
b	+	-	+	-	-	+	-	+
ab	+	+	+	+	-	-	-	-
c	+	-	-	+	+	-	-	+
ac	+	+	-	-	+	+	-	-
bc	+	-	+	-	+	-	+	-
abc	+	+	+	+	+	+	+	+

3.17 Piano fattoriale 2^n

La matrice degli effetti contiene le informazioni per calcolare gli **effetti** e le somme quadratiche SS che, a loro volta, servono per completare la tabella ANOVA

Per gli effetti:

$$A = \frac{-(1) + a - b + ab}{2r}$$

$$B = \frac{-(1) - a + b + ab}{2r}$$

$$AB = \frac{+(1) - a - b + ab}{2r}$$

Per le somme quadratiche:

$$\begin{aligned}SS_A &= \frac{(-1 + a - b + ab)^2}{4r} \\SS_B &= \frac{(-1 - a + b + ab)^2}{4r} \\SS_{AB} &= \frac{(+1 - a - b + ab)^2}{4r}\end{aligned}$$

In generale: $Ef(X) = \frac{2}{2^{n_r}} \text{Contrast}(X)$ e $SS(X) = \frac{1}{2^{n_r}} \text{Contrast}(X)^2$ dove il **contrasto** del fattore $\text{Contrast}(X)$ è calcolato usando i segni della relativa colonna X per i trattamenti nell'ordine di Yates (es. $\text{Contrast}(AB) = +1 - a - b + ab$)

3.18 Piano fattoriale 2^n : modello statistico

Il **modello statistico** di un piano fattoriale 2^n è ovviamente un modello lineare di primo grado in tutti i fattori. Per $n = 2$, ad esempio:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}$$

Per $n = 3$:

$$y_{ijkl} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \gamma_k + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + \varepsilon_{ijkl}$$

e così via.

In R vedremo che questi modelli possono essere rispettivamente abbreviati come $Y \sim A*B$ e $Y \sim A*B*C$ e utilizzati per calcolare la tabella ANOVA

Esercizio: ricavare i modelli di regressione corrispondenti ai due modelli statistici sopra riportati

3.19 Piani fattoriali non replicati

Al crescere del numero di fattori, il numero di singoli test può diventare insostenibile

Il modo più semplice per ridurre il numero di test è **evitare le ripetizioni per i vari trattamenti**

Se un trattamento non è ripetuto, però, non è possibile calcolare la SS_E e quindi non si può completare la tabella ANOVA con le F_0 e i p -value

La soluzione è stata proposta da C. Daniel e si basa sull'**ipotesi che almeno uno dei fattori o delle interazioni non sia significativo**

Quest'ipotesi è di solito ragionevole per i processi più complessi con n elevato, proprio i casi in cui è particolarmente importante ridurre il numero di test

L'idea è che gli **effetti non-significativi** siano statistiche calcolate su diversi sotto-campioni dello stesso campione omogeneo, e quindi siano normalmente distribuiti. Solo gli **effetti significativi** si dipartono dalla distribuzione normale degli altri

3.20 Metodo di Daniel

Quali effetti siano probabilmente significativi è quindi possibile determinarlo con un grafico quantile-quantile degli stessi

Il grafico è un primo screening che deve essere **conservativo**: serve solo per rimuovere effetti sicuramente non significativi (cioè molto allineati alla diagonale) e consentire l'esecuzione dell'ANOVA

La tabella ANOVA va comunque calcolata su un **modello statistico lineare ridotto**, in modo da confermare il risultato del metodo grafico o da rimuovere ulteriori effetti che risultassero effettivamente non-significativi


```
daniel <- expand.grid(  
  An = c(-1, 1),  
  Bn = c(-1, 1),  
  Cn = c(-1, 1),  
  Dn = c(-1, 1)  
) %>%  
  mutate(A=factor(An), B=factor(Bn),  
          C=factor(Cn), D=factor(Dn), .before=An) %>%  
  mutate(Yield=c(  
    45, 71, 48, 65, 68, 60, 80, 65,
```



```

43, 100, 45, 104, 75, 86, 70, 96
))
daniel.lm <- lm(Yield~A*B*C*D, data=daniel)
c <- effects(daniel.lm)
tibble(
  term = names(c),
  value = as.numeric(c)
) %>% slice_tail(n=length(c)-1) %>%
  ggplot(aes(sample=value)) +
  geom_hline(aes(yintercept=value), color=gray(0.7)) +
  geom_qq() +
  geom_qq_line() +
  geom_label(aes(y=value, x=-3., label=term), hjust="left") +
  coord_cartesian(xlim=c(-3,3)) +
  labs(x="Quantili teorici", y="Quantili campionari")

```



3.21 Metodo di Daniel


In questo caso risultano non-normali solo gli effetti A , C , D e le interazioni AC e AD

Il modello statistico lineare può quindi essere rivisto come

$$y_{ijkl} = \mu + \alpha_i + \gamma_j + (\alpha\gamma)_{ij} + \delta_k + (\alpha\delta)_{ik} + \varepsilon_{ijkl} \quad (1)$$

Cioè possiamo già escludere che B sia di fatto un fattore. In questo modo, anziché un piano fattoriale 2^4 non replicato abbiamo a che fare con un 2^3 replicato due volte (cioè $2 \cdot 2^3$), per il quale possiamo eseguire una normale analisi ANOVA

```
tibble(
  term = names(c),
  value = as.numeric(c)
) %>% slice_tail(n=length(c)-1) %>%
  ggplot(aes(sample=value)) +
  geom_hline(aes(yintercept=value), color=gray(0.7)) +
  geom_qq() +
  geom_qq_line() +
  geom_label(aes(y=value, x=-3., label=term), hjust="left") +
  coord_cartesian(xlim=c(-3,3)) +
  labs(x="Quantili teorici", y="Quantili campionari")
```



4 Trasformazioni

In generale, se i residui di un modello lineare risultano non-normali, allora i p -value non possono essere calcolati a partire dalle F_0

Spesso, però, è possibile **trasformare** la risposta in modo da rendere normali i residui

La trasformazione può essere una qualunque funzione analitica applicata alla risposta

4.1 Esempio

```
data <- tibble(  
  x = factor(rep(1:4, 6)) %>% sort(),  
  resa = c(  
    0.34, 0.12, 1.23, 0.70, 1.75, 0.12,  
    0.91, 2.94, 2.14, 2.36, 2.86, 4.55,  
    6.31, 8.37, 9.75, 6.09, 9.82, 7.24,  
    17.15, 11.82, 10.95, 17.20, 14.35, 16.82)  
)  
  
data.lm <- lm(resa~x, data=data)  
data <- data %>%  
  add_residuals(data.lm) %>%  
  add_predictions(data.lm)  
  
data.lmt <- lm(sqrt(resa)~x, data=data)  
data <- data %>%  
  add_residuals(data.lmt, var="resid_sq") %>%  
  add_predictions(data.lmt, var="pred_sq")
```

Consideriamo i dati rappresentati in questo grafico


Non ha importanza l'origine dei dati: limitiamoci a costruire un modello lineare dei dati

$$y_{ij} = \mu + x_i + \varepsilon_{ij}$$

Si noti come i residui non sembrano normali e che ci sono degli evidenti **pattern**


4.1.1 Dati

```
data %>% ggplot(aes(x=x, y=resa)) + geom_boxplot()
```




4.1.2 Residui vs. x

```
data %>%  
  ggplot(aes(x=x, y=resid)) +  
  geom_point()
```




4.1.3 Residui vs. $\hat{y}$

```
data %>%
  ggplot(aes(x=pred, y=resid)) +
  geom_point()
```



4.1.4 Q-Q

```
data %>%  
  ggplot(aes(sample=resid)) +  
  geom_qq() +  
  geom_qq_line()
```



4.2 Esempio

Se osserviamo dal boxplot che la resa tende ad aumentare più che linearmente con x , possiamo pensare di riformulare il modello *trasformandolo* mediante un'elevazione al quadrato:

$$y_{ij} = (\mu + x_i + \varepsilon_{ij})^2$$


Il modello non sembra più lineare, ma considerando che può essere riscritto come

$$\sqrt{y_{ij}} = \mu + x_i + \varepsilon_{ij}$$

è evidente che si tratta ancora di un **modello lineare nei coefficienti**.


4.2.1 Residui vs. x

```
data %>%  
  ggplot(aes(x=x, y=resid_sq)) +  
  geom_point()
```




4.2.2 Residui vs. $\hat{y}$

```
data %>%  
  ggplot(aes(x=pred_sq, y=resid_sq)) +  
  geom_point()
```



4.2.3 Q-Q

```
data %>%
  ggplot(aes(sample=resid_sq)) +
  geom_qq() +
  geom_qq_line()
```



In seguito a questa trasformazione è quindi evidente che il nuovo modello è più adeguato, con residui privi di pattern e più compatibili con una distribuzione normale

4.3 Trasformazioni Box-Cox

Box e Cox hanno proposto un metodo per identificare la **miglior trasformazione** nella famiglia delle trasformazioni di potenza $y^* = y^\lambda$, con $y^* = \ln(y)$ quando $\lambda = 0$

Si calcola un grafico della **verosimiglianza logaritmica** $\mathcal{L}$ (*log-likelihood*) della seguente $y^{(\lambda)}$:

$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda y^{\lambda-1}} & \lambda \neq 0 \\ y \ln y_i & \lambda = 0 \end{cases}, \quad \bar{y} = \exp \left[(1/n) \sum \ln y_i \right], \quad i = 1, 2, \dots, n$$

La verosimiglianza $\ln \mathcal{L}(\lambda|y)$ non è altro che la probabilità di estrarre un campione y dato un certo parametro λ . Il suo massimo coincide col valore di λ che rende il campione y più normale.

4.4 Diagramma Box-Cox


Il diagramma Box-Cox individua anche un intervallo corrispondente ad una variazione inferiore al 95%

Qualunque valore di λ interno a questo intervallo è statisticamente equivalente

Si sceglie quindi il valore incluso nell'intervallo **e che rappresenta una trasformazione “comoda”**

Ad es., se risultasse un λ ottimale pari a 0.58, sceglierei comunque $\lambda = 0.5$, che corrisponde alla trasformazione $y^* = \sqrt{y}$

```
car::boxCox(data.lm)
```



i Note

Ogni volta che un modello lineare è **sospetto** (in una **regressione** o nell'**analisi di un piano fattoriale**) è opportuno tentare con una trasformazione Box-Cox. Nei PF, a volte la trasformazione Box-Cox può **semplificare il modello** (cioè ridurre il numero di fattori o interazioni significativi)

5 Estensioni e frazionamenti

Un piano fattoriale 2^n assume che la risposta sia lineare: quest'ipotesi va verificata **estendendo** il piano a più di 2 livelli

Un piano fattoriale, anche 2^n non replicato, può risultare comunque troppo oneroso: in questi casi è possibile **frazionarlo**, cioè dividere per potenze di 2 il numero di trattamenti, pena la perdita di informazioni sulle interazioni più complesse

5.1 Central Composite Design (CCD)


Verrebbe automatico **estendere** un PF da 2^2 a 2^3 per valutare gli effetti quadratici

In questo modo, però, la **sensibilità** nelle direzioni assiali sarebbe inferiore alla sensibilità nelle direzioni diagonali, essendo l'intervallo di valutazione più piccolo nel primo caso


Si preferisce quindi eseguire PF centrati con **simmetria rotazionale attorno all'origine**

Per due fattori, i punti assiali sono estesi a distanza $\sqrt{2}$ dall'origine; nel generico caso n -dimensionale la distanza è $(2^n)^{1/4}$

5.1.1 Due fattori



5.1.2 Tre fattori




5.2 Piani fattoriali frazionati (FFP)

Supponiamo di considerare **soltanto** i vertici opposti del PF in figura: $(1), ab, ac, bc$

Stiamo considerando **metà del PF originale**, che comunque include tutti i livelli dei tre fattori

Sicuramente il frazionamento riduce la completezza del modello, ma consente di risparmiare molti test

- Come scegliere il frazionamento per dimensioni superiori?
- Quali informazioni perdiamo?



5.3 Scegliere il frazionamento: relazioni definenti

Osservando la **matrice degli effetti**, osserviamo che i trattamenti (1), ab , ac , bc corrispondono alle righe per cui vale la relazione $I = -ABC$. L'altra metà complementare corrisponde invece a $I = ABC$

Queste relazioni sono chiamate **relazioni definenti** perché definiscono il PFF. È indifferente scegliere la metà positiva o quella negativa

```
dm %>%
  knitr::kable(align=c("l", rep("c", 8)))
```

trattamento	I	A	B	AB	C	AC	BC	ABC
(1)	+	-	-	+	-	+	+	-
a	+	+	-	-	-	-	+	+
b	+	-	+	-	-	+	-	+
ab	+	+	+	+	-	-	-	-
c	+	-	-	+	+	-	-	+

trattamento	I	A	B	AB	C	AC	BC	ABC
ac	+	+	-	-	+	+	-	-
bc	+	-	+	-	+	-	+	-
abc	+	+	+	+	+	+	+	+

5.4 *Alias* e informazioni perdute

In un PF frazionato 2^{3-1} con relazione definente $I = ABC$, consideriamo questi effetti:

$$A = (-1 + a - b + ab - c + ac - bc + abc)/(2r)$$

$$BC = (+1 + a - b - ab - c - ac + bc + abc)/(2r)$$

Siccome i trattamenti sottolineati **non sono testati**, l'effetto A risulta indistinguibile dall'effetto BC

Si dice che A è in *alias* con BC

Data una certa relazione definente, le possibili strutture di alias possono essere ricavate dalla relazione stessa mediante un'algebra dedicata: $I \cdot X = X$, $X \cdot X = X$, $X \cdot Y = XY$.

Quindi, risulta $A \cdot I = A \cdot ABC$ cioè $A = BC$, e altrettanto $B = AC$ e $C = AB$.

5.5 *Alias* e informazioni perdute

Quindi, frazionando un PF si perdono informazioni: si perde la capacità di discriminare tra gli effetti in *alias*. È evidente che più lunga è la relazione definente, più elevato sarà il grado di interazioni in alias con gli effetti diretti (es. $A = BCDEF$)

In virtù del **principio di sparsità degli effetti**, tuttavia, questa perdita di informazioni non è drammatica. Il **principio** dice che in un processo la significatività di interazioni di alto livello è via via meno probabile all'aumentare del numro di fattori che le compongono

La matrice degli effetti per un PF frazionato 2^{n-1} più la relazione definente individuano univocamente un piano fattoriale frazionato

Di conseguenza, un alias $A = BCDEF$ può essere trascurato assumendo la significatività di A piuttosto che quella di $BCDEF$ in virtù del PSdE

5.6 PF Frazionati di tipo 2^{n-p}

È possibile frazionare un piano più di una volta, riducendo il numero di trattamenti a 2^{n-p}

Per ogni frazionamento è necessario scegliere una nuova relazione definente

Ad esempio, per 2^{7-2} si possono scegliere le RD $I = ABCDE$ e $I = CDEFG$

Per queste due RD ne esiste una terza, dipendente: $I = ABFG$.
Due qualsiasi di queste tre RD sono equivalenti

5.6.1 Minimum aberration design

- Si generano tutte le possibili p -uple di relazioni definenti, completandole con la dipendente
- Si conta il numero di lettere nelle $(p + 1)$ -uple (es. precedente: $\langle 5, 5, 4 \rangle$)
- il *design* che minimizza il numero di stringhe con lunghezza minima è da preferire perché **ha meno alias**

6 Raccomandazioni finali

È molto comune assistere a DoE applicati solo parzialmente...

6.1 Per fare un buon PF

- Iniziare con un 2^n per poi aumentarlo
- Valutare l'opportunità di frazionamento e scegliere con attenzione le relazioni definenti
- Eseguire **sempre** la verifica di adeguatezza del modello e raffinare il modello statistico di conseguenza

- Discutere le interazione e gli effetti **solo dopo aver raffinato il modello**
- Valutare gli effetti di *alias*

6.1.1 Temi avanzati

- *Blocking*
- *Minimum Aberration Design*
- Trasformazioni del modello e trasformazioni Box-Cox