

# Serie Temporal

Analisi Dati e Statistica, 2026–27



Paolo Bosetti

*Ultimo aggiornamento: 27/09/2026*

## Indice

|          |                                   |           |
|----------|-----------------------------------|-----------|
| <b>1</b> | <b>Link alle slide</b>            | <b>4</b>  |
| <b>2</b> | <b>Serie Temporal</b>             | <b>4</b>  |
| 2.1      | Statistica delle serie temporal   | 4         |
| 2.2      | Statistica delle serie temporal   | 5         |
| 2.3      | Autocovarianza e autocorrelazione | 6         |
| 2.4      | Autocorrelazione                  | 7         |
| 2.5      | Autocorrelogramma (ACF)           | 7         |
| 2.6      | Autocorrelogramma (ACF)           | 8         |
| 2.7      | Autocorrelogramma (ACF)           | 10        |
| 2.8      | Serie temporal stazionarie        | 11        |
| 2.9      | Stabilizzazione                   | 12        |
| 2.10     | Stabilizzazione (esempio)         | 12        |
| 2.11     | Operatori di differenziazione     | 14        |
| 2.12     | Stabilizzazione e ACF             | 14        |
| 2.13     | Stabilizzazione e ACF             | 15        |
| <b>3</b> | <b>Modelli statistici</b>         | <b>16</b> |
| 3.1      | Modelli AR — definizione          | 16        |
| 3.2      | Modelli AR — regressione          | 17        |
| 3.3      | Modelli MA — definizione          | 17        |
| 3.4      | Modelli MA — regressione          | 18        |
| 3.5      | Modelli MA e ACF                  | 18        |
| 3.6      | Modelli MA e ACF                  | 19        |

|          |                                 |           |
|----------|---------------------------------|-----------|
| 3.7      | Modelli AR e PACF               | 20        |
| 3.8      | Modelli AR e PACF               | 20        |
| 3.9      | Modelli MA e PACF               | 21        |
| 3.10     | Modelli ARMA                    | 22        |
| 3.11     | Modelli MA e PACF               | 23        |
| 3.12     | Modelli ARIMA                   | 23        |
| 3.13     | Stabilità e unicità dei modelli | 24        |
| 3.14     | Stabilità e unicità dei modelli | 24        |
| 3.15     | Stabilità e unicità dei modelli | 25        |
| 3.16     | Ridondanza                      | 26        |
| 3.17     | Ridondanza                      | 26        |
| 3.18     | Ridondanza                      | 27        |
| 3.19     | Regressione (S)ARIMA            | 27        |
| 3.20     | Regressione (S)ARIMA            | 28        |
| 3.21     | Akaike Information Criterion    | 28        |
| 3.22     | Altri criteri di informazione   | 29        |
| 3.23     | Regressione                     | 29        |
| 3.24     | Previsione                      | 31        |
| <b>4</b> | <b>Predizione</b>               | <b>32</b> |
| <b>5</b> | <b>Dettaglio</b>                | <b>32</b> |

```
options(width = 60)
set.seed(0)
library(latex2exp)
library(ggpubr)
```

Loading required package: ggplot2

```
library(glue)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ---- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v lubridate  1.9.5      v tibble     3.3.1
v purrr      1.2.2      v tidyr      1.3.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag() masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(ggfortify)
library(modelr)
library(tsbbox)
library(xts)
```

Loading required package: zoo

Attaching package: 'zoo'

The following objects are masked from 'package:base':

as.Date, as.Date.numeric

```
##### Warning from 'xts' package #####
#
# The dplyr lag() function breaks how base R's lag() function is supposed to #
# work, which breaks lag(my_xts). Calls to lag(my_xts) that you type or #
# source() into this session won't work correctly. #
#
# Use stats::lag() to make sure you're not using dplyr::lag(), or you can add #
# conflictRules('dplyr', exclude = 'lag') to your .Rprofile to stop #
# dplyr from breaking base R's lag() function. #
#
# Code in packages is not affected. It's protected by R's namespace mechanism #
# Set `options(xts.warn_dplyr_breaks_lag = FALSE)` to suppress this warning. #
#
#####
```

Attaching package: 'xts'

The following objects are masked from 'package:dplyr':

first, last

```
library(astsa)
library(patchwork)
theme_set(theme_gray()+theme(legend.position = "bottom"))
```

## 1 Link alle slide



## 2 Serie Temporalì

Una **serie temporale** è costituita da una serie di osservazioni di una variabile aleatoria tale per cui l'influenza di un'osservazione sulle seguenti non possa essere trascurata e—quindi—tale che la dipendenza dal tempo risulti essenziale

### 2.1 Statistica delle serie temporali

Tutti i metodi di regressione visti fin ora sono basati sull'assunzione che la variabile aleatoria sia  $x \stackrel{IID}{\sim} \mathcal{N}(\mu, \sigma^2)$ . Cioè tutte le osservazioni **devono essere non-autocorrelate**

Quest'assunzione è, tra l'altro, alla base della raccomandazione di casualizzazione della sequenza operativa

Supponiamo di poter considerare una misura come un segnale tempo-dipendente. È evidente che riducendo l'intervallo di campionamento del segnale prima o poi ogni campione sarà correlato al precedente

Esiste quindi una **frequenza di campionamento massima** al di sopra della quale ogni misura risulta essere autocorrelata, cioè le osservazioni di  $x$  non sono più IID

Questa situazione sussiste quando la **dinamica** propria dello strumento di misura o del misurando stesso—che sono **sempre finite**—sono più lente dell’intervallo temporale in cui si effettuano le misure


## 2.2 Statistica delle serie temporali

Consideriamo ad esempio la serie temporale in figura che riporta la differenza tra la temperatura media delle terre emerse e il corrispondente valore medio nel periodo 1951–1980

È evidente che osservazioni vicine sono più correlate di osservazioni lontane

Inoltre è evidente (**ed è di interesse**) valutare la dipendenza della v.a. considerata dal tempo allo scopo di **effettuare delle previsioni future**

```
ts <- ts_xts(gtemp_land)
ref <- ts["1951/1980"]
ggplot(ts, aes(x=Index, y=value)) +
  geom_line(color=gray(0.5)) +
  geom_line(data=ref, aes(y=value, color="Periodo di riferimento"), linewidth=1) +
  # geom_point(shape=4) +
  geom_hline(yintercept=0, linetype=2) +
  scale_x_date(breaks="20 years", date_labels = "%Y") +
  labs(x="anno", y="Anomalia termica terre emerse (°C)", color="") +
  theme(legend.position = "bottom")
```



## 2.3 Autocovarianza e autocorrelazione

Abbiamo visto come gli operatori **covarianza** e **correlazione** servano a stimare l'indipendenza di due campioni

Considerando un segnale tempo-dipendente  $x = x(t)$ , è interessante considerare la covarianza del segnale con se stesso, traslato nel tempo

Definiamo la **funzione autocovarianza**  $\gamma(s, t)$  come la funzione che valuta la covarianza di un segnale temporale con se stesso valutato **iniziando** ai tempi  $s$  e  $t$ :

$$\gamma_x(s, t) = \sigma_{x_s, x_t} = E[(x_s - \mu_s)(x_t - \mu_t)]$$

È evidente che  $\gamma_x(s, s) = \sigma^2(x_s)$

La **funzione di autocorrelazione** (ACF), di conseguenza, è definita come:

$$\rho_x(s, t) = \frac{\gamma_x(s, t)}{\sqrt{\gamma_x(s, s)\gamma_x(t, t)}}$$

ed ha il vantaggio di essere sempre compresa in  $[-1, 1]$ . È inoltre evidente che  $\rho_x(s, s) = 1$

## 2.4 Autocorrelazione

Se campioniamo un segnale continuo a intervalli fissi  $\Delta t$  per una durata complessiva  $T$ , otteniamo una **serie temporale finita** di  $N = T/\Delta t$  osservazioni:  $x_0 = \langle x_1, x_2, \dots, x_N \rangle$

Possiamo estendere la definizione stabilendo che sia  $s = t_0 = 0$  l'istante iniziale della serie e che sia  $t = s + \tau$  un generico momento successivo tale per cui

$$\tau = \ell \Delta t$$

dove  $\ell$  è il ritardo o *lag*, e allora l'**autocovarianza** e l'**autocorrelazione per una s.t. finita** risultano:

$$\gamma_x(\ell) = \frac{\sum_{i=1}^{N-\ell} (x_i - \bar{x}_0)(x_{i+\ell} - \bar{x}_\ell)}{N - \ell - 2}, \quad \rho_x(\ell) = \frac{\gamma_x(\ell)}{\sqrt{\sigma_x(0)\sigma_x(\ell)}}$$

dove


$$\bar{x}_0 = \frac{1}{N - \ell} \sum_{i=1}^{N-\ell} x_i, \quad \bar{x}_\ell = \frac{1}{N - \ell} \sum_{i=\ell}^N x_i$$

## 2.5 Autocorrelogramma (ACF)

```
ell <- 10
c <- ts_xts(chicken) %>% diff() %>% fortify() %>% mutate(i=1:n(), .before=Index) %>% filter(!is.na(value))

ps <- ggplot(c[ell:length(c$i),]) +
  geom_line(aes(x=i, y=value)) +
  geom_line(data=c[1:ell,], aes(x=i, y=value), color=gray(2/3), linetype=2) +
  coord_cartesian(xlim=range(c$i)) +
  theme(axis.title.x = element_blank(), axis.text.x = element_blank()) +
  labs(y="valore")
pt <- ggplot(lag(c, ell)) +
  geom_line(aes(x=i+ell, y=value)) +
  coord_cartesian(xlim=range(c$i)) +
  labs(x="indice", y="valore")
ggarrange(ps, pt, nrow=2, heights=c(1,1.08))
```

Warning: Removed 10 rows containing missing values or values outside the scale range (`geom\_line()`).



Per costruire il grafico ACF di una s.t. si trasla l'ascissa di  $\ell$  campioni trascurando i primi  $\ell$  campioni nella s.t. non traslata e gli ultimi  $\ell$  campioni in quella traslata

Poi si calcola l'autocorrelazione tra le due serie

Il processo viene ripetuto per  $\ell = 0, 1, \dots, n$ , con  $n$  scelto in funzione della dimensione della serie, tipicamente pari ad almeno 50 e comunque non oltre la metà della lunghezza della s.t.

## 2.6 Autocorrelogramma (ACF)


La **funzione di autocorrelazione**  $\rho_x(\ell)$  che è una funzione **a valori discreti**, può essere messa in grafico per studiare il *lag* massimo al di sopra del quale la serie storica  $x$  non è più autocorrelata

In figura il segnale di un microfono che registra il suono “AAHH”. La serie è **evidentemente periodica** ogni 0.01 s

L'autocorrelogramma mostra **autocorrelazione elevata** fino a  $\ell = 4$ . Poi l'andamento è **periodico**, a confermare che la s.t. è autocorrelata con se stessa ogni circa 10 lag


### 2.6.1 Serie storica

```
s <- ts_data.frame(speech) %>% slice(seq(1,n(),by=1)) %>%  
  mutate(time=seq_along(time)/10000)  
s %>%  
ggplot(aes(x=time, y=value)) +  
  geom_line() +  
  labs(x="tempo (s)", y="tensione (mV)")
```



### 2.6.2 ACF

```
with(acf(s$value, lag.max = 100, plot=F), data.frame(lag, acf)) %>%  
  ggplot(aes(x=lag, y=acf)) +  
  geom_hline(aes(yintercept=0)) +  
  geom_hline(yintercept=c(-1,1)*qnorm((1 + 0.95)/2)/sqrt(1020),  
            linetype=2, color="blue") +  
  geom_segment(mapping = aes(xend = lag, yend = 0)) +  
  labs(x="lag", y=TeX("\rho_x"))
```



## 2.7 Autocorrelogramma (ACF)

Consideriamo gli stessi dati della s.t. precedente, ma campionati in istanti casuali

Allora  $y \stackrel{IID}{\sim} \mathcal{N}(\mu, \sigma^2)$  e quindi  $\rho_y(\ell) = 0 \ \forall \ell > 0$


Come atteso, l'unico valore della ACF fuori dall'intervallo di confidenza è  $\rho_x(0)$

In questo caso si dice anche che la s.t. è un *random walk*

**ACF** sta per *Auto-Correlation Function*; la banda evidenziata in blu è l'intervallo di confidenza al 95%. Inoltre, in generale vale sempre  $\rho_x(0) = 1$


### 2.7.1 Serie storica

```
s <- s %>% mutate(value = sample(value))
s %>%
  ggplot(aes(x=time, y=value)) +
    geom_line() +
    labs(x="tempo", y="tensione (mV)")
```



## 2.7.2 ACF

```
with(acf(s$value, lag.max = 100, plot=F), data.frame(lag, acf)) %>%
  ggplot(aes(x=lag, y=acf)) +
  geom_hline(aes(yintercept=0)) +
  geom_hline(yintercept=c(-1,1)*qnorm((1 + 0.95)/2)/sqrt(1020),
            linetype=2, color="blue") +
  geom_segment(mapping = aes(xend = lag, yend = 0)) +
  labs(x="lag", y=TeX("$\\rho_x$"))
```



## 2.8 Serie temporali stazionarie

Una s.t. può essere stazionaria o meno. Si definiscono:

**Serie temporale stazionaria in senso ampio** È una serie temporale per cui il comportamento probabilistico di una qualsiasi collezione di valori  $\langle x_{t_1}, x_{t_2}, \dots, x_{t_k} \rangle$  è identico a quello della collezione traslata  $\langle x_{t_1+h}, x_{t_2+h}, \dots, x_{t_k+h} \rangle$ , cioè:

$$\Pr(x_{t_1} \leq c_1, \dots, x_{t_k} \leq c_k) = \Pr(x_{t_1+h} \leq c_1, \dots, x_{t_k+h} \leq c_k).$$

**Serie temporale stazionaria in senso stretto** È una serie temporale per cui il valor medio della serie temporale è costante (tempo-indipendente) e la funzione di autocovarianza  $\gamma(s, t)$  dipende da  $s$  e  $t$  solo tramite la loro differenza  $|s - t|$

Per una **serie stazionaria in senso ampio** si può assumere  $\sigma_x(0) = \sigma_x(\ell) = \sigma_x$  e  $\bar{x}_0 = \bar{x}_\ell$  e, quindi,  $\rho_x(\ell) = \gamma_x(\ell)/\sigma_x$

## 2.9 Stabilizzazione

- Le ST stazionarie almeno in senso ampio sono più semplici da trattare
- È quindi utile cercare di **stabilizzare** la ST separandola in un termine di **tendenza** (*trend*)  $x_t$  più un termine **stazionario**  $x_s$
- la stabilizzazione può essere fatta in due modi:
  - *detrending* mediante regressione lineare:  $x_t = x_{l,t} + x_{s,t}$ , dove  $x_{l,t} = a + bt$  e, quindi,  $x_{s,t}$  risulta essere la **serie dei residui** della regressione lineare di  $x_t$
  - *detrending* per differenziazione
- La ST stabilizzata può poi essere analizzata e quindi trasformata mediante l'operazione inversa:
  - somma del termine di tendenza
  - integrazione (cioè somma cumulativa)

## 2.10 Stabilizzazione (esempio)

```

m <- lm(chicken~time(chicken))
f <- xts(data.frame(
  line = predict(m),
  res = residuals(m)
), order.by=as.Date(time(chicken)))
p1 <- ggplot(ts_xts(chicken)) +
  geom_line(aes(x=Index, y=value)) +
  geom_line(aes(x=Index, y=line), data=f, col="blue") +
  labs(title="Prezzo di un pollo intero in Georgia (US)", x="data", y="prezzo ($)")


p2 <- ggplot(f) +
  geom_hline(yintercept = 0, color="blue") +
  geom_line(aes(x=Index, y=res)) +
  labs(title="De-trend lineare", x="data", y="prezzo ($)")

p3 <- ggplot(diff(ts_xts(chicken))) +
  geom_hline(yintercept = 0, color="blue") +
  geom_line(aes(x=Index, y=value)) +
  labs(title="De-trend per differenziazione", x="data", y="prezzo ($)")

p1 / (p2 + p3)

```

Warning: Removed 1 row containing missing values or values outside the scale range (`geom\_line()`).



## 2.11 Operatori di differenziazione

In generale, la stabilizzazione per differenziazione dà risultati migliori ed è anche più pratica: se la ST differenziata non è stabile, è possibile aumentare l'ordine di differenziazione fino a raggiungere la stabilità

Come si differenzia una ST?

Si definiscono:

- **Operatore *backshift*:** è l'operatore  $B^n$  tale per cui  $B^n x_t := x_{t-n}$
- **Operatore differenza:** è l'operatore  $\nabla$  tale per cui  $\nabla x_t := x_t - x_{t-1} = (1 - B)x_t$ . Risulta quindi che  $\nabla^d x_t = (1 - B)^d x_t$ , e quindi ad esempio  $\nabla^2 x_t = (1 - B)^2 x_t = x_t - 2x_{t-1} + x_{t-2}$

Quindi ad esempio la differenziazione  $\nabla^2 x_t$  è l'equivalente discreto della derivata seconda  $\frac{d^2}{dt^2}x(t)$  per la funzione continua  $x(t)$


## 2.12 Stabilizzazione e ACF

```
p1 <- with(acf(as.numeric(chicken), lag.max = 50, plot=F), data.frame(lag, acf)) %>%
  ggplot(aes(x=lag, y=acf)) +
  geom_hline(aes(yintercept=0)) +
  geom_hline(yintercept=c(-1,1)*qnorm((1 + 0.95)/2)/sqrt(1020),
            linetype=2, color="blue") +
  geom_segment(mapping = aes(xend = lag, yend = 0)) +
  labs(title="ACF ST prezzo del pollo", x="lag", y=TeX("$\\rho_x$"))

p2 <- with(acf(f$res, lag.max = 50, plot=F), data.frame(lag, acf)) %>%
  ggplot(aes(x=lag, y=acf)) +
  geom_hline(aes(yintercept=0)) +
  geom_hline(yintercept=c(-1,1)*qnorm((1 + 0.95)/2)/sqrt(1020),
            linetype=2, color="blue") +
  geom_segment(mapping = aes(xend = lag, yend = 0)) +
  labs(title="ACF de-trend lineare", x="lag", y=TeX("$\\rho_x$"))
```

```
p3 <- with(acf(diff(chicken), lag.max = 50, plot=F), data.frame(lag=1:51, acf)) %>%
  ggplot(aes(x=lag, y=acf)) +
  geom_hline(aes(yintercept=0)) +
  geom_hline(yintercept=c(-1,1)*qnorm((1 + 0.95)/2)/sqrt(1020),
            linetype=2, color="blue") +
  geom_segment(mapping = aes(xend = lag, yend = 0)) +
  labs(title="ACF ST differenziata", x="lag", y=TeX("$\\rho_x$"))


p1 / (p2 + p3)
```



## 2.13 Stabilizzazione e ACF

- La ACF di una serie non stabilizzata mostra sempre una correlazione anche a *lag* elevati
- La ACF della serie dei residui di una regressione lineare decresce più rapidamente, ma mantiene comunque una correlazione anche a *lag* elevati
- La ACF della serie differenziata, inoltre, si smorza molto rapidamente (i *lag* 1, 2, 3, ... dovrebbero essere esponenziali), dopodiché mostra oscillazioni armoniche, indice di una **periodicità** nella ST originale

p3



### 3 Modelli statistici

La regressione classica applicata alle serie temporali è **spesso insufficiente**. Ad esempio, nel caso del prezzo del pollo l'analisi della autocorrelazione mostra un comportamento ciclico che la regressione classica non riesce ad evidenziare

È quindi necessario sviluppare delle tecniche che consentano di modellare i dettagli di una serie temporale, in particolare tenendo in considerazione anche **l'autocorrelazione** che può caratterizzare le serie temporali

Possiamo quindi dire che la serie storica del prezzo del pollo mostra un *trend* che si **stabilizza al primo ordine** di differenziazione, ha una dinamica che mostra **autocorrelazione fino ai tre punti precedenti**, e un andamento **periodico** con periodo pari a 12 *lag*.

#### 3.1 Modelli AR — definizione

Un modello Auto-Regressivo (AR) esprime una determinata osservazione  $x_t$  al tempo  $t$  come combinazione lineare di  $p$  valori precedenti  $x_{t-1}, x_{t-2}, \dots, x_{t-p}$ . Un modello AR di ordine  $p$ , abbreviato in  $AR(p)$ , ha la forma:

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + w_t$$

- $x_t$  è stazionaria in senso ampio e  $w_t \sim \mathcal{N}(0, \sigma_w^2)$
- $\phi_1, \phi_2, \dots, \phi_p$  sono costanti e  $\phi_p \neq 0$

Se la media di  $x_t$  non è nulla, si sostituisce  $x_t$  con  $x_t - \mu$  per ottenere:

$$x_t - \mu = \phi_1(x_{t-1} - \mu) + \phi_2(x_{t-2} - \mu) + \dots + \phi_p(x_{t-p} - \mu) + w_t \quad (1)$$

$$x_t = \alpha + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + w_t, \quad \alpha = \mu(1 - \phi_1 - \phi_2 - \dots - \phi_p) \quad (2)$$

Le  $w_t$  sono anche chiamate **innovazioni**, dato che sono l'unico contributo **nuovo** di un punto rispetto ai precedenti.

### 3.2 Modelli AR — regressione

Ricordando la definizione dell'**operatore backshift**, la definizione di  $w_t$  può essere scritta come:

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)x_t = w_t$$

o ancora più concisamente come:

$$\Phi_p(B)x_t = w_t$$

dove  $\Phi_p(B) := 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$  è detto **operatore autoregressivo**.

Effettuare la regressione di un modello  $AR(p)$  su una serie storica  $x_t$  significa quindi adattare il modello  $\Phi_p(B)\hat{x}_t = w_t$  identificando i coefficienti di  $\Phi_p(B)$  che minimizzano i residui quadratici medi, essendo i residui  $\varepsilon_t = x_t - \hat{x}_t = x_t - \Phi_p^{-1}(B)w_t$  (ammesso che esista l'inversa  $\Phi_p^{-1}(B)$ ).

### 3.3 Modelli MA — definizione

Alternativamente, è possibile immaginare il caso in cui la generica osservazione  $x_t$  è espressa come combinazione lineare **del disturbo** agente sulle  $q$  osservazioni precedenti. Un modello MA di ordine  $q$ , abbreviato come  $MA(q)$  è definito come

$$x_t = w_t + \theta_1 w_{t-1} + \theta_2 w_{t-2} + \dots + \theta_q w_{t-q}$$

- $w_t \sim \mathcal{N}(0, \sigma_w^2)$
- $\theta_1, \theta_2, \dots, \theta_q$  sono parametri costanti con  $\theta_q \neq 0$

### 3.4 Modelli MA — regressione

Analogamente al caso  $AR(p)$ , per  $MA(q)$  è possibile definire l'**operatore media mobile** di ordine  $q$ :

$$\Theta_q(B) = (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)$$

tale per cui la equazione per  $x_t$  può essere scritta come:

$$x_t = \Theta_q(B)w_t$$

Come sopra, regredire un modello  $MA(q)$  ad una serie storica  $x_t$  significa identificare i termini di  $\Theta_q(B)$  che minimizzano i residui quadratici medi, definiti come  $\varepsilon_t = x_t - \hat{x}_t = x_t - \Theta_q(B)$  (si noti che questa volta non c'è l'inversa!)

### 3.5 Modelli MA e ACF


```
set.seed(0)
tsma <- arima.sim(model=list(ma=c(-0.5, 0.7, -0.75)), n=200)
```

Una ST  $MA(q)$  ha una memoria che si estende fino al *lag*  $q$ , nel senso che le innovazioni a distanze superiori a  $q$  non hanno alcun effetto sull'ultima osservazione

Quindi, data una serie temporale di tipo  $MA(q)$  si può spesso identificare l'ordine dalla sua ACF, contando i picchi dopo quello a *lag* 0:

- tre picchi fuori dalla banda di confidenza significano un modello  $MA(3)$
- i segni dei picchi corrispondono ai segni dei coefficienti

```
autoplot(tsma, xlab="#", ylab="valore") /
(acf(tsma, plot=F)) +
  geom_hline(yintercept=0)
```




### 3.6 Modelli MA e ACF

```
set.seed(0)
tsar <- arima.sim(model=list(ar=c(0.5, 0.3)), n=200)
```

Se invece la serie temporale è di tipo  $AR(p)$ , ogni osservazione dipende dall'innovazione e da tutte le osservazioni precedenti, in modo ricorsivo

In questo caso l'autocorrelogramma riporterà un decadimento esponenziale seguito eventualmente da oscillazioni armoniche

```
autoplot(tsar, xlab="#", ylab="valore") /
(acf(tsar, plot=F)) +
  geom_hline(yintercept=0)
```



### 3.7 Modelli AR e PACF

Per i modelli di tipo  $AR(p)$  è comunque possibile identificare l'ordine mediante la **funzione di autocorrelazione parziale** o PACF, così definita:

$$PACF_1 = ACF(z_{t+1}, z_t) \quad (3)$$

$$PACF_k = ACF(z_{t+k} - \hat{z}_{t+k}, z_t - \hat{z}_t), \quad k \geq 2 \quad (4)$$

$$(5)$$

in cui  $\hat{z}_{t+k}$  e  $\hat{z}_t$  sono combinazioni lineari di  $\{z_{t+1}, z_{t+2}, \dots, z_{t+k-1}\}$  che minimizzano l'errore quadratico medio di  $z_{t+k}$  e  $z_t$ , rispettivamente

### 3.8 Modelli AR e PACF


In generale, quindi, se la ACF mostra una memoria infinita (modello AR) e la PACF mostra pochi picchi, il numero di picchi è l'ordine del modello AR

**Attenzione:** non si considerano i picchi dopo il primo *cut-off*, cioè il *lag* in corrispondenza del quale l'autocorrelazione scende sotto il limite di confidenza per la prima volta

```
forecast::ggtsdisplay(tsar, main="Serie AR")
```

Registered S3 methods overwritten by 'forecast':

| method                 | from      |
|------------------------|-----------|
| autoplot.Arima         | ggfortify |
| autoplot.acf           | ggfortify |
| autoplot.ar            | ggfortify |
| autoplot.bats          | ggfortify |
| autoplot.decomposed.ts | ggfortify |
| autoplot.ets           | ggfortify |
| autoplot.forecast      | ggfortify |
| autoplot.stl           | ggfortify |
| autoplot.ts            | ggfortify |
| fitted.ar              | ggfortify |
| fortify.ts             | ggfortify |
| residuals.ar           | ggfortify |



**Attenzione:** in questi grafici ACF e PACF il *lag* comincia da 1!


### 3.9 Modelli MA e PACF

Confrontando sia ACF che PACF

- puro rumore: ACF e PACF sono nulle per *lag* maggiore di 0

- $AR(p)$ : ACF decresce lentamente, PACF non-nulla per  $lag$  minori o uguali a  $p$ , nulla altrimenti
- $MA(q)$ : ACF mostra  $q$  picchi; se  $PACF(1) > 0$ , PACF oscilla a 0, altrimenti decade geometricamente a 0

```
forecast::ggtsdisplay(tsma, main="Serie MA")
```



### 3.10 Modelli ARMA

L'ovvia estensione risulta dalla combinazione dei modelli  $AR(p)$  e  $MA(q)$

Un modello ARMA di ordine  $p, q$ , abbreviato come  $ARMA(p, q)$  è definito come:

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + w_t + \theta_1 w_{t-1} + \theta_2 w_{t-2} + \dots + \theta_q w_{t-q}$$

con  $\phi_p$  e  $\theta_q$  non nulli, ovvero, più brevemente:

$$\Phi_p(B)x_t = \Theta_q(B)w_t$$


Spesso, in pratica queste indicazioni sono difficili da riscontrare ed è quindi difficile individuare  $p, q$  in maniera certa e univoca

### 3.11 Modelli MA e PACF

Confrontando sia ACF che PACF

- puro rumore: ACF e PACF sono nulle per  $lag$  maggiore di 0
- $AR(p)$ : ACF decresce lentamente, PACF non-nulla per  $lag$  minori o uguali a  $p$ , nulla altrimenti
- $MA(q)$ : ACF mostra  $q$  picchi; se  $PACF(1) > 0$ , PACF oscilla a 0, altrimenti decade geometricamente a 0
- $ARMA(p, q)$ : ACF mostra  $q$  picchi; PACF decade geometricamente a 0 solo dopo  $lag p$

```
forecast::ggtsdisplay(tsma, main="Serie MA")
```



### 3.12 Modelli ARIMA

I processi  $ARMA(p, q)$  sono adatti solo a descrivere serie **stazionarie** in senso ampio

Abbiamo visto però che un processo non stazionario può essere reso tale per differenziazione di un opportuno grado  $d$

Un processo  $x_t$  è detto  $ARIMA(p, d, q)$  quando  $\nabla^d x_t = (1 - B)^d x_t$  2è un processo  $ARMA(p, q)$

Spesso, in pratica queste indicazioni sono difficili da riscontrare ed è quindi difficile individuare  $p, q$  in maniera certa e univoca

In generale, quando  $E(\nabla^d x_t) = 0$  il processo  $\text{ARIMA}(p, d, q)$  può essere scritto come:

$$\Phi_p(B)\nabla^d x_t = \Theta_q(B)w_t$$

Se invece il valore atteso  $E(\nabla^d x_t) = \mu$ , allora:

$$\Phi_p(B)\nabla^d x_t = \delta + \Theta_q(B)w_t, \quad \delta = \mu(1 - \phi_1 - \dots - \phi_p)$$

### 3.13 Stabilità e unicità dei modelli

Consideriamo un modello  $\text{AR}(1)$ : possiamo sviluppare la formula ricorsiva come:

$$x_t = \phi x_{t-1} + w_t = \phi(\phi x_{t-2} + w_{t-1}) + w_t \quad (6)$$

$$= \sum_{j=0}^{+\infty} \phi^j w_{t-j} \quad (7)$$

È quindi evidente che la serie temporale  $x_t$  è **stabile solo se**  $|\phi| < 1$

Nel caso generale del modello  $\text{AR}(p)$ , si ha la condizione di stabilità:

$$\left| \sum_{i=1}^p \phi_i \right| < 1$$

Un modello  $\text{AR}$  non stabile è detto anche **anti-causale**, perché si può dimostrare che per essere stabilizzato richiede la conoscenza delle osservazioni future

### 3.14 Stabilità e unicità dei modelli

Per un modello  $\text{MA}(1)$ , invece, consideriamo due modelli:

$$x_t = w_t + \theta w_{t-1}, \quad w_t \sim \mathcal{N}(0, 1) \quad (8)$$

$$y_t = \nu_t + 1/\theta \nu_{t-1}, \quad \nu_t \sim \mathcal{N}(0, \theta^2) \quad (9)$$

È evidente che  $x_t$  e  $\nu_t$  hanno la stessa ACF e sono indistinguibili, dato che noi non conosciamo le innovazioni  $w_t$  e  $\nu_t$  ma solo le due serie. Si può dimostrare che il risultato è generale (cioè non dipende dell'ordine  $q$ ).

È quindi necessario scegliere una delle due forme alternative. Per individuare quale, riscriviamo la serie come  $w_t = -\theta x_{t-1} + x_t$ , che ha la stessa forma della AR(1). Possiamo quindi scegliere l'alternativa che rispetta lo stesso criterio di *stabilità*:

$$\left| \sum_{i=1}^q \theta_i \right| < 1$$

Tale alternativa si dice **invertibile**

### 3.15 Stabilità e unicità dei modelli

In generale, si può dimostrare che i criteri visti sopra corrispondono a imporre il requisito che le radici complesse dei polinomi

$$\Phi_p(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p \quad (10)$$

$$\Theta_q(z) = 1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q \quad (11)$$

siano **tutte strettamente fuori dal cerchio unitario** sul piano complesso

Ad esempio: ARMA(2, 2) con  $\Phi_2(z) = 1 + 0.9z + 0.1z^2$  e  $\Theta_q(z) = 1 + 2z + 15z^2$ :

```
abs(polyroot(c(1, -0.9, -0.1)))
```

```
[1] 1 10
```

```
abs(polyroot(c(1, 2, 15)))
```

```
[1] 0.2581989 0.2581989
```

Cioè il termine AR non è causale e il termine MA non è invertibile (ma lo sarebbe  $\theta_q(z) = 1 + 1/2z + 1/15z^2$ )

### 3.16 Ridondanza

Consideriamo il processo  $x_t = w_t$ , con  $w_t \sim \mathcal{N}(0, 1)$ : si tratta ovviamente di puro rumore casuale

Moltiplichiamo entrambi i lati per  $1 - 0.5B$  per ottenere:

$$x_t = 0.5x_{t-1} - 0.5w_{t-1} + w_t$$

che **sembra** un processo ARMA(1, 1) ma ovviamente è sempre lo stesso rumore casuale. **Come distinguere questi casi?**

- si scompongono in fattori i polinomi  $\Phi_p$  e  $\Theta_q$
- si eliminano i **fattori comuni**
- si sicompongono i fattori per ottenere il **modello non ridondante**

In R si può ancora usare `polyroot()`

### 3.17 Ridondanza

Ad esempio, consideriamo il processo  $x_t = 0.4x_{t-1} + 0.45x_{t-2} + w_t + w_{t-1} + 0.25w_{t-2}$ , che usando l'operatore  $B$  diventa:

$$(1 - 0.4B - 0.45B^2)x_t = (1 + B + 0.25B^2)w_t.$$

In questa forma il processo sembra ARMA(2, 2), tuttavia possiamo scomporre i due polinomi in fattori, usando `polyroot()` per calcolare le radici:

```
# per Phi:  
-1/polyroot(c(1, -0.4, -0.45))
```

```
[1] -0.9-6.887768e-21i  0.5+2.125854e-21i
```

```
# per Theta:  
-1/polyroot(c(1, 1, 0.25))
```

```
[1] 0.5-5.551115e-17i 0.5+5.551115e-17i
```

**Nota:** se  $z_i$ ,  $i = 1, \dots, n$  sono le radici del polinomio  $p(z)$  di grado  $n$ , allora il polinomio può essere scomposto nei fattori  $(1 - 1/z_1 z) \cdot (1 - 1/z_2 z) \dots (1 - 1/z_n z)$ .

### 3.18 Ridondanza

Come si vede, si può scrivere

$$\Phi_p(B) = (1 - 0.9B)(1 + 0.5B) \quad (12)$$

$$\Theta_q(B) = (1 + 0.5B)^2 \quad (13)$$

Eliminando il fattore comune  $(1 + 0.5B)$  otteniamo il modello

$$x_t = 0.9x_{t-1} + 0.5w_{t-1} + w_t$$

che è un ARMA(1, 1).

Quindi ai criteri di **causalità** e di **invertibilità** si aggiunge il criterio di **non ridondanza** dei parametri, che si verifica eliminando ogni fattore comune dalla scomposizione in fattori dei polinomi  $\Phi_p(B)$  e  $\Theta_q(B)$ .

### 3.19 Regressione (S)ARIMA

Per quanto detto sopra, un processo, o serie temporale,  $x_t$  può essere regredita mediante un modello ARIMA identificandone i parametri per **minimizzazione degli scarti quadratici**

Tuttavia, prima della regressione è necessario definire gli indici  $p, d, q$  adeguati, tali che non si abbia **né sotto- né sovra-adattamento**

In certi casi, inoltre, le serie sono **periodiche**: oltre ad un possibile **trend** sono soggette anche a ciclici andamenti oscillanti. In questi casi:

- si rende la ST stazionaria per differenziazione
- si separa un contributo a bassa frequenza, chiamato **stagionale**, da un contributo ad alta frequenza
- si effettua separatamente la regressione del contributo stagionale e del contributo non stagionale come due processi ARIMA distinti e sovrapposti: tale regressione si chiama *Seasonal ARIMA* o **SARIMA**

### 3.20 Regressione (S)ARIMA

Inoltre, abbiamo visto che i modelli ARIMA si basano sull'ipotesi di serie temporali stazionarie in senso ampio

Quindi, è necessario che sia il **valor medio che la varianza siano costanti nel tempo**

- La media si stabilizza per differenziazione
- La varianza si può stabilizzare mediante **trasformazioni Box-Cox**

Quindi, nel caso più generale il modello è SARIMA( $p, d, q, p_s, d_s, q_s, \lambda$ )

**Prima di eseguire una regressione è quindi necessario definire i valori dei sette parametri, evitando sovra- e sotto-adattamento**

- $d, d_s$  possono essere identificati per tentativi, aumentando gradualmente i valori (prima di  $d$  e poi di  $d_s$ ) finché la ACF è soddisfacente
- gli altri termini possono essere individuati verificando la bontà della regressione su una griglia di combinazioni e valutando un opportuno **indice di merito**

### 3.21 Akaike Information Criterion

L'indice di merito più usato nella regressione SARIMA è l'**Akaike Information Criterion**, o AIC

In genere la qualità di una regressione con  $k$  parametri è misurata dalla somma quadratica dei residui,  $SS_E(k)$ , normalizzata per la dimensione del campione  $n$ :

$$\hat{\sigma}_k^2 = \frac{SS_E(k)}{n}$$

Questo indicatore si chiama **Maximum Likelihood Estimator** (MLE). Più questo valore è piccolo, meglio il modello si adatta ai dati

Tuttavia aumentando  $k$  si ha una diminuzione di MLE, a rischio di sovra-adattamento. Per questo motivo Akaike ha proposto di penalizzare MLE con il numero di parametri:

$$\text{AIC} = \log(\hat{\sigma}_k^2) + \frac{n+2k}{n}$$

L'AIC va ovviamente **minimizzato**

### 3.22 Altri criteri di informazione

Oltre all'AIC esistono anche l'AIC corretto e il *Bayesian Information Criterion*, o BIC:

- AIC corretto:  $\text{AIC}_c = \log(\hat{\sigma}_k^2) + \frac{n+k}{n-k-2}$
- BIC:  $\text{BIC} = \log(\hat{\sigma}_k^2) + \frac{k \log(n)}{n}$

Il BIC **penalizza maggiormente la dimensione del modello**, per cui è preferito per campioni molto grandi (migliaia di osservazioni), per i quali AIC e AICc tenderebbero a favorire modelli inutilmente complessi (troppi parametri, sovra-adattamento)

Come l'AIC, anche AICc e BIC vanno **minimizzati**

### 3.23 Regressione

La libreria R `forecast` fornisce la funzione `auto.arima()` che valuta gli indicatori su una griglia di combinazioni dei sette parametri e fornisce la regressione migliore:

```
forecast::auto.arima(AirPassengers, lambda="auto", trace=T)
```

```
ARIMA(2,1,2)(1,1,1)[12]      : Inf
ARIMA(0,1,0)(0,1,0)[12]      : -
845.0766
ARIMA(1,1,0)(1,1,0)[12]      : -
885.6939
ARIMA(0,1,1)(0,1,1)[12]      : -
896.9901
```

```

    ARIMA(0,1,1)(0,1,0)[12]          : -
860.1426
    ARIMA(0,1,1)(1,1,1)[12]          : -
895.2944
    ARIMA(0,1,1)(0,1,2)[12]          : -
895.3558
    ARIMA(0,1,1)(1,1,0)[12]          : -
889.5331
    ARIMA(0,1,1)(1,1,2)[12]          : Inf
    ARIMA(0,1,0)(0,1,1)[12]          : -
880.0685
    ARIMA(1,1,1)(0,1,1)[12]          : -
896.1031
    ARIMA(0,1,2)(0,1,1)[12]          : -
895.698
    ARIMA(1,1,0)(0,1,1)[12]          : -
893.2768
    ARIMA(1,1,2)(0,1,1)[12]          : -
894.0835

```

Best model: ARIMA(0,1,1)(0,1,1)[12]

Series: AirPassengers

ARIMA(0,1,1)(0,1,1)[12]

Box Cox transformation: lambda= -0.2947046

Coefficients:

```

          ma1      sma1
      -0.4355  -0.5847
s.e.   0.0908   0.0725

```

sigma^2 = 5.856e-05: log likelihood = 451.59


AIC=-897.18 AICc=-896.99 BIC=-888.55

### 3.23.1 Serie temporale

```


AirPassengers %>% autoplot() +
  labs(x="Tempo", y="Numero passeggeri", title="Passeggeri compagnie aeree USA")

```



### 3.23.2 Stabilizzata

```
diff(AirPassengers-0.295) %>% autoplot() +  
  labs(x="Tempo", y="Numero passeggeri", title="Passeggeri compagnie aeree USA")
```



### 3.24 Previsione


Una volta selezionato il modello più adatto (quello con **AIC minimo**) si può procedere a regressione e predizione

La predizione può essere ottenuta con la funzione `forecast()`

Tale funzione riporta anche le bande di confidenza al 95%

## 4 Predizione

```
fit <- forecast::auto.arima(AirPassengers, lambda="auto")
autoplot(forecast::forecast(fit,h=20)) +
  theme(axis.text.x = element_text(angle = 45,
    hjust = 1)) +
  labs(title="Predizione ARIMA(0,1,1)(0,1,1)[12]", x="Tempo", y="Numero passeggeri")
```



## 5 Dettaglio

```
fit <- forecast::auto.arima(AirPassengers, lambda="auto")
forecast::forecast(fit,h=20) %>%
  ggplot(aes(x=Index, y=Data)) +
  geom_line() +
  geom_ribbon(aes(ymin=`Lo 95`, ymax=`Hi 95`), alpha=1/3) +
  geom_ribbon(aes(ymin=`Lo 80`, ymax=`Hi 80`), alpha=1/3) +
  geom_line(aes(y=`Point Forecast`, color="blue")) +
  scale_x_date(limits=c(ymd("1960/1/1"), NA), date_minor_breaks = "1 month") +
```

```
theme(axis.text.x = element_text(angle = 45,
  hjust = 1)) +
labs(title="Predizione ARIMA(0,1,1)(0,1,1)[12]", x="Tempo", y="Numero passeggeri")
```

